

**PERBANDINGAN LATENT DIRICHLET ALLOCATION
DENGAN NONNEGATIVE MATRIX FACTORIZATION
UNTUK PEMODELAN TOPIK BERITA**



Oleh:

Aurellia Zhullvita Amanullah

220411100200

Dosen Pembimbing I :

HUSNI, S.Kom., MT.

(197707222003121006)

Dosen Pembimbing II :

Yoga Dwitya Pramudita, S.Kom., M.Cs. (198404132008121002)

PROGRAM STUDI TEKNIK INFORMATIKA

JURUSAN TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS TRUNODJOYO MADURA

2026

HALAMAN JUDUL

**PERBANDINGAN LATENT DIRICHLET ALLOCATION
DENGAN NONNEGATIVE MATRIX FACTORIZATION
UNTUK PEMODELAN TOPIK BERITA**

SKRIPSI

**Diajukan untuk Memenuhi Persyaratan Penyelesaian Studi Strata Satu
(S1) dan Memperoleh Gelar Sarjana Komputer (S. Kom.) di Program
Studi Teknik Informatika**

Jurusan Teknik Informatika

Fakultas Teknik

Universitas Trunojoyo Madura

**AURELLIA ZHULLVITA AMANULLAH
220411100200**

**PROGRAM STUDI TEKNIK INFORMATIKA
JURUSAN TEKNIK INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS TRUNODJOYO MADURA
2026**

HALAMAN PENGESAHAN

PERBANDINGAN LATENT DIRICHLET ALLOCATION DENGAN NONNEGATIVE MATRIX FACTORIZATION UNTUK PEMODELAN TOPIK BERITA

Skripsi ini diajukan sebagai salah satu syarat untuk menyelesaikan pendidikan di Program Studi Teknik Informatika Universitas Trunojoyo Madura

Oleh:

Nama : Aurellia Zhullvita Amanullah
NIM : 220411100200

Disetujui oleh Tim Penguji Skripsi:

Tanggal Sidang: 00 April 2026

Husni, S.Kom., MT.
197907222003121006

(Pembimbing I)

Yoga Dwitva Pramudita, S.Kom.,
M.Cs.
198404132008121002

(Pembimbing II)

Dr. Fika Hastarita Rachman, S.T.,
M.Eng
198303052006042002

(Penguji I)

Ika Oktavia Suzanti, S.Kom., M.Cs.
198810182015042004

(Penguji II)

Bangkalan, 01 Juli 2026

Mengetahui,

Ketua Jurusan Teknik Informatika

Husni, S.Kom., M.T.
197707222003121006

HALAMAN PERNYATAAN ORISINALITAS

Saya yang bertandatangan di bawah ini, menyatakan bahwa skripsi saya dengan judul:

” PERBANDINGAN LATENT DIRICHLET ALLOCATION DENGAN NONNEGATIVE MATRIX FACTORIZATION UNTUK PEMODELAN TOPIK BERITA”

1. Adalah asli, bukan merupakan karya pihak lain serta belum pernah diajukan untuk mendapatkan gelar akademik Sarjana Komputer baik di Universitas Trunojoyo Madura maupun di Perguruan Tinggi yang lain di Indonesia.
2. Tidak terdapat karya atau pendapat pihak lain yang pernah ditulis atau diterbitkan oleh orang lain, kecuali yang secara tertulis telah diacu dalam naskah ini dan disebutkan dalam daftar pustaka.

Apabila dikemudian hari terbukti skripsi ini sebagian atau seluruhnya merupakan hasil plagiasi atau terdapat hal-hal yang tidak sesuai dengan pernyataan diatas, maka saya sanggup menerima saksi akademis yang berlaku dengan segala akibat hukumnya sesuai peraturan Universitas Trunojoyo Madura dan atau peraturan perundang-undangan yang berlaku.

Bangkalan, 01 Juli 2026

Yang menyatakan,

AURELLIA ZHULLVITA AMANULLAH

NIM. 220411100200

ABSTRAK

Pertumbuhan pesat jumlah berita daring berbahasa Indonesia seiring kemajuan teknologi informasi telah menciptakan tantangan tersendiri dalam analisis manual, terutama karena volume data yang masif serta sifatnya yang tidak terstruktur. Oleh karena itu, diperlukan metode pemodelan topik untuk mengidentifikasi struktur tematik secara otomatis dari kumpulan dokumen teks. Penelitian ini bertujuan untuk membandingkan kinerja metode *Latent Dirichlet Allocation* (LDA) dan *Non-Negative Matrix Factorization* (NMF) dalam pemodelan topik pada berita online berbahasa Indonesia. Dataset yang digunakan terdiri atas 4.000 berita yang diperoleh melalui proses web scraping dari beberapa portal berita nasional dengan periode publikasi tahun 2020–2025, terbagi ke dalam empat kategori, yaitu politik, ekonomi, teknologi, dan olahraga. Tahapan penelitian meliputi preprocessing teks yang terdiri dari cleaning, case folding, tokenizing, stopwords removal, dan stemming, dilanjutkan dengan representasi data menggunakan TF-IDF. Selanjutnya, dilakukan pemodelan topik dengan jumlah topik optimal $K=4$ menggunakan metode LDA dan NMF serta evaluasi menggunakan metrik Topic Coherence (Cv) dan interpretabilitas topik secara kualitatif. Penelitian ini diharapkan dapat memberikan kontribusi dalam menentukan metode pemodelan topik yang lebih efektif serta memberikan gambaran struktur tematik pada berita online berbahasa Indonesia. Hasil penelitian menunjukkan bahwa NMF menghasilkan nilai rata-rata Topic Coherence (Cv) sebesar 0,7645, lebih tinggi dibandingkan LDA yang hanya sebesar 0,4830, serta menghasilkan kata-kata dominan yang lebih spesifik dan lebih mudah diinterpretasikan dibandingkan LDA. Dengan demikian, NMF terbukti lebih efektif dibandingkan LDA dalam pemodelan topik pada berita online berbahasa Indonesia.

Kata Kunci: Berita online, LDA, NMF, Pemodelan Topik, Topic Coherence

ABSTRACT

The development of information technology has led to a rapid increase in the number of Indonesian-language online news, making manual analysis difficult due to the large and unstructured data volume. Therefore, a topic modeling method is needed to automatically identify thematic structures from a collection of text documents. This study aims to compare the performance of the *Latent Dirichlet Allocation* (LDA) and *Non-Negative Matrix Factorization* (NMF) methods in topic modeling in Indonesian-language online news. The dataset consists of 4,000 news articles obtained through web scraping from several national news portals with a publication period of 2020–2025, divided into four categories: politics, economics, technology, and sports. The research stages include text preprocessing, consisting of cleaning, case folding, tokenizing, stopwords removal, and stemming, followed by data representation using TF-IDF. Next, topic modeling was carried out with an optimal number of topics of $K=4$ using the LDA and NMF methods, followed by evaluation using the Topic Coherence (Cv) metric and qualitative topic interpretability. This study is expected to contribute to determining more effective topic modeling methods and provide an overview of the thematic structure in Indonesian-language online news. The research results indicate that NMF yields an average Topic Coherence (Cv) score of 0.7645, higher than LDA's 0.4830, and produces more specific and more easily interpretable dominant words than LDA. Thus, NMF is proven to be more effective than LDA for topic modeling of Indonesian-language online news.

Keywords: Online news, LDA, NMF, Topic Modeling, Topic Coherence.

PENGANTAR

Alhamdulillah, puji dan syukur penulis panjatkan ke hadirat Allah Subhanahu wa Ta'ala karena atas rahmat, karunia dan hidayah-Nya penulis dapat menyelesaikan penyusunan skripsi yang berjudul **"PERBANDINGAN LATENT DIRICHLET ALLOCATION DENGAN NONNEGATIVE MATRIX FACTORIZATION UNTUK PEMODELAN TOPIK BERITA"** dengan baik dan lancar.

Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana pada Program Studi Teknik Informatika Fakultas Teknik Universitas Trunojoyo Madura. Dalam proses penyusunan skripsi ini, penulis menyadari bahwa keberhasilan ini tidak terlepas dari dukungan, bimbingan, dan doa dari berbagai pihak. Oleh karena itu, penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Allah SWT yang senantiasa melimpahkan rahmat dan hidayah-Nya tanpa henti, sehingga penulis diberi kekuatan hati, kesehatan, dan kesabaran dalam menyelesaikan penyusunan skripsi ini.
2. Mamiku tercinta, Nanin Ekawati, tidak ada rangkaian kata yang mampu menggambarkan betapa besar cinta, doa, dan pengorbanan yang telah Mami berikan dalam setiap langkah perjalanan ini. Terima kasih di saat penulis merasa lelah, ragu, dan hampir menyerah, selalu ada doa yang tidak pernah putus, pelukan yang menenangkan, serta keyakinan dari Mami yang menjadi kekuatan terbesar bagi penulis untuk terus melangkah hingga sampai di titik ini. Di setiap sujud Mami selalu ada nama penulis yang dipanjatkan kepada Allah, dan tanpa disadari itulah yang menjadi penopang di setiap langkah yang terasa berat. Skripsi ini menjadi salah satu bukti bahwa doa seorang ibu tidak pernah sia-sia.
3. Papiku tercinta, Amirullah, terima kasih telah menjadi sosok yang selalu menunjukkan kasih sayang melalui tindakan, bukan sekadar kata-kata. Mungkin tidak banyak yang Papi ucapkan, tetapi penulis selalu merasakan

bagaimana setiap usaha, pengorbanan, dan kerja keras yang Papi lakukan menjadi jalan yang mengantarkan penulis hingga sampai di titik ini.

4. Bapak HUSNI, S.Kom., MT. selaku Dosen Pembimbing I dan Bapak Yoga Dwitya Pramudita, S.Kom., M.Cs. selaku Dosen Pembimbing II yang telah memberikan arahan, bimbingan, serta motivasi yang sangat berarti kepada penulis selama proses penyusunan skripsi ini.
5. Bapak/Ibu Dosen penguji yang telah memberikan masukan, saran, dan arahan yang membangun demi kesempurnaan skripsi ini.
6. Bapak/Ibu Dosen Program Studi Teknik Informatika beserta staf Fakultas Teknik Universitas Trunojoyo Madura atas ilmu dan pengalaman yang telah diberikan selama masa studi penulis.
7. Seluruh teman-teman Program Studi Teknik Informatika yang telah memberikan dukungan dan semangat selama proses perkuliahan hingga penyusunan skripsi ini.
8. Kepada Ahmad Andi Zainuri (NIM 220411100176), terima kasih telah menjadi seseorang yang selalu ada di saat susah maupun senang, yang tidak pernah berhenti memberikan semangat ketika penulis hampir menyerah. Kehadiranmu bukan sekadar menemani, tetapi menjadi alasan penulis untuk terus bangkit dan menyelesaikan perjalanan ini sampai akhir. Terima kasih atas cinta, kesabaran, dan doa yang selalu kamu titipkan diam-diam. Semoga Allah selalu meridhoi langkah kita bersama.
9. Isnita Widyur Rahmah (NIM 220411100048) , sahabat seperjuangan sejak masa maba yang selalu hadir di setiap langkah perjalanan ini. Terima kasih atas kebersamaan, semangat, dan dukungan yang tidak pernah padam dari awal hingga akhir penyusunan skripsi ini. Semoga persahabatan kita terus terjaga dan perjalanan ini menjadi kenangan yang selalu kita banggakan bersama.
10. Kepada diriku sendiri, Aurellia Zhullvita Amanullah terima kasih telah bertahan. Terima kasih sudah tidak menyerah di saat segalanya terasa berat, sudah memilih untuk bangkit di setiap kali terjatuh, dan sudah mempercayai

bahwa perjuangan ini layak untuk diselesaikan. Perjalanan ini tidak selalu mudah, ada malam-malam panjang, keraguan, dan lelah yang tak terucapkan namun saya berhasil melewatinya. Ini adalah bukti nyata bahwa saya lebih kuat dari yang pernah saya bayangkan. Semoga pencapaian ini menjadi awal dari banyak hal baik yang akan terus datang, dan semoga saya selalu ingat bahwa diri saya sendiri pun layak untuk diapresiasi.

Akhirnya, semoga segala bantuan yang telah berikan semua pihak di atas menjadi amalan yang bermanfaat dan mendapatkan balasan dari Allah SWT dan skripsi ini menjadi informasi bermanfaat bagi pembaca atau pihak lain yang membutuhkannya. Penulis menyadari bahwa penyusunan skripsi ini masih jauh dari kata sempurna. Oleh karena itu, dengan kerendahan hati penulis memohon maaf dan mengharapkan kritik serta saran yang membangun.

Bangkalan, 01 Juli 2026

penulis

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PENGESAHAN	ii
HALAMAN PERNYATAAN ORISINALITAS	iii
ABSTRAK.....	iv
ABSTRACT.....	v
PENGANTAR	vi
DAFTAR ISI.....	ix
DAFTAR SINGKATAN	xiii
DAFTAR GAMBAR	xiv
DAFTAR TABEL.....	xv
DAFTAR KODE.....	xvi
BAB I	1
PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.2.1 Permasalahan.....	4
1.2.2 Metode Penelitian.....	5
1.2.3 Pertanyaan Penelitian.....	6
1.3 Tujuan dan Manfaat.....	6
1.3.1 Tujuan	6
1.3.2 Manfaat	6
1.4 Batasan Masalah.....	7
1.5 Sistematika Penulisan Skripsi	7
BAB II.....	10
KAJIAN PUSTAKA.....	10
2.1 Text Mining	10
2.2 Natural Language Processing.....	11
2.3 Text Preprocessing	12
2.3.1 Cleaning	13
2.3.2 Case Folding	13
2.3.3 Tokenizing.....	14

2.3.4	Stemming	14
2.3.5	Stopword Removal.....	15
2.3.6	Hasil Text Preprocessing.....	16
2.4	Pemodelan Topik.....	16
2.5	TF-IDF (Term Frequency – Inverse Document Frequency)	19
2.6	Latent Dirichlet Allocation (LDA)	21
2.6.1	Konsep Dasar LDA	21
2.6.2	Proses Generatif LDA	22
2.6.3	Parameter dalam LDA.....	22
2.6.4	Implementasi LDA dalam Penelitian	22
2.6.5	Kelebihan dan Keterbatasan LDA	23
2.6.6	Evaluasi Model LDA	23
2.6.7	Perplexity pada Model LDA	24
2.7	Non-Negative Matrix Factorization (NMF)	25
2.7.1	Konsep Dasar NMF	25
2.7.2	Proses Kerja NMF dalam Topic Modeling	26
2.7.3	Parameter dalam NMF	26
2.7.4	Output NMF dalam Penelitian	27
2.7.5	Kelebihan dan Keterbatasan NMF	28
2.7.6	Evaluasi Model NMF	28
2.8	Topic Coherence.....	29
2.8.1	Konsep Dasar Topic Coherence.....	30
2.8.2	Jenis-Jenis Topic Coherence	30
2.8.3	Rumus Dasar Topic Coherence (U_Mass).....	31
2.8.4	Peran Topic Coherence dalam Penelitian	31
2.8.5	Interpretabilitas dan Topic Coherence	32
2.9	Penelitian Terkait	32
2.10	Kerangka Pemikiran	38
BAB III		40
METODOLOGI PENELITIAN.....		40
3.1	Alur Penelitian.....	40
3.2	Pemahaman Bisnis (Business Understanding)	43
3.2.1	Tujuan Bisnis (Business Objectives)	43
3.2.2	Penilaian Situasi dan Kriteria Kesuksesan.....	44

3.3	Pemahaman Data (Data Understanding)	45
3.3.1	Sumber Data.....	45
3.3.2	Deskripsi Atribut.....	46
3.3.3	Eksplorasi Data Awal (Exploratory Data Analysis)	48
3.4	Persiapan Data (Data Preparation)	53
3.4.1	Pembersihan Data (Data Cleaning).....	54
3.4.2	Penghapusan Stopword dan Stemming.....	55
3.4.3	Representasi Data menggunakan TF-IDF	57
3.5	Pemodelan (Modeling)	58
3.5.1	Arsitektur Sistem End-to-End.....	59
3.5.2	Algoritma Latent Dirichlet Allocation (LDA)	62
3.5.3	Algoritma Non-negative Matrix Factorization (NMF)	64
3.5.4	Skenario Eksperimen	65
3.5.5	Perhitungan Manual	68
3.6	Evaluasi (Evaluation)	81
3.7	Implementasi Sistem (Implementation)	86
3.7.1	Arsitektur Implementasi Sistem.....	87
3.7.2	Proses Implementasi Pemodelan.....	87
3.7.3	Output Hasil Pemodelan	88
3.7.4	Lingkungan Implementasi.....	88
BAB IV		89
HASIL DAN PEMBAHASAN.....		89
4.1	Hasil Preprocessing Data.....	89
4.1.1	Statistik Dataset Setelah Preprocessing	90
4.1.2	Top-20 Kata dengan Frekuensi Tertinggi Setelah Preprocessing ...	92
4.1.3	Kode Implementasi Preprocessing.....	93
4.2	Hasil Representasi TF-IDF.....	94
4.2.1	Karakteristik Matriks TF-IDF	94
4.2.2	Kata dengan Bobot TF-IDF Tertinggi per Kategori	95
4.2.3	Kode Implementasi TF-IDF	96
4.3	Pencarian Jumlah Topik Optimal (K)	96
4.3.1	Hasil Pencarian K Optimal	97
4.3.2	Visualisasi Coherence dan Perplexity vs K	99
4.3.3	Kode Implementasi Pencarian K Optimal	100

4.4	Hasil Pemodelan Topik dengan Metode LDA	101
4.4.1	Topik yang Dihasilkan LDA.....	101
4.4.2	Parameter dan Nilai Evaluasi LDA.....	103
4.4.3	Kode Implementasi LDA	103
4.5	Hasil Pemodelan Topik dengan Metode NMF	104
4.5.1	Topik yang Dihasilkan NMF	105
4.5.2	Kode Implementasi NMF.....	106
4.6	Perbandingan Hasil LDA dan NMF	107
4.6.1	Dasar Penentuan Label Topik	107
4.6.2	Perbandingan Waktu Komputasi	110
4.6.3	Ringkasan Perbandingan LDA dan NMF	111
4.6.4	Analisis Interpretabilitas Topik.....	114
4.6.5	Kode Implementasi Perbandingan	115
4.7	Perbandingan Pengaruh Stemming terhadap Kualitas Topik	116
4.7.1	Konfigurasi Pipeline.....	116
4.7.2	Hasil Perbandingan Coherence	117
4.7.3	Kode Implementasi Pengaruh Stemming.....	118
4.8	Pembahasan	119
4.8.1	Analisis Perbandingan LDA dan NMF	119
4.8.2	Karakteristik Bahasa Indonesia dalam Pemodelan Topik.....	120
4.8.3	Keterkaitan dengan Penelitian Terdahulu	120
4.8.4	Implikasi Penelitian.....	121
BAB V.....		122
PENUTUP.....		122
5.1	Kesimpulan.....	122
5.2	Saran	123
DAFTAR PUSTAKA		125
DAFTAR RIWAYAT HIDUP.....		130

DAFTAR SINGKATAN

Notasi	Arti
LDA	Latent Dirichlet Allocation
NMF	Non-negative Matrix Factorization
TF	Term Frequency
IDF	Inverse Document Frequency
TF-IDF	Term Frequency – Inverse Document Frequency
NLP	Natural Language Processing
K	Jumlah Topik (<i>Number of Topics</i>)
α (Alpha)	Parameter distribusi Dirichlet pada dokumen (LDA)
β (Beta)	Parameter distribusi Dirichlet pada topik (LDA)
W	Matriks dokumen-topik (NMF)
H	Matriks topik-kata (NMF)
V	Matriks dokumen-term
Coherence	Ukuran kualitas topik berdasarkan keterkaitan kata
Perplexity	Ukuran performa model dalam memprediksi kata
Cv	Coherence Value (jenis metrik topic coherence)
Max iter	Jumlah iterasi maksimum dalam algoritma
Init	Metode inisialisasi matriks pada NMF
NNDSVD	Non-negative Double Singular Value Decomposition
Text Mining	Proses analisis data teks
Topic Modeling	Teknik untuk menemukan topik dalam dokumen
Preprocessing	Tahapan awal pengolahan data teks
Tokenizing	Proses pemecahan teks menjadi kata
Stopword	Kata umum yang tidak memiliki makna penting
Stemming	Proses mengubah kata menjadi bentuk dasar

DAFTAR GAMBAR

Gambar 3. 1 Analisis Distribusi Kategorihis	49
Gambar 3. 2 Panjang Dokumen	49
Gambar 3. 3 Histogram Panjang Dokumen	50
Gambar 3. 4 Missing Value	51
Gambar 3. 5 Alur Tahapan Preprocessing Teks.....	54
Gambar 3. 6 Arsitektur Sistem End-to-End Pemodelan Topik.....	60
Gambar 4. 1 Hasil Jumlah K Optimal.....	99

DAFTAR TABEL

Tabel 2. 1 Penelitian Terkait	34
Tabel 3. 1 Alur Penelitian Berdasarkan Kerangka CRISP-DM.....	41
Tabel 3. 2 Kamus Data Dataset Berita	46
Tabel 3. 3 hasil top kata setelah preprocessing	52
Tabel 3. 4 Contoh Hasil Preprocessing per Tahap	55
Tabel 3. 5 Contoh Hasil Stemming pada Data Berita	56
Tabel 3. 6 Konfigurasi Parameter TF-IDF	57
Tabel 3. 7 Skenario Pengujian Eksperimen	67
Tabel 3. 8 Sampel Data	68
Tabel 3. 9 Dokumen 1	69
Tabel 3. 10 Dokumen 2	69
Tabel 3. 11 Dokumen 3	70
Tabel 3. 12 Ringkasan Hasil Akhir Preprocessing.....	70
Tabel 3. 13 Perhitungan TF-IDF kata pemerintah	73
Tabel 3. 14 Perhitungan TF-IDF kata ekonomi	73
Tabel 3. 15 Perhitungan TF-IDF kata olahraga	73
Tabel 3. 16 Perhitungan TF-IDF kata indonesia.....	74
Tabel 3. 17 Hasil Pembobotan TF-IDF Dokumen Berita Dokumen 1	74
Tabel 3. 18 Hasil Pembobotan TF-IDF Dokumen Berita Dokumen 2	74
Tabel 3. 19 Hasil Pembobotan TF-IDF Dokumen Berita Dokumen 3	75
Tabel 3. 20 Distribusi Probabilitas Kata pada Setiap Topik	76
Tabel 3. 21 Perhitungan Coherence Politik.....	79
Tabel 3. 22 Perhitungan Coherence Ekonomi.....	80
Tabel 4. 1 Contoh Hasil Preprocessing per Tahap	90
Tabel 4. 2 Statistik Dataset Sebelum dan Sesudah Preprocessing	91
Tabel 4. 3 Top 20 Kata dengan Frekuensi Tertinggi Setelah Preprocessing	92
Tabel 4. 4 Karakteristik Matriks Dokumen-Term TF-IDF	94
Tabel 4. 5 Kata dengan Bobot TF-IDF Tertinggi per Kategori	95
Tabel 4. 6 Nilai Topic Coherence (Cv), Log-Perplexity LDA, dan Reconstruction Error NMF pada Berbagai Jumlah Topik (K)	97
Tabel 4. 7 Topik yang Dihasilkan oleh Metode LDA (K=4).....	102
Tabel 4. 8 Parameter dan Nilai Log-Perplexity Model LDA.....	103
Tabel 4. 9 Topik yang Dihasilkan oleh Metode NMF (K=4)	105
Tabel 4. 10 Dasar Penentuan Label Topik LDA dan NMF	107
Tabel 4. 11 Perbandingan Nilai Topic Coherence (Cv) LDA dan NMF	110
Tabel 4. 12 Perbandingan Waktu Komputasi LDA dan NMF	110
Tabel 4. 13 Ringkasan Perbandingan LDA dan NMF (matrik pembanding utama)	111
Tabel 4. 14 Metrik Diagnostik Internal Masing-Masing Metode (Tidak Diperbandingkan).....	113
Tabel 4. 15 Konfigurasi Pipeline Dengan Stemming vs Tanpa Stemming.....	116
Tabel 4. 16 Perbandingan Topic Coherence: Dengan Stemming vs Tanpa Stemming	117

DAFTAR KODE

Kode Program 4. 1 Implementasi Preprocessing	90
Kode Program 4. 2 Implementasi Preprocessing	93
Kode Program 4. 3 TF-IDF	96
Kode Program 4. 4 Pencarian K Optimal.....	101
Kode Program 4. 5 LDA	104
Kode Program 4. 6 Implementasi NMF	106
Kode Program 4. 8 Perbandingan	115
Kode Program 4. 9 Pengaruh Stemming.....	119

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi yang pesat telah mendorong meningkatnya jumlah berita online berbahasa Indonesia secara eksponensial. Berita online kini menjadi sumber informasi utama masyarakat karena dapat diakses dengan cepat dan mudah melalui berbagai platform digital. Setiap harinya, ribuan artikel berita dipublikasikan oleh berbagai portal berita nasional, menghasilkan volume data yang sangat besar dan bersifat tidak terstruktur. Kondisi ini menyulitkan proses analisis secara manual karena tidak efisien dan membutuhkan waktu yang sangat lama. Oleh karena itu, diperlukan metode pengolahan teks otomatis yang mampu mengekstraksi pola dan struktur tematik dari kumpulan dokumen berita secara efisien (Hou & Huang, 2025; Li et al., 2022).

Salah satu pendekatan yang banyak digunakan untuk menganalisis data teks tidak terstruktur adalah pemodelan topik (*topic modeling*), yaitu teknik yang bertujuan menemukan topik-topik tersembunyi dalam kumpulan dokumen secara otomatis tanpa memerlukan data berlabel (Vayansky & Kumar, 2020; Abdelrazek et al., 2023; Churchill & Singh, 2022). Metode ini bekerja dengan menganalisis pola distribusi kata dalam dokumen untuk mengungkap tema-tema utama yang merepresentasikan isi keseluruhan korpus (Qiang et al., 2020; Zuo et al., 2021). Karena termasuk dalam kategori *unsupervised learning*, pemodelan topik sangat sesuai untuk diterapkan pada data berita online yang umumnya tidak memiliki label kategori yang eksplisit (Murshed et al., 2023; Curiskis et al., 2020).

Pemodelan topik telah banyak diterapkan dalam berbagai domain penelitian, mulai dari analisis media sosial, forum diskusi, dokumen ilmiah, hingga berita online (Muthusami et al., 2024; Ghasiya & Okamura, 2021; Jung et al., 2024; Silva et al., 2021). Dalam konteks berita, metode ini digunakan untuk memahami opini publik, mengidentifikasi isu sosial yang sedang berkembang, serta menganalisis tren informasi dalam periode waktu tertentu (Kumi et al., 2024; Sik et al., 2023; Li &

Chang, 2023). Hal ini membuktikan bahwa pemodelan topik merupakan pendekatan yang relevan dan bernilai tinggi dalam analisis data teks berskala besar.

Meskipun pemodelan topik telah terbukti bermanfaat, terdapat permasalahan mendasar yang belum terselesaikan, yaitu perbedaan kualitas topik yang dihasilkan oleh setiap metode. Setiap metode memiliki karakteristik dan pendekatan yang berbeda sehingga dapat menghasilkan topik dengan tingkat koherensi, kejelasan, dan interpretabilitas yang berbeda pula (Amaro & Bacao, 2024; Rüdiger et al., 2022). Permasalahan ini menjadi semakin kritis pada data berita online berbahasa Indonesia yang memiliki kompleksitas linguistik tinggi, variasi kosakata yang beragam, serta penggunaan kata-kata serapan dan istilah daerah yang tidak ditemukan dalam bahasa lain. Hingga saat ini, belum terdapat acuan yang jelas mengenai metode pemodelan topik yang paling optimal untuk data berita online berbahasa Indonesia, khususnya dalam membandingkan *Latent Dirichlet Allocation* (LDA) dan *Non-negative Matrix Factorization* (NMF) secara langsung (Amaro & Bacao, 2024).

Sejumlah penelitian sebelumnya telah menerapkan LDA maupun NMF secara terpisah dalam pemodelan topik, namun menunjukkan hasil yang bervariasi bergantung pada karakteristik data yang digunakan. Sebagai contoh, beberapa studi menemukan bahwa LDA menghasilkan topik yang lebih representatif pada data yang berdistribusi luas, sementara studi lain menunjukkan bahwa NMF lebih unggul dalam menghasilkan topik yang lebih tajam dan mudah diinterpretasikan (Egger & Yu, 2022; Latif et al., 2021; M'sik & Casablanca, 2020). Perbedaan temuan ini mengindikasikan bahwa performa kedua metode sangat bergantung pada domain dan karakteristik data, sehingga perbandingan langsung pada konteks berita berbahasa Indonesia menjadi penting untuk dilakukan.

Di antara berbagai pendekatan pemodelan topik, LDA menonjol sebagai metode probabilistik yang paling luas diadopsi dalam penelitian text mining. LDA memodelkan dokumen sebagai campuran distribusi topik dan setiap topik sebagai distribusi kata, sehingga mampu menangkap hubungan laten antar kata dan dokumen secara fleksibel (Chauhan & Shah, 2021; Hua et al., 2020). Keunggulan utama LDA terletak pada kemampuannya memodelkan ketidakpastian distribusi

topik secara global sehingga cocok digunakan pada korpus berukuran besar dengan variasi tema yang luas (M'sik & Casablanca, 2020). Namun demikian, LDA memiliki keterbatasan dalam hal interpretabilitas, karena topik yang dihasilkan terkadang mengandung kata-kata yang secara semantik kurang kohesif sehingga sulit dipahami secara langsung.

Sebagai perbandingan, *Non-negative Matrix Factorization* (NMF) menawarkan pendekatan yang berbeda secara fundamental, yaitu berbasis faktorisasi matriks. NMF memecah matriks dokumen-kata menjadi dua matriks non-negatif yang merepresentasikan hubungan antara dokumen dan topik serta antara topik dan kata (Vangara et al., 2021; Ebrahimi & Peltonen, 2025). Karena setiap nilai dalam matriks bersifat non-negatif, representasi yang dihasilkan lebih bersifat parsimonious dan mudah diinterpretasikan. Keunggulan NMF terletak pada kemampuannya menghasilkan topik yang lebih spesifik, terpisah dengan jelas antar satu topik dengan topik lainnya, dan lebih mudah dipahami oleh pengguna akhir (M'sik & Casablanca, 2020). Namun, NMF tidak secara eksplisit memodelkan distribusi probabilitas antar topik seperti pada LDA sehingga representasinya lebih deterministik.

Perbedaan mendasar antara pendekatan probabilistik pada Latent Dirichlet Allocation (LDA) dan pendekatan faktorisasi matriks pada Non-Negative Matrix Factorization (NMF) menjadi dasar dilakukannya perbandingan antara kedua metode tersebut. LDA diketahui lebih unggul dalam memodelkan distribusi topik secara global serta dalam menangani ambiguitas kata, sedangkan NMF dinilai lebih mampu menghasilkan topik yang memiliki batas yang lebih jelas dan mudah diinterpretasikan.

Berdasarkan perbedaan tersebut, diperlukan analisis untuk menentukan metode yang lebih efektif ketika diterapkan pada data berita online berbahasa Indonesia. Penentuan metode yang lebih optimal tidak dapat dilakukan secara teoritis semata, melainkan harus didasarkan pada hasil evaluasi empiris yang dilakukan secara langsung terhadap dataset yang relevan (Egger & Yu, 2022; Latif et al., 2021; M'sik & Casablanca, 2020).

Konteks bahasa Indonesia menambah dimensi tersendiri dalam penelitian ini. Bahasa Indonesia memiliki karakteristik linguistik yang unik, di antaranya sistem afiksasi yang kompleks (penggunaan awalan, akhiran, dan imbuhan sisipan), penggunaan kata-kata serapan dari bahasa daerah maupun bahasa asing, serta gaya penulisan berita yang variatif antarportal. Karakteristik ini berpotensi memengaruhi kualitas representasi teks dan performa masing-masing metode pemodelan topik secara berbeda. Oleh karena itu, hasil penelitian dari konteks bahasa lain tidak dapat langsung digeneralisasikan ke data berbahasa Indonesia, dan studi komparatif yang berfokus pada konteks ini menjadi sangat dibutuhkan.

Evaluasi terhadap hasil pemodelan topik dalam penelitian ini dilakukan menggunakan metrik *topic coherence*, yaitu metrik yang mengukur tingkat keterkaitan semantik antar kata-kata teratas dalam suatu topik (Meaney et al., 2023; Hosseiny Marani & Baumer, 2023; Korenčić et al., 2021). Nilai koherensi yang lebih tinggi mengindikasikan bahwa topik yang dihasilkan lebih konsisten secara semantik dan lebih mudah dipahami. Selain itu, evaluasi juga dilengkapi dengan penilaian interpretabilitas topik secara kualitatif guna memperoleh gambaran yang lebih komprehensif mengenai kualitas hasil pemodelan.

Berdasarkan uraian permasalahan di atas, penelitian ini bertujuan untuk menganalisis dan membandingkan performa metode LDA dan NMF dalam pemodelan topik pada berita online berbahasa Indonesia. Dataset yang digunakan diperoleh melalui proses *web scraping* dari beberapa portal berita nasional dengan total 4.000 berita yang terbagi ke dalam empat kategori, yaitu politik, ekonomi, teknologi, dan olahraga, dengan periode publikasi tahun 2020–2025. Penelitian ini diharapkan mampu memberikan acuan empiris yang jelas mengenai metode pemodelan topik yang paling efektif pada konteks berita berbahasa Indonesia berdasarkan nilai *topic coherence* dan interpretabilitas, serta menjadi referensi bagi penelitian selanjutnya di bidang pengolahan teks berbasis *unsupervised learning*.

1.2 Rumusan Masalah

1.2.1 Permasalahan

Berdasarkan uraian pada latar belakang, permasalahan utama dalam penelitian ini adalah belum diketahuinya metode pemodelan topik yang paling

efektif dalam menghasilkan topik berkualitas pada data berita online berbahasa Indonesia. Meskipun pemodelan topik telah terbukti mampu mengekstraksi struktur tematik dari kumpulan dokumen secara otomatis, setiap metode menghasilkan topik dengan tingkat koherensi dan interpretabilitas yang berbeda-beda. Kondisi ini menyebabkan belum adanya acuan yang jelas mengenai metode yang paling optimal untuk digunakan pada konteks data berita berbahasa Indonesia, khususnya dalam hal perbandingan antara metode *Latent Dirichlet Allocation* (LDA) dan *Non-Negative Matrix Factorization* (NMF). LDA dan NMF merupakan dua metode pemodelan topik yang paling banyak digunakan, namun memiliki pendekatan yang secara fundamental berbeda. LDA berbasis probabilistik dan unggul dalam memodelkan distribusi topik secara global, sedangkan NMF berbasis faktorisasi matriks dan cenderung menghasilkan topik yang lebih spesifik serta mudah diinterpretasikan. Perbedaan pendekatan ini mengakibatkan kedua metode berpotensi menghasilkan kualitas topik yang berbeda ketika diterapkan pada dataset yang sama, khususnya pada berita berbahasa Indonesia yang memiliki kompleksitas linguistik tersendiri. Oleh karena itu, diperlukan analisis perbandingan yang sistematis untuk mengevaluasi performa kedua metode berdasarkan nilai *topic coherence* dan interpretabilitas topik yang dihasilkan (Egger & Yu, 2022; Amaro & Bacao, 2024; M'sik & Casablanca, 2020).

1.2.2 Metode Penelitian

Permasalahan tersebut dapat diatasi dengan menerapkan metode pemodelan topik menggunakan pendekatan unsupervised learning melalui beberapa tahapan yang saling berkaitan. Tahap pertama adalah pengumpulan dataset berita online berbahasa Indonesia yang diperoleh melalui proses web scraping dari beberapa portal berita nasional. Data yang digunakan berupa judul berita dan isi berita yang kemudian dilakukan tahap preprocessing teks yang meliputi pembersihan teks, tokenisasi, stopwords removal, dan stemming agar data siap diproses pada tahap berikutnya.

Tahap kedua adalah pembentukan representasi numerik teks menggunakan metode Term Frequency–Inverse Document Frequency (TF-IDF) sehingga dokumen teks dapat diolah dalam bentuk matriks dokumen-kata. Tahap ketiga adalah penerapan metode *Latent Dirichlet Allocation* (LDA) dan *Non-Negative*

Matrix Factorization (NMF) untuk menghasilkan sekumpulan topik beserta kata-kata dominan yang merepresentasikan isi berita. Kedua metode tersebut diterapkan pada dataset yang sama sehingga hasil yang diperoleh dapat dibandingkan secara objektif. Tahap terakhir adalah evaluasi dan perbandingan hasil pemodelan topik yang dihasilkan oleh metode LDA dan NMF. Evaluasi dilakukan berdasarkan nilai koherensi topik serta interpretabilitas topik yang dihasilkan untuk mengetahui metode yang lebih efektif dalam memodelkan topik berita online berbahasa Indonesia.

1.2.3 Pertanyaan Penelitian

Seberapa optimal perbandingan kualitas topik yang dihasilkan oleh metode LDA dan NMF dalam pemodelan topik berita online berbahasa Indonesia berdasarkan nilai topic coherence serta interpretabilitas dan kemampuan representasi tema dokumen?

1.3 Tujuan dan Manfaat

1.3.1 Tujuan

Tujuan penelitian ini adalah untuk menganalisis dan membandingkan kualitas topik yang dihasilkan oleh metode Latent Dirichlet Allocation (LDA) dan Non-Negative Matrix Factorization (NMF) dalam pemodelan topik berita online berbahasa Indonesia berdasarkan nilai topic coherence, interpretabilitas, serta kemampuan representasi tema dokumen.

1.3.2 Manfaat

Penelitian ini memberikan manfaat dalam mengetahui metode pemodelan topik yang lebih efektif antara LDA dan NMF pada data berita online berbahasa Indonesia. Melalui perbandingan yang dilakukan, penelitian ini mampu menunjukkan metode yang menghasilkan topik dengan kualitas lebih baik berdasarkan tingkat koherensi dan kemudahan interpretasi. Selain itu, hasil penelitian ini juga memberikan gambaran pola topik dalam berita online serta dapat menjadi referensi dalam pemilihan metode pemodelan topik yang sesuai pada penelitian serupa.

1.4 Batasan Masalah

1. Penelitian ini menggunakan data berupa berita online berbahasa Indonesia yang diperoleh melalui proses web scraping dari portal berita nasional seperti Kompas, Detik, CNN Indonesia, dan Antaranews dengan periode data tahun 2020–2025.
2. Jumlah data yang digunakan dalam penelitian ini 4000 berita, di mana 1 record merepresentasikan 1 berita yang terdiri dari judul berita dan isi berita.
3. Penelitian ini hanya menganalisis berita berbahasa Indonesia, sehingga berita berbahasa selain Bahasa Indonesia tidak disertakan dalam proses analisis.
4. Topik berita yang dianalisis dalam penelitian ini dibatasi pada kategori politik, ekonomi, teknologi, dan olahraga untuk merepresentasikan keberagaman isu dalam berita online.
5. Penelitian ini berfokus pada perbandingan kinerja metode Latent Dirichlet Allocation (LDA) dan Non-Negative Matrix Factorization (NMF) dalam pemodelan topik, tanpa melibatkan metode pemodelan topik lainnya.
6. Representasi teks yang digunakan dalam penelitian ini adalah TF-IDF (*Term Frequency–Inverse Document Frequency*) untuk membentuk matriks dokumen-kata sebelum diterapkan metode LDA dan NMF.
7. Tahapan preprocessing teks meliputi cleaning, case folding, tokenizing, stemming, stopword removal.
8. Evaluasi hasil pemodelan topik dilakukan menggunakan nilai topic coherence dan interpretabilitas topik.
9. Output penelitian berupa kumpulan topik beserta kata dominan pada setiap topik, dan bukan berupa klasifikasi berita.

1.5 Sistematika Penulisan Skripsi

Penulisan pada laporan ini akan ditulis ke dalam 5 bab, yaitu sebagai berikut :

BAB 1 PENDAHULUAN

Bab ini berisi latar belakang penelitian, perumusan masalah, usulan solusi, pertanyaan penelitian, tujuan penelitian, manfaat penelitian, batasan masalah, serta

sistematika penulisan laporan. Bab ini menjelaskan pentingnya analisis topik pada data berita online berbahasa Indonesia serta alasan pemilihan metode *Latent Dirichlet Allocation* (LDA) dan *Non-Negative Matrix Factorization* (NMF) sebagai metode pemodelan topik yang dibandingkan.

BAB II TINJAUAN PUSTAKA

Bab ini memuat teori-teori yang mendukung penelitian serta penelitian terdahulu yang relevan. Pembahasan dalam bab ini meliputi konsep *Text Mining*, *Natural Language Processing* (NLP), tahapan text preprocessing, pembobotan kata menggunakan TF-IDF, konsep pemodelan topik, metode *Latent Dirichlet Allocation* (LDA), metode *Non-Negative Matrix Factorization* (NMF), serta metode evaluasi model menggunakan topic coherence. Selain itu, bab ini juga membahas penelitian terdahulu yang berkaitan dengan penerapan pemodelan topik pada data teks.

BAB III TINJAUAN PUSTAKA

Bab ini menjelaskan metode penelitian yang digunakan dalam penelitian ini. Pembahasan meliputi proses pengumpulan dataset berita online berbahasa Indonesia, tahap preprocessing data yang terdiri dari case folding, tokenizing, stopwords removal, dan stemming, proses pembobotan kata menggunakan TF-IDF, penerapan metode LDA dan NMF untuk ekstraksi topik, serta proses evaluasi hasil pemodelan topik menggunakan nilai topic coherence untuk membandingkan performa kedua metode.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan seluruh hasil eksperimen pemodelan topik yang dilakukan terhadap dataset berita online berbahasa Indonesia. Pembahasan meliputi hasil preprocessing data, representasi TF-IDF, pencarian jumlah topik optimal (K), hasil pemodelan topik menggunakan metode LDA dan NMF, perbandingan nilai Topic Coherence (Cv) dan waktu komputasi kedua metode, serta analisis pengaruh stemming terhadap kualitas topik yang dihasilkan.

BAB V PENUTUP

Bab ini berisi kesimpulan dari hasil penelitian yang menjawab pertanyaan penelitian mengenai perbandingan kualitas topik antara metode LDA dan NMF berdasarkan nilai topic coherence, interpretabilitas, dan efisiensi komputasi. Selain itu, bab ini juga memuat saran untuk pengembangan penelitian selanjutnya di bidang pemodelan topik pada data teks berbahasa Indonesia.

BAB II

KAJIAN PUSTAKA

2.1 Text Mining

Text mining adalah serangkaian teknik komputasi yang digunakan untuk menggali informasi bernilai dari dokumen teks berskala besar. Pendekatan ini mengombinasikan metode statistik, pembelajaran mesin, serta pemrosesan bahasa alami (NLP) agar data tidak terstruktur dapat diubah menjadi pengetahuan yang terstruktur. (Li et al., 2022; Abdelrazek et al., 2023). Perkembangan teknologi informasi telah menyebabkan pertumbuhan data teks digital yang sangat pesat, terutama pada media online seperti portal berita, media sosial, forum diskusi, dan dokumen elektronik (Hou & Huang, 2025). Kondisi tersebut menyebabkan kebutuhan akan metode analisis teks otomatis menjadi semakin penting karena proses analisis manual tidak lagi efisien untuk menangani data dalam skala besar.

Data teks termasuk ke dalam kategori data tidak terstruktur (unstructured data) karena tidak memiliki format baku seperti data numerik pada basis data relasional (Vayansky & Kumar, 2020). Karakteristik data teks yang tidak terstruktur menyebabkan proses pengolahan data memerlukan tahapan khusus sebelum dapat dianalisis menggunakan algoritma komputasional. Oleh karena itu, text mining digunakan sebagai pendekatan yang mampu mengubah data teks menjadi bentuk representasi numerik sehingga dapat diproses lebih lanjut menggunakan metode machine learning (Abdelrazek et al., 2023).

Tahap preprocessing merupakan tahap yang sangat penting dalam text mining karena kualitas hasil analisis sangat dipengaruhi oleh kualitas data teks yang digunakan (Vayansky & Kumar, 2020). Data teks yang belum melalui preprocessing biasanya masih mengandung kata tidak penting, tanda baca, serta variasi kata yang dapat mengurangi kualitas hasil analisis. Dalam penelitian ini text mining digunakan untuk menganalisis berita online berbahasa Indonesia guna menemukan struktur topik yang tersembunyi dalam kumpulan dokumen berita menggunakan metode pemodelan topik. Secara umum proses text mining terdiri

dari beberapa tahapan utama yaitu pengumpulan data, preprocessing teks, transformasi data, pemodelan, serta evaluasi hasil (Hou & Huang, 2025).

2.2 Natural Language Processing

NLP adalah cabang ilmu yang berfokus pada pengembangan sistem komputer yang mampu memproses, menafsirkan, dan memahami bahasa manusia secara alami tanpa intervensi manual. Bidang ini menggabungkan teori linguistik komputasional, kecerdasan buatan, dan pembelajaran mesin. (Hou & Huang, 2025). NLP menggabungkan konsep dari linguistik komputer, kecerdasan buatan, dan machine learning untuk memungkinkan komputer memahami teks dalam bahasa alami. Bahasa alami memiliki struktur yang kompleks serta mengandung variasi kosakata, tata bahasa, dan makna yang berbeda-beda. Hal tersebut menyebabkan komputer tidak dapat langsung memproses teks tanpa dilakukan tahapan pengolahan terlebih dahulu (Zuo et al., 2021). Oleh karena itu, teknik NLP digunakan untuk mengubah teks menjadi bentuk yang lebih terstruktur sehingga dapat diproses oleh algoritma machine learning.

Natural Language Processing memiliki beberapa tahapan penting dalam pengolahan teks, diantaranya adalah tokenisasi, normalisasi teks, stopword removal, serta stemming (Vayansky & Kumar, 2020). Tahapan tokenisasi bertujuan untuk memecah teks menjadi unit-unit kata atau token. Normalisasi teks dilakukan untuk menyamakan bentuk kata seperti mengubah huruf menjadi huruf kecil serta menghilangkan tanda baca. Stopword removal digunakan untuk menghapus kata-kata umum yang tidak memiliki makna penting seperti "dan", "yang", serta "di". Sedangkan stemming bertujuan untuk mengubah kata berimbuhan menjadi kata dasar sehingga dapat mengurangi variasi kata dalam dokumen. Selain tahapan tersebut, Natural Language Processing juga mencakup proses representasi teks menjadi bentuk numerik agar dapat diproses oleh komputer. Representasi teks yang umum digunakan antara lain Bag of Words dan TF-IDF yang mengubah dokumen menjadi bentuk vektor angka berdasarkan frekuensi kemunculan kata. Representasi teks ini sangat penting dalam proses text mining karena menjadi dasar bagi algoritma machine learning untuk melakukan analisis data teks.

Natural Language Processing telah banyak digunakan dalam berbagai bidang penelitian seperti analisis media sosial, analisis berita online, analisis dokumen ilmiah, serta sistem rekomendasi berbasis teks (Muthusami et al., 2024; Jung et al., 2024; Silva et al., 2021). Selain itu, NLP juga digunakan untuk memahami opini masyarakat serta mengidentifikasi tren informasi dari kumpulan dokumen dalam jumlah besar (Kumi et al., 2024). Dalam penelitian ini Natural Language Processing digunakan sebagai tahap awal untuk mempersiapkan data berita online sebelum diterapkan metode pemodelan topik menggunakan LDA dan NMF.

2.3 Text Preprocessing

Sebelum data teks dapat dianalisis, perlu dilakukan serangkaian langkah awal yang dikenal sebagai preprocessing. Tujuan utama tahap ini adalah menghilangkan berbagai elemen pengganggu (noise) serta menyeragamkan format teks agar siap diproses oleh algoritma komputasi. Data teks yang diperoleh dari berita online umumnya masih mengandung berbagai karakter yang tidak diperlukan seperti tanda baca, angka, simbol, serta kata-kata yang tidak memiliki makna penting. Oleh karena itu, diperlukan proses preprocessing agar teks menjadi lebih terstruktur dan mudah diproses oleh algoritma machine learning (Vayansky & Kumar, 2020; Abdelrazek et al., 2023).

Tahap preprocessing sangat penting karena kualitas hasil analisis teks sangat dipengaruhi oleh kualitas data yang digunakan. Data teks yang tidak dibersihkan dengan baik dapat menyebabkan terbentuknya topik yang kurang jelas serta menurunkan nilai koherensi topik pada proses pemodelan topik (Meaney et al., 2023; Korenčić et al., 2021). Dengan melakukan preprocessing yang tepat, variasi kata dapat dikurangi sehingga distribusi kata dalam dokumen menjadi lebih konsisten dan mudah dianalisis (Qiang et al., 2020). Secara umum tahapan preprocessing yang digunakan dalam penelitian text mining meliputi case folding, cleaning, tokenizing, stopword removal, dan stemming (Vayansky & Kumar, 2020).

2.3.1 Cleaning

Cleaning merupakan proses pembersihan teks dari karakter yang tidak diperlukan seperti tanda baca, angka, simbol, hyperlink, serta karakter khusus lainnya. Proses cleaning bertujuan untuk menghilangkan noise yang dapat mengganggu proses analisis teks. Contoh proses cleaning:

Sebelum cleaning

"Pemerintah menaikkan harga BBM pada tahun 2024!!!"

Sesudah cleaning

"pemerintah menaikkan harga bbm pada tahun"

Karakter yang biasanya dihapus dalam proses cleaning meliputi:

- Tanda baca (.,!?)
- Angka
- Simbol (#,@,\$,%,&)
- URL atau hyperlink
- Karakter khusus

Proses cleaning membantu mengurangi jumlah kata yang tidak relevan sehingga model dapat lebih fokus pada kata-kata penting dalam dokumen (Qiang et al., 2020).

2.3.2 Case Folding

Case folding merupakan proses mengubah seluruh huruf dalam teks menjadi huruf kecil (lowercase). Proses ini bertujuan untuk menghilangkan perbedaan antara huruf kapital dan huruf kecil sehingga kata yang memiliki makna sama tidak dianggap sebagai kata yang berbeda.

Sebagai contoh kata:

"Indonesia", dan "INDONESIA"

akan diubah menjadi:

"indonesia"

Dengan melakukan case folding jumlah variasi kata dalam dokumen dapat dikurangi sehingga proses analisis menjadi lebih efisien (Vayansky & Kumar, 2020).

2.3.3 Tokenizing

Tokenizing merupakan proses memecah teks menjadi unit-unit kata yang disebut token. Setiap dokumen akan diubah menjadi kumpulan kata yang dapat diproses lebih lanjut oleh algoritma text mining (Zuo et al., 2021).

Sebagai contoh kalimat:

"pemerintah menaikkan harga bbm di indonesia"

akan diubah menjadi:

["pemerintah", "menaikkan", "harga", "bbm", "di", "indonesia"]

Tokenizing mempermudah proses analisis karena setiap kata dapat dihitung frekuensinya serta digunakan dalam pembentukan model pemodelan topik (Qiang et al., 2020). Pada penelitian ini, proses tokenisasi menggunakan token berbasis kata (word token) dengan pendekatan unigram, di mana setiap kata hasil preprocessing dianggap sebagai satu token. Proses tokenisasi dilakukan setelah tahapan cleaning dan case folding pada preprocessing data untuk memecah dokumen berita menjadi kumpulan kata yang dapat diproses lebih lanjut. Token yang dihasilkan selanjutnya digunakan sebagai dasar pembentukan representasi dokumen menggunakan metode TF-IDF sebelum dilakukan pemodelan topik menggunakan metode LDA dan NMF.

2.3.4 Stemming

Stemming merupakan proses mengubah kata berimbuhan menjadi kata dasar. Bahasa Indonesia memiliki banyak imbuhan seperti awalan, akhiran, dan sisipan sehingga satu kata dapat memiliki banyak variasi bentuk.

Contoh proses stemming:

- "pemerintahan" → "perintah"

- "membaca" → "baca"
- "berjalan" → "jalan"
- "teknologi" → "teknologi"

Stemming bertujuan untuk mengurangi variasi kata sehingga kata yang memiliki makna sama dapat dikelompokkan menjadi satu bentuk dasar (Vayansky & Kumar, 2020). Dengan melakukan stemming, jumlah fitur dalam dokumen dapat dikurangi sehingga proses pemodelan menjadi lebih efisien.

2.3.5 Stopword Removal

Stopword removal merupakan proses menghapus kata-kata umum yang sering muncul dalam dokumen tetapi tidak memiliki makna penting dalam pembentukan topik. Kata-kata tersebut disebut sebagai stopwords.

Contoh stopwords dalam bahasa Indonesia antara lain:

- yang
- dan
- di
- ke
- dari
- adalah
- dengan

Sebagai contoh kalimat:

"pemerintah menaikkan harga bbm di indonesia"

Setelah stopwords removal menjadi:

"pemerintah menaikkan harga bbm indonesia"

Penghapusan stopwords dapat meningkatkan kualitas model pemodelan topik karena kata-kata yang tidak penting tidak akan mempengaruhi pembentukan topik (Murshed et al., 2023).

2.3.6 Hasil Text Preprocessing

Setelah seluruh tahapan preprocessing dilakukan, teks berita online akan berubah menjadi kumpulan kata dasar yang lebih terstruktur. Hasil preprocessing kemudian digunakan sebagai input pada tahap transformasi teks menggunakan metode TF-IDF sebelum diterapkan metode pemodelan topik LDA dan NMF.


2.4 Pemodelan Topik

Salah satu teknik dalam text mining yang cukup populer adalah pemodelan topik. Teknik ini bekerja secara otomatis untuk mengidentifikasi tema-tema laten yang tersebar di dalam koleksi dokumen tanpa memerlukan label atau anotasi sebelumnya. (Umamaheswaran et al., 2023). Pemodelan topik bekerja dengan mengelompokkan kata-kata yang sering muncul secara bersamaan sehingga membentuk suatu topik tertentu. Setiap topik direpresentasikan sebagai kumpulan kata dengan probabilitas tertentu, sedangkan setiap dokumen direpresentasikan sebagai kombinasi beberapa topik dengan proporsi yang berbeda-beda (Qiang et al., 2020).

Pemodelan topik termasuk dalam metode pembelajaran tanpa pengawasan (*unsupervised learning*) karena tidak memerlukan data pelatihan yang telah diberi label sebelumnya (Hua et al., 2020). Metode ini banyak digunakan dalam analisis dokumen teks dalam jumlah besar seperti berita online, media sosial, artikel ilmiah, maupun dokumen digital lainnya (Vayansky & Kumar, 2020).

Dalam proses pemodelan topik, dokumen teks yang telah melalui tahapan preprocessing akan diubah terlebih dahulu ke dalam bentuk representasi numerik menggunakan metode pembobotan kata seperti Term Frequency (TF) atau Term Frequency – Inverse Document Frequency (TF-IDF) [19]. Representasi numerik tersebut biasanya disusun dalam bentuk matriks dokumen-kata (*Document-Term Matrix*) yang menjadi input bagi algoritma pemodelan topik (Curiskis et al., 2020).

Secara umum, proses pemodelan topik dapat digambarkan sebagai berikut:



Gambar 2. 1 proses topic modelling

pemodelan topik memiliki beberapa tujuan utama, yaitu:

1. Mengidentifikasi topik utama dari kumpulan dokumen teks.
2. Mengelompokkan dokumen berdasarkan kesamaan topik.
3. Mengetahui distribusi topik dalam setiap dokumen.
4. Menemukan pola informasi tersembunyi dalam data teks

(Umamaheswaran et al., 2023).

Dalam topic modeling, setiap dokumen diasumsikan memiliki lebih dari satu topik. Hal ini berarti suatu dokumen dapat memiliki kombinasi beberapa topik dengan proporsi tertentu. Sebagai contoh, sebuah berita online dapat mengandung topik politik dan ekonomi secara bersamaan, namun dengan tingkat dominasi yang berbeda-beda (Qiang et al., 2020). Distribusi topik pada dokumen dinyatakan sebagai:

$$P(z|d)$$

2.1

Keterangan:

- $P(z|d)$ = probabilitas topik z pada dokumen d
- z = topik

- d = dokumen

Distribusi kata pada suatu topik dinyatakan sebagai:

$$P(w|z) \quad 2.2$$

Keterangan:

- $P(w|z)$ = probabilitas kata w pada topik z
- w = kata
- z = topik

Beberapa metode yang umum digunakan dalam pemodelan topik antara lain:

1. *Latent Dirichlet Allocation* (LDA)
2. *Non-Negative Matrix Factorization* (NMF)
3. Latent Semantic Analysis (LSA) [17]

Dalam penelitian ini digunakan dua metode pemodelan topik yaitu *Latent Dirichlet Allocation* (LDA) dan *Non-Negative Matrix Factorization* (NMF) untuk membandingkan kualitas topik yang dihasilkan.

Metode LDA merupakan metode probabilistik yang mengasumsikan bahwa dokumen merupakan campuran dari beberapa topik, sedangkan setiap topik merupakan distribusi probabilitas dari kata-kata tertentu (Umamaheswaran et al., 2023).

Metode NMF merupakan metode faktorisasi matriks yang memecah matriks dokumen-kata menjadi dua matriks non-negatif yang merepresentasikan hubungan antara dokumen dan topik serta hubungan antara topik dan kata (Qiang et al., 2020).

Hasil dari kedua metode tersebut akan dievaluasi menggunakan nilai topic coherence untuk menentukan metode yang menghasilkan topik paling baik (Vayansky & Kumar, 2020).

Dalam penelitian ini pemodelan topik digunakan untuk menganalisis kumpulan berita online berbahasa Indonesia. Dokumen berita yang telah melalui tahapan preprocessing akan dianalisis menggunakan metode LDA dan NMF untuk menghasilkan sejumlah topik. Topik-topik yang dihasilkan kemudian akan dibandingkan menggunakan nilai topic coherence untuk menentukan metode terbaik dalam pemodelan topik berita online berbahasa Indonesia.

2.5 TF-IDF (Term Frequency – Inverse Document Frequency)

Salah satu teknik pembobotan kata yang populer dalam Information Retrieval dan Text Mining adalah TF-IDF, yang bertugas mengubah dokumen teks menjadi representasi numerik. Dalam bidang *Information Retrieval* dan *Text Mining* untuk merepresentasikan dokumen dalam bentuk numerik. Metode ini bertujuan untuk mengukur seberapa penting suatu kata dalam sebuah dokumen relatif terhadap keseluruhan koleksi dokumen (Egger & Yu, 2022). TF-IDF banyak digunakan sebagai tahap awal dalam pemodelan topik, klasifikasi teks, serta analisis sentimen karena mampu mengurangi pengaruh kata-kata umum yang sering muncul tetapi kurang informatif.

Metode TF-IDF dibangun di atas dua ukuran dasar. Pertama, frekuensi kemunculan suatu kata dalam dokumen (TF). Kedua, kebalikan dari frekuensi dokumen yang mengandung kata tersebut (IDF). Perkalian kedua nilai ini menghasilkan bobot yang mencerminkan pentingnya sebuah kata secara lokal (dalam satu dokumen) maupun global (dalam seluruh korpus).

1. Term Frequency (TF)

Term Frequency mengukur frekuensi kemunculan suatu kata dalam sebuah dokumen. Semakin sering kata muncul dalam dokumen, maka nilai TF semakin besar. Secara matematis, TF dapat dirumuskan sebagai:

$$TF(t, d) = \frac{f_{t, d}}{\sum_k f_{k, d}} \quad 2.3$$

keterangan:

- ft,d adalah jumlah kemunculan term t dalam dokumen d ,
- $\sum_k f_{k,d}$ adalah total seluruh kata dalam dokumen d .

Nilai TF menunjukkan tingkat kepentingan kata dalam dokumen tertentu, namun belum mempertimbangkan distribusi kata tersebut pada dokumen lain.

2. Inverse Document Frequency (IDF)

Inverse Document Frequency bertujuan untuk mengurangi bobot kata yang sering muncul di banyak dokumen karena dianggap kurang diskriminatif. IDF dirumuskan sebagai:

$$IDF(t) = \log\left(\frac{N}{df_t}\right) \quad 2.4$$

Keterangan :

- N adalah jumlah total dokumen,
- df_t adalah jumlah dokumen yang mengandung term t

Semakin banyak dokumen yang mengandung suatu kata, maka nilai IDF akan semakin kecil.

3. Perhitungan TF-IDF

Bobot akhir TF-IDF diperoleh dengan mengalikan nilai TF dan IDF:

$$TFIDF(t, d) = TF(t, d) \times IDF(t) \quad 2.5$$

Bobot ini mencerminkan tingkat kepentingan suatu kata dalam dokumen tertentu dibandingkan dengan keseluruhan koleksi dokumen.

Dalam penelitian ini, TF-IDF digunakan untuk mengubah data teks berita online berbahasa Indonesia menjadi representasi numerik sebelum diterapkan metode *Latent Dirichlet Allocation* (LDA) dan *Non-Negative Matrix Factorization* (NMF). Representasi berbasis TF-IDF membantu menonjolkan kata-kata yang

relevan dalam setiap dokumen serta meningkatkan kualitas pemodelan topik, khususnya pada metode NMF yang berbasis dekomposisi matriks non-negatif (Latif et al., 2021).

Penggunaan TF-IDF pada penelitian ini juga bertujuan untuk mengurangi pengaruh kata umum (*stopwords*) dan meningkatkan ketajaman distribusi kata dalam pembentukan topik. Dengan demikian, proses pemodelan topik dapat menghasilkan struktur tematik yang lebih representatif dan mudah diinterpretasikan.

2.6 Latent Dirichlet Allocation (LDA)

Salah satu pendekatan probabilistik dalam pemodelan topik yang pertama kali diperkenalkan oleh Blei, Ng, dan Jordan (2003) adalah *Latent Dirichlet Allocation* (LDA). LDA digunakan untuk mengidentifikasi struktur topik tersembunyi (*latent topics*) dalam kumpulan dokumen teks tanpa memerlukan data berlabel (Egger & Yu, 2022). Metode ini termasuk dalam kategori *unsupervised learning* karena tidak memerlukan anotasi atau pelabelan awal terhadap data.

Model LDA dibangun di atas dua asumsi utama. Pertama, sebuah dokumen dapat tersusun atas lebih dari satu topik dengan proporsi tertentu. Kedua, setiap topik dapat dijelaskan melalui sebaran probabilitas kata-kata yang menyusunnya. Dengan demikian, LDA memodelkan hubungan antara dokumen, topik, dan kata dalam bentuk distribusi probabilistik.

2.6.1 Konsep Dasar LDA

Dalam model LDA terdapat tiga komponen utama, yaitu:

1. Dokumen (Document)
Sekumpulan kata yang membentuk satu unit teks.
2. Topik (Topic)
Distribusi probabilitas atas kosakata tertentu.
3. Kata (Word)
Unit dasar yang membentuk dokumen.

LDA mengasumsikan bahwa:

- Setiap dokumen memiliki distribusi topik tertentu.
- Setiap topik memiliki distribusi kata tertentu.
- Pemilihan kata dalam dokumen dipengaruhi oleh distribusi topik tersebut.

Secara matematis, LDA menggunakan distribusi Dirichlet sebagai prior untuk distribusi topik dalam dokumen dan distribusi kata dalam topik.

2.6.2 Proses Generatif LDA

Secara konseptual, proses generatif LDA dapat dijelaskan (Egger & Yu, 2022): Secara konseptual, pembangkitan dokumen dalam LDA mengikuti alur berikut. Pertama, untuk setiap dokumen d , diambil suatu distribusi topik θ_d dari distribusi Dirichlet dengan parameter α . Kedua, untuk setiap topik k , diambil suatu distribusi kata ϕ_k dari distribusi Dirichlet dengan parameter β . Ketiga, untuk setiap kata yang akan muncul dalam dokumen, dipilih terlebih dahulu sebuah topik z_n berdasarkan distribusi θ_d , kemudian kata w_n dipilih berdasarkan distribusi kata ϕ_{z_n} dari topik yang telah terpilih tersebut.

2.6.3 Parameter dalam LDA

Beberapa parameter yang memengaruhi perilaku model LDA antara lain: jumlah topik (K), parameter Dirichlet α yang mengontrol sebaran topik per dokumen, serta parameter β yang mengatur sebaran kata per topik. Pemilihan nilai α dan β yang tepat dapat membuat topik yang dihasilkan lebih spesifik atau lebih umum.

2.6.4 Implementasi LDA dalam Penelitian

Dalam penelitian ini, metode LDA diterapkan pada data berita online berbahasa Indonesia yang telah melalui tahap *preprocessing* dan representasi numerik. Meskipun LDA secara umum menggunakan representasi *Bag-of-Words*, pada penelitian ini pembentukan matriks kata dilakukan setelah proses pembersihan teks untuk meningkatkan kualitas topik yang dihasilkan.

Output dari LDA berupa:

- Sejumlah topik (misalnya 5 topik)
- Daftar kata dominan pada setiap topik beserta bobot probabilitasnya

- Distribusi topik pada masing-masing dokumen

Sebagai contoh, suatu topik dapat direpresentasikan oleh kata-kata dominan seperti: *pemerintah*, *kebijakan*, *anggaran*, *kementerian*, yang kemudian dapat diinterpretasikan sebagai topik politik atau kebijakan publik.

2.6.5 Kelebihan dan Keterbatasan LDA

Latent Dirichlet Allocation (LDA) memiliki beberapa kelebihan dalam pemodelan topik, terutama dalam kemampuannya memodelkan distribusi probabilistik antar topik dalam kumpulan dokumen. Pendekatan ini memungkinkan setiap dokumen direpresentasikan sebagai campuran beberapa topik, sehingga mampu menangani ambiguitas kata dalam konteks yang berbeda. Selain itu, LDA dapat diterapkan pada kumpulan dokumen berukuran besar serta tidak memerlukan data berlabel karena termasuk dalam metode *unsupervised learning* (Egger & Yu, 2022; Latif et al., 2021).

Namun demikian, LDA juga memiliki beberapa keterbatasan. Salah satunya adalah sensitivitas terhadap penentuan jumlah topik (k), di mana pemilihan nilai yang tidak tepat dapat memengaruhi kualitas topik yang dihasilkan. Selain itu, interpretasi topik yang dihasilkan masih bergantung pada analisis manual oleh peneliti, sehingga bersifat subjektif. LDA juga cenderung kurang optimal ketika diterapkan pada dataset dengan ukuran kecil atau domain yang sangat spesifik (Korenčić et al., 2021; Egger & Yu, 2022).

2.6.6 Evaluasi Model LDA

Kualitas topik yang dihasilkan oleh metode Latent Dirichlet Allocation (LDA) umumnya dievaluasi menggunakan pendekatan kuantitatif dan kualitatif. Evaluasi kuantitatif dilakukan menggunakan metrik *topic coherence*, yang digunakan untuk mengukur tingkat keterkaitan semantik antar kata dalam suatu topik. Nilai *coherence* yang lebih tinggi menunjukkan bahwa topik yang dihasilkan lebih konsisten dan mudah dipahami (Egger & Yu, 2022; Korenčić et al., 2021).

Selain itu, evaluasi kualitatif dilakukan berdasarkan interpretabilitas topik, yaitu sejauh mana topik yang dihasilkan dapat dipahami dan diberi makna oleh peneliti berdasarkan kata-kata dominan yang muncul. Dalam penelitian ini, nilai

topic coherence digunakan sebagai indikator utama dalam membandingkan performa metode LDA dengan Non-Negative Matrix Factorization (NMF) dalam menghasilkan topik yang berkualitas.

2.6.7 Perplexity pada Model LDA

Perplexity merupakan salah satu metrik evaluasi standar yang digunakan untuk mengukur kualitas model probabilistik seperti LDA. Secara intuitif, perplexity mengukur seberapa baik model dalam memprediksi distribusi kata pada dokumen yang belum pernah dilihat sebelumnya, di mana semakin kecil nilai perplexity maka semakin baik kemampuan prediksi model tersebut (Meaney et al., 2023). Penting untuk dipahami bahwa nilai mentah yang dikembalikan fungsi `log_perplexity()` pada library Gensim adalah *per-word log-likelihood* (L) yang bersifat negatif, bukan nilai perplexity itu sendiri, sehingga konversi wajib dilakukan sebelum nilai tersebut dapat ditampilkan dan dibandingkan antar model. Nilai perplexity diperoleh melalui rumus konversi sebagai berikut:

$$PP = \exp(-L) \quad (2.6)$$

Keterangan:

PP = nilai perplexity (selalu positif)

L = per-word log-likelihood (nilai negatif dari Gensim)

exp = fungsi eksponensial

Nilai perplexity bersifat monoton menurun seiring bertambahnya jumlah topik K. Hal ini terjadi karena model dengan lebih banyak topik memiliki fleksibilitas yang lebih besar dalam menjelaskan distribusi kata pada dokumen, sehingga nilai perplexity akan selalu membaik tanpa batas meskipun topik yang dihasilkan semakin sulit diinterpretasikan. Oleh karena itu, perplexity tidak dapat digunakan sebagai satu-satunya dasar dalam menentukan jumlah topik optimal, melainkan harus dikombinasikan dengan metrik *topic coherence* (Cv) yang mengukur keterbacaan dan keterkaitan semantik antar kata dalam suatu topik.

Dalam penelitian ini, Perplexity digunakan sebagai metrik diagnostik internal untuk mengevaluasi kapasitas prediktif model LDA pada proses penentuan jumlah topik (K). Namun, karena NMF bukanlah model probabilistik, perplexity tidak memiliki dasar perhitungan yang valid secara teoretis untuk NMF, sehingga metrik ini tidak digunakan untuk membandingkan LDA dengan NMF.

2.7 Non-Negative Matrix Factorization (NMF)

Non-Negative Matrix Factorization (NMF) adalah teknik dekomposisi matriks yang banyak diaplikasikan untuk mengekstraksi fitur laten dari data berdimensi tinggi dengan kendala non-negatif. Dari data berdimensi tinggi dengan syarat seluruh elemen matriks bernilai non-negatif. Metode ini diperkenalkan oleh Lee dan Seung (1999) dan banyak digunakan dalam bidang *machine learning*, *data mining*, serta *text mining* (Egger & Yu, 2022). Dalam konteks pemodelan topik, NMF digunakan untuk mengidentifikasi struktur topik tersembunyi dengan memfaktorkan matriks dokumen-kata menjadi dua matriks yang lebih kecil dan interpretatif.

Berbeda dengan LDA yang berbasis model probabilistik, NMF merupakan pendekatan aljabar linear yang memanfaatkan teknik faktorisasi matriks untuk menemukan pola laten dalam data. Karena seluruh nilai matriks bersifat non-negatif, hasil dekomposisi cenderung lebih mudah diinterpretasikan sebagai bobot kontribusi kata terhadap suatu topik.

2.7.1 Konsep Dasar NMF

Prinsip kerja NMF adalah memecah matriks asli (dokumen vs kata) menjadi dua matriks yang lebih kecil. Matriks pertama (W) merepresentasikan hubungan antara dokumen dan topik, sedangkan matriks kedua (H) menggambarkan keterkaitan antara topik dan kata. Seluruh elemen dalam kedua matriks tersebut bernilai nol atau positif yaitu:

$$V \approx W \times H \quad 2.7$$

Keterangan :

- V = matriks dokumen-kata ($m \times n$)
- W = matriks dokumen-topik ($m \times k$)
- H = matriks topik-kata ($k \times n$)
- k = jumlah topik yang ditentukan

Matriks W menunjukkan bobot topik pada setiap dokumen, sedangkan matriks H menunjukkan bobot kata pada setiap topik. Proses faktorisasi dilakukan dengan meminimalkan fungsi kesalahan (error function), biasanya menggunakan pendekatan *Euclidean distance* atau *Kullback-Leibler divergence*.

2.7.2 Proses Kerja NMF dalam Topic Modeling

Tahapan penerapan NMF dalam pemodelan topik adalah sebagai berikut:

1. Melakukan *preprocessing* teks (case folding, tokenisasi, stopwords removal, stemming).
2. Mengubah teks menjadi representasi numerik menggunakan TF-IDF.
3. Membentuk matriks dokumen-kata.
4. Melakukan dekomposisi matriks menggunakan algoritma NMF.
5. Mengidentifikasi kata dengan bobot tertinggi pada setiap topik.
6. Menginterpretasikan topik berdasarkan kata dominan tersebut.

Karena NMF menggunakan representasi TF-IDF, metode ini cenderung menghasilkan topik yang lebih spesifik dan terfokus dibandingkan pendekatan probabilistik tertentu (Latif et al., 2021).

2.7.3 Parameter dalam NMF

1. Jumlah Topik (k)

Parameter ini menentukan jumlah topik yang akan diekstraksi dari kumpulan dokumen. Pemilihan nilai k sangat berpengaruh terhadap kualitas topik yang dihasilkan, di mana nilai yang terlalu kecil dapat menyebabkan topik menjadi terlalu umum, sedangkan nilai yang terlalu besar dapat menghasilkan topik yang redundan atau sulit diinterpretasikan (Vangara et al., 2021; Egger & Yu, 2022).

2. Metode Inisialisasi (Initialization Method)

Inisialisasi matriks awal (W dan H) merupakan faktor penting dalam proses konvergensi algoritma NMF. Metode inisialisasi yang umum digunakan antara lain random dan Non-negative Double Singular Value Decomposition (NNDSVD), di mana NNDSVD cenderung menghasilkan konvergensi yang lebih stabil dan cepat dibandingkan inisialisasi acak (Vangara et al., 2021).

3. Jumlah Iterasi Maksimum (Max Iteration)

Parameter ini menentukan jumlah iterasi maksimum dalam proses optimasi untuk meminimalkan fungsi error. Semakin besar jumlah iterasi, semakin besar peluang model mencapai konvergensi optimal, namun juga meningkatkan waktu komputasi Latif et al. (2021).

4. Metode Optimasi (Solver)

Solver digunakan untuk menentukan cara memperbarui matriks W dan H selama proses faktorisasi. Dua pendekatan umum yang digunakan adalah multiplicative update rules dan coordinate descent. Pemilihan solver memengaruhi kecepatan konvergensi dan stabilitas hasil pemodelan (Lee & Seung, 1999; Scikit-learn Documentation, 2023).

2.7.4 Output NMF dalam Penelitian

Output dari metode NMF dalam penelitian ini berupa:

- Sejumlah topik (misalnya 5 topik)
- Daftar kata dominan pada setiap topik beserta bobotnya
- Distribusi kontribusi topik pada masing-masing dokumen

Sebagai contoh, suatu topik dapat menghasilkan kata dominan seperti: *startup*, *aplikasi*, *teknologi*, *digital*, *platform*, yang dapat diinterpretasikan sebagai topik teknologi digital.

Berbeda dengan LDA yang menghasilkan probabilitas, NMF menghasilkan bobot kontribusi berbasis dekomposisi matriks, sehingga interpretasi topik cenderung lebih langsung berdasarkan nilai bobot tertinggi pada matriks H .

2.7.5 Kelebihan dan Keterbatasan NMF

Kelebihan:

Non-Negative Matrix Factorization (NMF) memiliki beberapa keunggulan dalam pemodelan topik, khususnya dalam menghasilkan representasi yang lebih mudah diinterpretasikan. Hal ini disebabkan karena seluruh nilai dalam matriks bersifat non-negatif sehingga topik yang terbentuk cenderung lebih jelas dan tidak saling tumpang tindih (Egger & Yu, 2022; Vangara et al., 2021).

Selain itu, NMF sangat cocok digunakan dengan representasi TF-IDF karena mampu menonjolkan kata-kata penting dalam dokumen. Hal ini menyebabkan topik yang dihasilkan lebih spesifik dan terfokus dibandingkan metode probabilistik tertentu (Latif et al., 2021; Egger & Yu, 2022).

NMF juga memiliki kemampuan yang baik dalam menangani data berdimensi tinggi seperti data teks, sehingga banyak digunakan dalam berbagai penelitian pemodelan topik (Vangara et al., 2021).

Keterbatasan:

Meskipun memiliki berbagai keunggulan, NMF juga memiliki beberapa keterbatasan. Salah satunya adalah sensitivitas terhadap inisialisasi awal, yang dapat memengaruhi hasil akhir dari proses faktorisasi matriks (Vangara et al., 2021).

Selain itu, NMF mengharuskan penentuan jumlah topik (k) di awal, sehingga pemilihan nilai yang tidak tepat dapat menghasilkan topik yang kurang optimal atau sulit diinterpretasikan (Latif et al., 2021).

Keterbatasan lainnya adalah NMF tidak memodelkan distribusi probabilistik antar topik seperti pada LDA, sehingga kurang mampu menangkap hubungan kompleks antar topik dalam dokumen (Egger & Yu, 2022).

2.7.6 Evaluasi Model NMF

Dalam penelitian ini, kualitas topik yang dihasilkan oleh metode *Non-Negative Matrix Factorization* (NMF) dievaluasi menggunakan pendekatan kuantitatif dan kualitatif.

1. Evaluasi Kuantitatif (Topic Coherence)

Evaluasi kuantitatif dilakukan menggunakan metrik *topic coherence*, yang digunakan untuk mengukur tingkat keterkaitan semantik antar kata dalam satu topik. Nilai *coherence* yang lebih tinggi menunjukkan bahwa topik yang dihasilkan lebih konsisten dan mudah dipahami (Egger & Yu, 2022; Korenčić et al., 2021).

2. Evaluasi Kualitatif (Interpretabilitas)

Selain evaluasi numerik, dilakukan juga evaluasi kualitatif berdasarkan interpretabilitas topik, yaitu sejauh mana topik yang dihasilkan dapat dipahami dan diberi makna oleh peneliti berdasarkan kata-kata dominan yang muncul dalam topik tersebut (Latif et al., 2021).

Hasil evaluasi tersebut kemudian digunakan untuk membandingkan performa metode NMF dengan metode lainnya, yaitu *Latent Dirichlet Allocation* (LDA), dalam menghasilkan topik yang berkualitas pada data berita online berbahasa Indonesia.

Selain evaluasi kualitatif, performa internal model NMF dapat diukur menggunakan *Reconstruction Error*, yaitu nilai error dari proses faktorisasi matriks $V \approx W \times H$. *Reconstruction Error* dihitung berdasarkan jarak antara matriks asli V dan hasil perkalian $W \times H$, di mana nilai yang semakin kecil menunjukkan bahwa proses faktorisasi berhasil mempertahankan struktur informasi dari data asli. Sama halnya dengan *Perplexity* pada LDA, *Reconstruction Error* pada NMF bersifat internal dan tidak digunakan sebagai metrik pembandingan antar-metode (LDA vs NMF) karena dasar matematis dan skala pengukurannya berbeda.

2.8 Topic Coherence

Salah satu metrik yang umum dipakai untuk menilai kualitas topik dari suatu model adalah topic coherence yang dihasilkan oleh metode *topic modeling*. Secara umum, *topic coherence* mengukur tingkat konsistensi semantik antar kata dalam satu topik, sehingga topik yang memiliki koherensi tinggi dianggap lebih mudah dipahami dan lebih bermakna secara konseptual (Egger & Yu, 2022).

Berbeda dengan metrik evaluasi berbasis probabilistik seperti *perplexity*, *topic coherence* lebih mencerminkan kualitas interpretatif dari topik yang

dihasilkan. Oleh karena itu, metrik ini banyak digunakan dalam penelitian pemodelan topik untuk membandingkan performa berbagai metode seperti LDA dan NMF (Latif et al., 2021).

Untuk menilai seberapa baik topik yang dihasilkan oleh suatu model, peneliti sering menggunakan metrik yang disebut *topic coherence*. Metrik ini mengukur tingkat kesesuaian semantik antar kata-kata yang muncul bersama dalam satu topik. Semakin tinggi nilai koherensi, semakin mudah topik tersebut dipahami oleh manusia.

2.8.1 Konsep Dasar Topic Coherence

Dalam *topic modeling*, satu topik biasanya direpresentasikan oleh sejumlah kata dengan bobot tertinggi. Misalnya:

Topik A $\rightarrow$ {pemerintah, kebijakan, anggaran, kementerian, regulasi}

Jika kata-kata tersebut sering muncul bersama dalam dokumen yang sama dan memiliki hubungan semantik yang kuat, maka topik tersebut memiliki nilai koherensi yang tinggi. Sebaliknya, jika kata-kata dalam satu topik jarang muncul bersama atau tidak memiliki hubungan semantik yang jelas, maka nilai koherensinya rendah.

2.8.2 Jenis-Jenis Topic Coherence

Beberapa metode perhitungan *topic coherence* yang umum digunakan antara lain:

1. C_V Coherence

C_V merupakan salah satu metrik *topic coherence* yang paling banyak digunakan karena mampu mengukur keterkaitan semantik antar kata dalam topik dengan pendekatan kombinasi seperti *sliding window*, *normalized pointwise mutual information* (NPMI), dan *cosine similarity*. Metrik ini memiliki korelasi yang cukup baik dengan penilaian manusia terhadap kualitas topik (Egger & Yu, 2022; Korenčić et al., 2021).

2. U_Mass Coherence

U_Mass merupakan metrik *coherence* yang berbasis probabilitas kemunculan bersama kata dalam dokumen. Metode ini lebih sederhana dan banyak digunakan pada pendekatan awal pemodelan topik, terutama pada model probabilistik seperti LDA. Namun, metrik ini cenderung kurang mencerminkan interpretasi manusia dibandingkan metrik lainnya (Latif et al., 2021; Egger & Yu, 2022).

3. C_UCI (Pointwise Mutual Information – PMI)

C_UCI menggunakan pendekatan statistik berbasis *pointwise mutual information* (PMI) untuk mengukur tingkat keterkaitan antar kata dalam suatu topik berdasarkan kemunculan bersama dalam korpus. Nilai yang lebih tinggi menunjukkan hubungan yang lebih kuat antar kata dalam topik tersebut (Korenčić et al., 2021; Egger & Yu, 2022).

Dalam penelitian ini, nilai *coherence* digunakan sebagai indikator kuantitatif untuk membandingkan kualitas topik yang dihasilkan oleh metode LDA dan NMF.

2.8.3 Rumus Dasar Topic Coherence (U_Mass)

Salah satu bentuk perhitungan *topic coherence* dapat dirumuskan sebagai berikut:

$$\text{Coherence} = (x + a)^n = \sum_{i < j} \log \frac{D(w_i, w_j) + 1}{D(w_i)} \quad 2.8$$

keterangan:

- $D(w_i, w_j)$ adalah jumlah dokumen yang mengandung kedua kata w_i dan w_j
- $D(w_i)$ adalah jumlah dokumen yang mengandung kata w_i

Nilai koherensi yang lebih tinggi menunjukkan hubungan antar kata yang lebih kuat dalam satu topik

2.8.4 Peran Topic Coherence dalam Penelitian

Dalam penelitian ini, *topic coherence* digunakan sebagai metrik utama untuk:

1. Menentukan jumlah topik optimal.
2. Membandingkan kualitas topik antara metode LDA dan NMF.
3. Mengukur seberapa baik model dalam merepresentasikan struktur tematik berita online berbahasa Indonesia.

Sebagai contoh, jika LDA menghasilkan nilai koherensi sebesar 0,48 dan NMF menghasilkan 0,56, maka dapat disimpulkan bahwa NMF menghasilkan topik yang lebih konsisten secara semantik.

2.8.5 Interpretabilitas dan Topic Coherence

Meskipun *topic coherence* merupakan metrik kuantitatif, interpretasi akhir tetap melibatkan analisis kualitatif oleh peneliti. Nilai koherensi yang tinggi umumnya sejalan dengan kemudahan dalam pemberian label topik, sehingga meningkatkan interpretabilitas hasil.

Oleh karena itu, dalam penelitian ini evaluasi dilakukan melalui dua pendekatan:

- Evaluasi kuantitatif → menggunakan nilai *topic coherence*
- Evaluasi kualitatif → analisis manual terhadap kata dominan pada setiap topik

Pendekatan kombinasi ini memberikan gambaran yang lebih komprehensif dalam menentukan metode pemodelan topik yang paling sesuai.

2.9 Penelitian Terkait

Penelitian terkait digunakan sebagai dasar dalam penelitian ini untuk menunjukkan perkembangan metode pemodelan topik serta penerapannya pada berbagai jenis data teks.

Berbagai penelitian sebelumnya menunjukkan bahwa metode pemodelan topik seperti LDA dan NMF mampu menemukan struktur topik tersembunyi dalam kumpulan dokumen teks secara efektif (Muthusami et al., 2024; Abdelrazek et al., 2023; Amaro & Bacao, 2024).

Penelitian yang dilakukan oleh Curiskis et al. (2020) menggunakan pemodelan topik untuk mengelompokkan teks tidak terstruktur dari media sosial,

khususnya komentar Reddit. Dataset yang digunakan berjumlah sekitar 40.000 dokumen. Hasil penelitian menunjukkan bahwa metode pemodelan topik mampu mengelompokkan dokumen dengan baik berdasarkan distribusi kata. Namun, kualitas topik yang dihasilkan sangat dipengaruhi oleh tahapan preprocessing serta jumlah topik yang ditentukan.

Penelitian oleh Hua et al. (2020) menerapkan metode probabilistic pemodelan topik menggunakan *Latent Dirichlet Allocation* (LDA) pada dataset dokumen teks sebanyak 5.000 data. Hasil penelitian menunjukkan bahwa LDA efektif dalam merepresentasikan distribusi probabilitas topik dalam dokumen dan dapat digunakan untuk membandingkan koleksi dokumen. Namun, interpretasi topik yang dihasilkan masih memerlukan analisis manual oleh pengguna.

Penelitian yang dilakukan oleh Korenčić et al. (2021) mengusulkan metode evaluasi topic coverage untuk mengukur keterwakilan topik dalam dokumen secara lebih komprehensif. Dataset yang digunakan berjumlah sekitar 8.000 dokumen teks. Hasil penelitian menunjukkan bahwa metode ini mampu memberikan evaluasi yang lebih menyeluruh dibandingkan metrik topic coherence, namun memerlukan perhitungan yang lebih kompleks.

Penelitian oleh Vangara et al. (2021) menggunakan metode *Non-Negative Matrix Factorization* (NMF) untuk melakukan dekomposisi matriks dokumen-kata pada dataset teks ilmiah. Hasil penelitian menunjukkan bahwa NMF mampu menghasilkan topik yang stabil dan efektif dalam menentukan jumlah topik yang optimal. Namun, penelitian ini tidak menyebutkan jumlah dataset secara spesifik.

Penelitian yang dilakukan oleh Balasubramaniam et al. (2021) menerapkan metode NMF dan tensor factorization untuk menganalisis data tweet COVID-19. Hasil penelitian menunjukkan bahwa metode tersebut mampu menangkap dinamika topik dan hubungan multidimensi dalam data teks. Namun, kompleksitas model menjadi salah satu keterbatasan dalam implementasinya.

Penelitian oleh Zuo et al. (2021) mengembangkan metode pemodelan topik berbasis word embedding untuk meningkatkan pemahaman semantik pada teks pendek. Hasil penelitian menunjukkan bahwa metode ini lebih akurat dalam

menangkap makna kata dibandingkan metode tradisional. Namun, metode ini membutuhkan komputasi yang lebih tinggi.

Penelitian yang dilakukan oleh Atzberger et al. (2023) melakukan evaluasi skala besar terhadap berbagai metode pemodelan topik dan teknik reduksi dimensi pada dataset dokumen teks. Hasil penelitian menunjukkan bahwa performa model sangat dipengaruhi oleh metode representasi data yang digunakan, sehingga pemilihan representasi menjadi faktor penting dalam pemodelan topik.

Penelitian oleh Batool dan Byun (2024) menggunakan metode *Latent Dirichlet Allocation* (LDA) untuk menganalisis data tweet selama pandemi. Hasil penelitian menunjukkan bahwa LDA mampu memodelkan distribusi topik secara probabilistik dengan baik. Namun, metode ini sensitif terhadap penentuan jumlah topik yang digunakan.

Penelitian yang dilakukan oleh Voskergian et al. (2024) mengusulkan pendekatan ensemble pemodelan topik dengan menggabungkan beberapa model untuk meningkatkan akurasi hasil. Hasil penelitian menunjukkan bahwa pendekatan ini mampu menghasilkan topik yang lebih akurat. Namun, kompleksitas model menjadi lebih tinggi dibandingkan metode tunggal.

Penelitian oleh Khodeir dan Elghannam (2025) menggunakan metode BERTopic untuk mengidentifikasi topik pada data forum MOOC. Hasil penelitian menunjukkan bahwa metode ini mampu menghasilkan topik yang lebih koheren dengan memanfaatkan embedding dan clustering. Namun, metode ini memerlukan sumber daya komputasi yang cukup besar.

Berikut merupakan rangkuman penelitian terdahulu yang relevan dengan penelitian ini.

Tabel 2. 1 Penelitian Terkait

No	Penulis & Tahun	Metode	Dataset	Hasil dan Keterbatasan
1	Curiskis et al. (2020)	Menggunakan pemodelan topik karena mampu mengelompokkan teks tidak	3 dataset OSN: (1) Twitter #Auspul: 29.283 tweet (13 topik politik), (2)	Model mampu mengelompokkan dokumen dengan baik, namun dipengaruhi

No	Penulis & Tahun	Metode	Dataset	Hasil dan Keterbatasan
		terstruktur dari media sosial secara otomatis berdasarkan distribusi kata	RepLab 2013: 2.657 tweet (13 kategori), (3) Reddit: 40.000 komentar dari 5 subreddit, dibagi berdasarkan panjang teks (total : 71.940)	preprocessing panjang teks, dan keterbatasan data sosial media yang noisy
2	Hua et al. (2020)	Menggunakan probabilistic pemodelan topik (LDA) karena mampu merepresentasikan distribusi probabilitas topik dalam dokumen	(5.000) dataset dokumen teks	Model efektif dalam membandingkan dokumen, namun interpretasi topik masih manual
3	Korenčić et al. (2021)	Menggunakan topic coverage sebagai metode evaluasi karena mampu mengukur keterwakilan topik dalam dokumen secara lebih komprehensif	(8.000) dataset teks	Evaluasi lebih komprehensif dibanding coherence
4	Vangara et al. (2021)	Menggunakan <i>Non-negative Matrix Factorization</i> (NMF) karena efektif dalam dekomposisi matriks dan menghasilkan topik yang lebih stabil	Menggunakan 9 benchmark dataset teks dengan rincian: BBC (2225 dokumen, berita), BBC-Sport (737 dokumen, berita olahraga), Guardian-2013 (27334 dokumen, berita), 20 Newsgroups s-ng-2 (1997	NMF stabil dalam menentukan jumlah topik

No	Penulis & Tahun	Metode	Dataset	Hasil dan Keterbatasan
			dokumen), s-ng-3 (2993 dokumen), s-ng-4 (3991 dokumen), s-ng-5 (4987 dokumen), Reuters-4 (8293 dokumen, berita), dan Reuters-5 (10387 dokumen, berita). Dataset berupa korpus teks yang diproses menjadi TF-IDF dan SPPMI.	
5	Balasubramaniam et al. (2021)	Menggunakan NMF dan tensor factorization karena mampu menangani data kompleks dan menganalisis hubungan multi-dimensi	Dataset tweet COVID-19 (tidak disebutkan jumlahnya)	Mampu menangkap dinamika topik
6	Zuo et al. (2021)	Menggunakan embedding-based pemodelan topik karena mampu menangkap makna semantik kata pada teks pendek	Dataset short text (tidak disebutkan jumlahnya)	Lebih akurat namun komputasi tinggi
7	Atzberger et al. (2023)	Menggunakan evaluasi skala besar pemodelan topik karena membandingkan performa berbagai metode pada dataset besar	Dataset dokumen teks (tidak disebutkan jumlahnya)	Performa tergantung representasi data

No	Penulis & Tahun	Metode	Dataset	Hasil dan Keterbatasan
8	Batool & Byun (2024)	Menggunakan <i>Latent Dirichlet Allocation</i> (LDA) karena mampu memodelkan distribusi probabilitas topik dalam teks	Dataset tweet pandemi (tidak disebutkan jumlahnya)	Sensitif terhadap jumlah topik
9	Voskergian et al. (2024)	Menggunakan ensemble pemodelan topik karena menggabungkan beberapa model untuk meningkatkan akurasi	Dataset teks (tidak disebutkan jumlahnya)	Akurasi meningkat namun kompleks
10	Khodeir & Elghannam (2025)	Menggunakan BERTopic karena menggabungkan embedding dan clustering untuk menghasilkan topik yang lebih koheren	Dataset forum MOOC (tidak disebutkan jumlahnya)	Topik lebih koheren

Beberapa penelitian menunjukkan bahwa metode *Latent Dirichlet Allocation* (LDA) memiliki keunggulan dalam pendekatan probabilistik untuk memodelkan distribusi topik dalam dokumen, sedangkan *Non-Negative Matrix Factorization* (NMF) cenderung menghasilkan topik yang lebih mudah diinterpretasikan. Selain itu, kualitas hasil pemodelan topik umumnya dievaluasi menggunakan metrik topic coherence untuk mengukur konsistensi semantik antar kata dalam topik.

Namun, berdasarkan penelitian terdahulu, sebagian besar studi hanya berfokus pada penggunaan satu metode pemodelan topik seperti LDA atau NMF tanpa melakukan perbandingan secara langsung. Selain itu, penelitian yang membandingkan kedua metode tersebut pada konteks berita online berbahasa


Indonesia dengan evaluasi berbasis topic coherence dan interpretabilitas masih terbatas. Oleh karena itu, penelitian ini dilakukan untuk mengisi kesenjangan tersebut dengan melakukan analisis komparatif antara LDA dan NMF pada dataset berita online berbahasa Indonesia.

2.10 Kerangka Pemikiran

Penelitian ini bertujuan untuk menganalisis dan membandingkan metode *Latent Dirichlet Allocation* (LDA) dan *Non-Negative Matrix Factorization* (NMF) dalam melakukan pemodelan topik pada berita online berbahasa Indonesia. Proses penelitian diawali dengan pengumpulan data berita online yang diperoleh melalui proses web scraping dari beberapa portal berita nasional.

Selanjutnya, data akan melalui tahap preprocessing teks yang meliputi case folding, tokenizing, stopwords removal, dan stemming. Setelah itu, dilakukan pembobotan kata menggunakan metode TF-IDF untuk membentuk representasi numerik dokumen. Tahap berikutnya adalah penerapan metode LDA dan NMF untuk menghasilkan topik-topik yang merepresentasikan isi dokumen.

Hasil dari kedua metode tersebut kemudian dievaluasi menggunakan metrik topic coherence serta dianalisis berdasarkan tingkat interpretabilitas topik. Kerangka pemikiran penelitian ini digambarkan pada Gambar 2.2



Gambar 2. 2 Diagram Kerangka Pemikiran

Gambar 2.2 menunjukkan alur penelitian yang dilakukan dalam penelitian ini. Proses dimulai dari pengumpulan dataset berita online, kemudian dilakukan tahap preprocessing yang meliputi case folding, tokenizing, stopwords removal, dan stemming. Selanjutnya, data direpresentasikan menggunakan metode TF-IDF sebelum diterapkan metode pemodelan topik menggunakan LDA dan NMF. Hasil pemodelan topik kemudian dievaluasi menggunakan topic coherence dan dibandingkan untuk menentukan metode yang paling optimal.

BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian

Penelitian ini dilakukan melalui beberapa tahapan yang sistematis untuk mencapai tujuan penelitian. Alur penelitian dimulai dari pengumpulan data, preprocessing teks, representasi data, pemodelan topik menggunakan metode Latent Dirichlet Allocation (LDA) dan Non-Negative Matrix Factorization (NMF), hingga tahap evaluasi dan analisis hasil.

Tahap pertama adalah pengumpulan data, yaitu mengumpulkan dataset berita online berbahasa Indonesia yang akan digunakan sebagai sumber data penelitian. Data yang diperoleh kemudian masuk ke tahap preprocessing teks, yang bertujuan untuk membersihkan dan menyiapkan data agar siap diolah. Proses ini meliputi pembersihan teks (cleaning), tokenisasi, penghapusan stopword, serta normalisasi kata.

Selanjutnya, dilakukan tahap representasi data menggunakan metode pembobotan TF-IDF. Tahap ini bertujuan untuk mengubah data teks menjadi bentuk numerik agar dapat diproses oleh algoritma pemodelan topik.

Tahap berikutnya adalah pemodelan topik menggunakan dua metode, yaitu Latent Dirichlet Allocation (LDA) dan Non-Negative Matrix Factorization (NMF). Kedua metode digunakan untuk mengidentifikasi pola tersembunyi dalam bentuk topik dari kumpulan dokumen berita. Pada tahap ini, jumlah topik ditentukan sebesar $K = 4$ untuk menjaga konsistensi perbandingan antar metode.

Setelah model terbentuk, dilakukan tahap evaluasi menggunakan metrik topic coherence (C_v) untuk mengukur kualitas topik yang dihasilkan berdasarkan keterkaitan semantik antar kata dalam setiap topik. Selain itu, waktu komputasi juga diperhatikan sebagai indikator efisiensi masing-masing metode.

Tahap terakhir adalah analisis hasil, yaitu membandingkan performa metode LDA dan NMF berdasarkan nilai evaluasi yang diperoleh. Hasil analisis ini digunakan

untuk menentukan metode yang lebih optimal dalam menghasilkan topik dari dataset berita yang digunakan.

Tahapan penelitian ini tuliskan dalam Tabel Alur Penelitian Berdasarkan Kerangka CRISP-DM 3.1.

Tabel 3. 1 Alur Penelitian Berdasarkan Kerangka CRISP-DM

Fase CRISP-DM	Aktivitas dalam Penelitian Ini	Sub Bab
Business Understanding	Identifikasi permasalahan: analisis manual berita online berbahasa Indonesia tidak efisien akibat volume data yang besar. Penetapan tujuan penelitian dan kriteria keberhasilan (nilai Topic Coherence Cv yang lebih tinggi antara LDA dan NMF).	3.2
Data Understanding	Pengumpulan 4.000 artikel berita dari portal nasional (Kompas, Detik, CNN Indonesia, Antara News) periode 2020–2025 melalui web scraping. Eksplorasi data awal: distribusi kategori, statistik panjang dokumen, frekuensi kata, dan analisis missing value.	3.3
Data Preparation	Preprocessing teks: cleaning, case folding, tokenizing, stopword removal, stemming, dan representasi numerik menggunakan TF-IDF.	3.4
Modeling	Pemodelan topik menggunakan LDA (pendekatan probabilistik) dan NMF (faktorisasi matriks), dengan jumlah topik $K=4$ dan evaluasi skenario eksperimen serta perhitungan manual.	3.5

Fase CRISP-DM	Aktivitas dalam Penelitian Ini	Sub Bab
Evaluation	Evaluasi kuantitatif utama menggunakan Topic Coherence (Cv) sebagai metrik pembandingan kinerja antar metode (LDA vs NMF). Evaluasi kualitatif berupa analisis interpretabilitas kata dominan pada setiap topik dan kemampuan representasi tema dokumen. Selain itu, digunakan metrik diagnostik internal pendukung, yaitu Perplexity (khusus LDA) dan Reconstruction Error (khusus NMF), yang berfungsi untuk memantau performa masing-masing metode secara terpisah dan tidak digunakan sebagai dasar perbandingan antara LDA dan NMF. Apabila hasil evaluasi belum memenuhi kriteria yang ditetapkan, dilakukan iterasi ke fase <i>Data Preparation</i> atau <i>Modeling</i>.	3.6
Deployment/Implementation	Implementasi sistem menggunakan Python mencakup pipeline preprocessing, pembobotan TF-IDF, pemodelan LDA dan NMF, serta perbandingan performa antar metode.	3.7

Berdasarkan Tabel 3.1 di atas, penelitian ini mencakup enam fase CRISP-DM. Sifat siklikal CRISP-DM memungkinkan adanya iterasi kembali ke fase

sebelumnya apabila hasil evaluasi belum memenuhi kriteria yang ditetapkan. Penjelasan rinci masing-masing fase diuraikan pada sub-bab berikutnya.

3.2 Pemahaman Bisnis (Business Understanding)

Tahap Business Understanding merupakan tahap awal dalam metodologi penelitian yang bertujuan untuk memahami tujuan penelitian dari perspektif kebutuhan sistem serta permasalahan yang ingin diselesaikan. Pada penelitian berbasis text mining dan topic modeling, tahap ini berfokus pada identifikasi kebutuhan analisis data teks yang dapat membantu dalam memahami pola informasi yang terkandung dalam kumpulan dokumen teks [Murshed et al., 2023].

Dalam konteks penelitian ini, objek yang dianalisis adalah dataset berita online yang memiliki jumlah dokumen besar dan beragam topik. Dengan meningkatnya jumlah informasi yang dipublikasikan secara digital, analisis manual terhadap berita menjadi semakin sulit dilakukan. Oleh karena itu, diperlukan pendekatan otomatis seperti pemodelan topik untuk mengidentifikasi tema atau topik utama yang muncul dalam kumpulan berita tersebut [Vayansky & Kumar, 2020].

Metode *Latent Dirichlet Allocation* (LDA) dan *Non-negative Matrix Factorization* (NMF) merupakan dua pendekatan yang banyak digunakan dalam analisis topik pada dokumen teks karena mampu menemukan pola topik tersembunyi secara otomatis dalam kumpulan dokumen yang besar. Oleh karena itu, penelitian ini bertujuan untuk membandingkan kedua metode tersebut dalam menghasilkan topik yang representatif pada dataset berita online.

3.2.1 Tujuan Bisnis (Business Objectives)

Tujuan utama dari penelitian ini adalah untuk membandingkan kinerja metode LDA dan NMF dalam menghasilkan topik pada data berita online berbahasa Indonesia berdasarkan kualitas topik yang dihasilkan.

Berdasarkan kebutuhan analisis data teks pada media digital, penelitian ini memiliki beberapa tujuan utama sebagai berikut:

1. Mengidentifikasi Topik Utama dalam Berita Online

Penelitian ini bertujuan untuk menemukan topik-topik utama yang muncul dalam kumpulan berita online menggunakan pendekatan topic modeling. Metode ini memungkinkan analisis terhadap kumpulan dokumen besar untuk menemukan struktur topik yang tersembunyi secara otomatis.

2. Menganalisis Performa Metode LDA dan NMF

Penelitian ini bertujuan untuk membandingkan kinerja metode *Latent Dirichlet Allocation* (LDA) dan *Non-negative Matrix Factorization* (NMF) dalam menghasilkan topik yang relevan dan mudah diinterpretasikan. Kedua metode ini merupakan teknik yang banyak digunakan dalam analisis teks untuk menemukan pola topik dalam kumpulan dokumen.

3. Mendukung Analisis Informasi dalam Dataset Berita

Dengan menggunakan teknik topic modeling, penelitian ini diharapkan dapat membantu dalam memahami pola informasi yang muncul dalam berita online sehingga memudahkan proses analisis data teks yang berjumlah besar.

3.2.2 Penilaian Situasi dan Kriteria Kesuksesan

Penelitian ini dilakukan dalam konteks meningkatnya jumlah data teks yang tersedia secara digital, khususnya pada media berita online. Analisis terhadap kumpulan berita dalam jumlah besar memerlukan metode otomatis yang mampu mengidentifikasi struktur informasi yang terkandung dalam teks. Pendekatan pemodelan topik telah banyak digunakan dalam berbagai penelitian untuk menganalisis dokumen teks dari berbagai domain seperti media sosial, berita, dan forum online. Dalam penelitian ini, keberhasilan metode yang digunakan akan diukur berdasarkan beberapa indikator evaluasi yang digunakan dalam analisis topic modeling.

1. Kriteria Kuantitatif

Keberhasilan model akan diukur menggunakan topic coherence, yaitu metrik yang digunakan untuk mengevaluasi kualitas topik yang dihasilkan oleh model. Nilai topic coherence yang lebih tinggi menunjukkan bahwa kata-kata dalam suatu topik memiliki hubungan semantik yang lebih kuat sehingga topik yang dihasilkan lebih mudah dipahami.

2. Kriteria Kualitatif

Selain evaluasi numerik, keberhasilan penelitian juga dilihat dari kemampuan model dalam menghasilkan topik yang mudah diinterpretasikan dan relevan dengan konteks berita online. Topik yang baik diharapkan mampu merepresentasikan tema utama yang terdapat dalam kumpulan dokumen berita yang ada. Dengan menggunakan kedua kriteria tersebut, penelitian ini diharapkan dapat memberikan gambaran yang jelas mengenai metode yang lebih efektif dalam menghasilkan pemodelan topik pada dataset berita online.

3.3 Pemahaman Data (Data Understanding)

Tahap Data Understanding merupakan tahap yang bertujuan untuk memahami data yang akan digunakan dalam penelitian. Pada tahap ini dilakukan proses pengumpulan data awal, identifikasi karakteristik dataset, serta analisis struktur data yang akan digunakan dalam proses pemodelan. Pemahaman data sangat penting dalam penelitian berbasis text mining karena kualitas dan karakteristik data akan mempengaruhi hasil analisis yang dilakukan.

Dalam penelitian topic modeling, data yang digunakan biasanya berupa kumpulan dokumen teks yang berasal dari berbagai sumber seperti media sosial, forum diskusi, maupun berita online. Dataset tersebut kemudian dianalisis untuk memahami distribusi teks, jumlah dokumen, serta karakteristik kata yang terdapat dalam dataset sebelum dilakukan proses preprocessing dan pemodelan topik.

Data yang digunakan dalam penelitian ini berupa berita online berbahasa Indonesia yang diperoleh melalui proses web scraping dari beberapa portal berita nasional seperti Kompas, Detik, CNN Indonesia, dan Antaranews.

3.3.1 Sumber Data

Dataset yang digunakan dalam penelitian ini adalah dataset berita online yang dikumpulkan dari portal berita digital yang tersedia secara publik di internet. Dataset ini terdiri dari kumpulan artikel berita yang berisi teks berita yang akan digunakan sebagai bahan analisis dalam proses topic modeling. Pengumpulan dataset dilakukan dengan mengambil sejumlah artikel berita yang memiliki berbagai kategori topik seperti politik, ekonomi, teknologi, dan olahraga. Setiap

dokumen berita kemudian disimpan dalam bentuk dataset teks yang selanjutnya akan diproses dalam tahap preprocessing.

Dataset yang digunakan dalam penelitian ini terdiri dari 4000 dokumen berita yang masing-masing berisi teks artikel berita (*dataset berita*). Data tersebut digunakan sebagai input dalam proses *pemodelan topik* menggunakan metode Latent Dirichlet Allocation (LDA) dan Non-negative Matrix Factorization (NMF).

Penggunaan dataset berita dalam penelitian pemodelan topik telah banyak dilakukan karena berita merupakan sumber informasi yang kaya akan topik dan mencerminkan berbagai isu yang berkembang di masyarakat (Egger & Yu, 2022; Latif et al., 2021). Selain itu, analisis topik pada berita digital dapat digunakan untuk memahami pola informasi serta tren yang muncul dalam periode waktu tertentu (Korenčić et al., 2021).

3.3.2 Deskripsi Atribut

Dataset yang digunakan dalam penelitian ini berupa kumpulan dokumen teks berita yang memiliki beberapa atribut utama yang digunakan dalam proses analisis. Atribut tersebut berfungsi untuk mengidentifikasi setiap dokumen serta menyimpan informasi teks yang akan dianalisis dalam proses topic modeling. Rincian atribut yang digunakan dalam dataset penelitian ini ditunjukkan pada Tabel 3.1

Tabel 3. 2 Kamus Data Dataset Berita

No	Nama Atribut	Deskripsi
1.	id_berita	Nomor identitas unik untuk setiap dokumen berita
2.	judul	Judul dari artikel berita
3.	isi_berita	Isi lengkap teks berita yang akan dianalisis dalam proses topic modeling

4.	kategori	Kategori topik berita seperti politik, ekonomi, teknologi, atau olahraga
----	----------	--

Dataset yang digunakan dalam penelitian ini terdiri dari beberapa atribut yang memiliki peran masing-masing dalam proses analisis, yaitu sebagai berikut:

id_berita

Atribut id_berita merupakan identitas unik untuk setiap data berita. Atribut ini digunakan sebagai penanda atau pembeda antar dokumen dalam dataset, sehingga memudahkan proses pengelolaan dan pelacakan data selama penelitian berlangsung.

judul_berita

Atribut judul_berita berisi ringkasan singkat dari isi berita. Judul digunakan sebagai informasi pendukung yang dapat membantu memberikan gambaran umum terhadap topik yang dibahas dalam dokumen, meskipun tidak selalu digunakan secara langsung dalam proses pemodelan.

isi_berita

Atribut isi_berita merupakan atribut utama yang digunakan dalam proses analisis karena berisi teks lengkap dari dokumen berita. Teks pada atribut ini akan diproses melalui tahapan *preprocessing*, pembobotan TF-IDF, serta pemodelan topik menggunakan metode LDA dan NMF. Data teks tersebut kemudian diubah menjadi representasi numerik agar dapat diproses oleh algoritma *machine learning*.

Atribut isi_berita merupakan atribut utama yang digunakan dalam proses analisis karena berisi teks dokumen yang akan diproses melalui tahapan preprocessing, pembobotan TF-IDF, serta pemodelan topik menggunakan metode LDA dan NMF. Data teks pada atribut ini akan diubah menjadi representasi numerik sehingga dapat diproses oleh algoritma machine learning.

Dataset terdiri dari 4000 data berita yang dikategorikan ke dalam empat topik utama, yaitu politik, ekonomi, teknologi, dan olahraga, dengan masing-masing kategori berjumlah sekitar 1000 data. Pembagian ini dilakukan untuk memberikan variasi konteks dalam proses pemodelan topik pada setiap kategori.

3.3.3 Eksplorasi Data Awal (Exploratory Data Analysis)

Eksplorasi Data Awal (Exploratory Data Analysis/EDA) merupakan tahapan awal yang dilakukan untuk memahami karakteristik dataset sebelum memasuki tahap preprocessing dan pemodelan. Pada tahap ini dilakukan analisis terhadap distribusi data, panjang dokumen, serta pola kemunculan kata dalam teks.

Tujuan dari EDA adalah untuk mengidentifikasi kondisi data, seperti adanya noise, ketidakseimbangan data, serta karakteristik teks, sehingga dapat menjadi dasar dalam menentukan metode preprocessing dan pemodelan yang tepat.

1. Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini merupakan data berita yang diperoleh melalui proses web scraping dari beberapa portal berita nasional, yaitu Kompas.com, Detik.com, CNN Indonesia, dan Antara News. Data yang dikumpulkan berada dalam rentang waktu tahun 2020 hingga 2025.


Jumlah data yang digunakan dalam penelitian ini adalah sebanyak 4000 berita, di mana setiap record merepresentasikan satu berita yang terdiri dari dua atribut utama, yaitu judul berita dan isi berita.

Topik berita dalam penelitian ini dibatasi ke dalam 4 kategori, yaitu:

- politik
- ekonomi
- teknologi
- olahraga

Pembatasan kategori ini dilakukan untuk memfokuskan analisis serta mempermudah interpretasi hasil pemodelan topik menggunakan metode LDA dan NMF. Proses pengambilan data dilakukan secara otomatis menggunakan teknik web scraping dengan memanfaatkan struktur halaman dari masing-masing portal berita. Dataset yang digunakan mencerminkan berbagai isu aktual pada masing-masing kategori, sehingga relevan untuk dilakukan analisis pemodelan topik. Dataset yang digunakan memiliki keragaman topik yang cukup sehingga mendukung proses identifikasi pola topik secara lebih optimal.

2. Distribusi Kategori Berita



Gambar 3. 1 Analisis Distribusi Kategorihis

Berdasarkan hasil analisis distribusi kategori, dataset yang digunakan terdiri dari 4.000 dokumen berita yang terbagi secara merata ke dalam empat kategori, yaitu politik, ekonomi, teknologi, dan olahraga, dengan masing-masing kategori berjumlah sekitar 1.000 dokumen. Distribusi yang seimbang antar kategori ini memastikan bahwa tidak terdapat dominasi satu kategori tertentu dalam proses pemodelan topik, sehingga hasil yang diperoleh dapat merepresentasikan keempat tema secara proporsional.

3. Statistik Panjang Dokumen


```
... Statistik panjang dokumen:
count    4000.000000
mean      445.548500
std       254.610525
min        10.000000
25%       277.000000
50%       388.000000
75%       558.000000
max       5648.000000
Name: panjang, dtype: float64
```

Gambar 3. 2 Panjang Dokumen

Panjang dokumen dihitung berdasarkan jumlah kata pada setiap isi berita. Hasil analisis menunjukkan bahwa rata-rata panjang dokumen adalah 445,5 kata, dengan panjang minimum 10 kata dan maksimum 5.648 kata. Sebagian besar dokumen berada pada rentang 100 hingga 600 kata per artikel. Hal ini menunjukkan bahwa sebagian besar dokumen memiliki panjang yang cukup untuk dilakukan pemodelan topik.

Dokumen dengan panjang yang cukup memungkinkan model LDA dan NMF menangkap distribusi kata secara lebih optimal dalam membentuk topik.

4. Distribusi Panjang Dokumen



Gambar 3. 3 Histogram Panjang Dokumen

Distribusi panjang dokumen menunjukkan bahwa mayoritas dokumen berada pada rentang panjang tertentu. Kondisi ini mengindikasikan bahwa dataset memiliki karakteristik yang sesuai untuk digunakan dalam pemodelan topik.

Metode seperti *Latent Dirichlet Allocation (LDA)* cenderung bekerja lebih optimal pada dokumen dengan panjang yang memadai karena mampu menangkap distribusi kata secara lebih representatif.

5. Analisis Frekuensi Kata Sebelum Preprocessing

Top 20 kata sebelum preprocessing:

[('yang', 39335), ('dan', 36216), ('di', 35908), ('ini', 16821), ('untuk', 16394), ('dari', 16049), ('dengan', 15726), ('dalam', 14796), ('pada', 13366), ('indonesia', 11813), ('juga', 10996), ('tidak', 9942), ('itu', 9767), ('menjadi', 8002), ('ke', 7622), ('akan', 7125), ('lebih', 6609), ('tersebut', 6430), ('sebagai', 6141), ('atau', 5103)]

Berdasarkan hasil analisis, kata-kata yang paling sering muncul sebelum preprocessing didominasi oleh kata umum seperti “yang”, “dan”, dan “di”, yang tidak memiliki makna spesifik terhadap topik. Hal ini menunjukkan perlunya tahap preprocessing untuk menghilangkan kata-kata yang tidak relevan.

6. Analisis Missing Value

```
... Missing value:
id_berita      0
judul          0
isi_berita     0
kategori       0
panjang        0
dtype: int64
```

Gambar 3. 4 Missing Value

Berdasarkan hasil pemeriksaan, tidak ditemukan nilai kosong (missing value) pada dataset. Oleh karena itu, seluruh data dapat langsung digunakan pada tahap preprocessing tanpa perlu penanganan khusus.

7. Analisis Setelah Preprocessing

Top 20 kata setelah preprocessing:

[('jadi', 12809), ('indonesia', 11835), ('sebut', 8375), ('lebih', 7005), ('kata', 6556), ('lalu', 4836), ('baca', 4678), ('laku', 4614), ('perintah', 4576), ('kerja', 4490), ('tahun', 4420), ('besar', 4383), ('hingga', 4328), ('ekonomi', 4267),

('sama', 4054), ('kuat', 3914), ('tingkat', 3885), ('negara', 3869), ('satu', 3805), ('jakarta', 3774)]

Setelah dilakukan preprocessing yang meliputi cleaning, case folding, tokenizing, stemming dan, stopwords removal. kata-kata yang dihasilkan menjadi lebih representatif terhadap topik tertentu.

Proses ini berhasil mengurangi noise serta menyatukan variasi kata, sehingga meningkatkan kualitas data untuk tahap pemodelan menggunakan metode LDA dan NMF.

Setelah dilakukan preprocessing, terjadi pengurangan jumlah kata unik (vocabulary) serta hilangnya kata-kata yang tidak relevan. Hal ini menunjukkan bahwa proses preprocessing berhasil meningkatkan kualitas representasi teks sehingga lebih siap digunakan dalam proses pembobotan dan pemodelan topik.

8. Contoh Hasil Preprocessing

Tabel 3. 3 hasil top kata setelah preprocessing

No	Sebelum preprocessing	Sesudah preprocessing
1.	Menteri Sekretaris Negara (Mensesneg) Prasetyo	menteri sekretaris negara mensesneg prasetyo
2.	KETUA Umum Partai Kebangkitan Bangsa Abdul Muh	ketua umum partai bangkit bangsa abdul muhaimi
3.	Surabaya (ANTARA) - Wakil Ketua Dewan Perwakilan	surabaya wakil ketua dewan wakil rakyat daerah
4.	Jakarta (ANTARA) - Presiden Prabowo Subianto	jakarta presiden prabowo subianto
5.	Jakarta (ANTARA) - Wakil Ketua Umum DPP Partai	jakarta wakil ketua umum dpp partai

Tabel berikut menunjukkan perbandingan teks sebelum dan sesudah preprocessing. Terlihat bahwa kata-kata yang tidak relevan telah dihilangkan dan bentuk kata telah dinormalisasi.


Hal ini menunjukkan bahwa proses preprocessing mampu menghasilkan representasi teks yang lebih bersih dan terstruktur. Berdasarkan hasil Exploratory Data Analysis (EDA), dilakukan perhitungan jumlah kata pada setiap dokumen dalam dataset berita. Hasil analisis menunjukkan bahwa rata-rata panjang dokumen adalah sebesar 300 - 800 kata per artikel, dengan panjang minimum 10 kata dan maksimum 5648 kata dan rata-rata 446 kata.

Distribusi panjang dokumen menunjukkan adanya variasi jumlah kata antar dokumen, namun sebagian besar berada pada rentang 100 hingga 600 kata. Berdasarkan karakteristik tersebut, dokumen dalam dataset dapat dikategorikan sebagai teks dengan panjang sedang/panjang.

Panjang dokumen ini dinilai cukup representatif untuk proses pemodelan topik menggunakan metode Latent Dirichlet Allocation (LDA) dan Non-negative Matrix Factorization (NMF), karena kedua metode tersebut cenderung menghasilkan performa yang lebih baik pada dokumen dengan jumlah kata yang memadai.

3.4 Persiapan Data (Data Preparation)

Tahap Data Preparation bertujuan untuk mempersiapkan data teks mentah agar dapat digunakan dalam proses pemodelan topik. Dataset berita online yang diperoleh melalui web scraping masih mengandung berbagai elemen tidak relevan seperti tanda baca, angka, simbol, dan tautan URL yang perlu dihilangkan sebelum dianalisis. Dalam penelitian ini, tahap persiapan data terdiri dari lima proses preprocessing teks secara berurutan, yaitu cleaning, case folding, tokenizing, stopwords removal, dan stemming, dilanjutkan dengan representasi numerik menggunakan TF-IDF. Alur keseluruhan proses preprocessing ditunjukkan pada Gambar 3.5 berikut:



Gambar 3. 5 Alur Tahapan Preprocessing Teks

3.4.1 Pembersihan Data (Data Cleaning)

Tahap data cleaning merupakan proses awal yang bertujuan untuk membersihkan teks dari elemen-elemen yang tidak diperlukan dalam analisis. Data berita yang diperoleh dari portal berita online umumnya masih mengandung karakter tambahan seperti tautan URL, tag HTML, tanda baca, angka, dan simbol yang tidak berkontribusi terhadap pembentukan topik.

Pada penelitian ini, proses cleaning mencakup tiga langkah utama, yaitu penghapusan URL dan tautan (http, www), penghapusan tag HTML, serta penghapusan karakter selain huruf alfabet. Setelah proses cleaning, dilakukan case folding yaitu mengubah seluruh teks menjadi huruf kecil (lowercase) agar tidak terjadi duplikasi kata akibat perbedaan penulisan huruf besar dan kecil. Sebagai contoh, kata "Teknologi" dan "teknologi" akan diperlakukan sebagai kata yang sama setelah case folding diterapkan.

Tahap berikutnya adalah tokenizing, yaitu proses memecah teks yang sudah bersih menjadi satuan kata tunggal (token). Setiap kata yang dipisahkan oleh spasi akan

menjadi satu token tersendiri. Contoh hasil tokenizing pada satu kalimat berita ditunjukkan pada Tabel 3.4 berikut:

Tabel 3. 4 Contoh Hasil Preprocessing per Tahap

Tahap	Hasil
Teks Asli	Pemerintah Indonesia melalui Kementerian ESDM resmi menetapkan harga BBM terbaru per 1 Januari 2024.
Cleaning	Pemerintah Indonesia melalui Kementerian ESDM resmi menetapkan harga BBM terbaru per Januari
Case Folding	pemerintah indonesia melalui kementerian esdm resmi menetapkan harga bbm terbaru per januari
Tokenizing	['pemerintah', 'indonesia', 'melalui', 'kementerian', 'esdm', 'resmi', 'menetapkan', 'harga', 'bbm', 'terbaru', 'per', 'januari']
Stopword Removal	['pemerintah', 'indonesia', 'kementerian', 'esdm', 'resmi', 'menetapkan', 'harga', 'bbm', 'terbaru', 'januari']
Stemming	['perintah', 'indonesia', 'menteri', 'esdm', 'resmi', 'tetap', 'harga', 'bbm', 'baru', 'januari']

Tahapan preprocessing meliputi:

- Cleaning (penghapusan tanda baca, angka, simbol)
- Case folding
- Tokenizing
- Stemming
- Stopword Removal

3.4.2 Penghapusan Stopword dan Stemming

Setelah proses cleaning, case folding, dan tokenizing selesai dilakukan, tahap selanjutnya adalah stopwords removal dan stemming. Kedua proses ini bertujuan untuk mengurangi dimensi data dan memfokuskan analisis pada kata-kata yang memiliki makna penting.

Stopword removal merupakan proses penghapusan kata-kata umum yang sering muncul dalam teks namun tidak memiliki kontribusi terhadap makna utama dokumen. Pada penelitian ini, daftar stopwords yang digunakan berasal dari library PySastrawi yang telah dilengkapi dengan daftar stopwords bahasa Indonesia, kemudian diperkaya dengan stopwords tambahan (custom stopwords) yang relevan untuk domain berita online, seperti nama portal berita (kompas, detik, cnn, tribun), kata sambung tambahan, dan artefak hasil scraping seperti quot dan amp. Total stopwords yang digunakan mencakup seluruh daftar bawaan PySastrawi ditambah 40 kata kustom yang diidentifikasi dari karakteristik dataset.

Selanjutnya dilakukan proses stemming menggunakan library PySastrawi, yaitu mengubah kata berimbuhan menjadi bentuk kata dasar. Proses ini membantu mengelompokkan variasi morfologis kata yang memiliki makna sama ke dalam satu representasi yang seragam, sehingga mengurangi sparsitas data dan meningkatkan kualitas pemodelan topik. Contoh hasil stemming pada beberapa kata dari dataset penelitian ini ditunjukkan pada Tabel 3.5 berikut:

Tabel 3. 5 Contoh Hasil Stemming pada Data Berita

Kata Asli	Hasil Stemming
pemerintahan	perintah
kementerian	menteri
pertumbuhan	tumbuh
perekonomian	ekonomi
pemilihan	pilih
kebijakan	Bijak
pembangunan	bangun
menetapkan	tetap

Proses stemming tidak selalu menghasilkan kata dasar yang secara semantik tepat. Sebagai contoh, kata "pemerintah" di-stem menjadi "perintah" yang memiliki makna berbeda. Artefak stemming ini merupakan keterbatasan dari algoritma Nazief-Adriani yang digunakan oleh PySastrawi dan menjadi salah satu faktor yang memengaruhi kualitas topik yang dihasilkan.

3.4.3 Representasi Data menggunakan TF-IDF

Setelah proses preprocessing selesai, data teks yang telah bersih diubah menjadi representasi numerik menggunakan metode Term Frequency-Inverse Document Frequency (TF-IDF). Representasi ini diperlukan karena algoritma NMF membutuhkan input berupa matriks numerik, sedangkan LDA menggunakan representasi Bag of Words (BoW) yang dibangun dari dictionary Gensim.

TF-IDF mengukur seberapa penting suatu kata dalam sebuah dokumen relatif terhadap seluruh koleksi dokumen. Kata yang sering muncul di banyak dokumen akan mendapat bobot rendah (IDF kecil), sedangkan kata yang sering muncul di satu dokumen tertentu namun jarang di dokumen lain akan mendapat bobot tinggi. Konfigurasi TF-IDF yang digunakan dalam penelitian ini adalah sebagai berikut.

Tabel 3. 6 Konfigurasi Parameter TF-IDF

Parameter	Nilai	Keterangan
max_features	10.000	Maksimum 10.000 kata unik yang dipertimbangkan
min_df	5	Kata harus muncul minimal di 5 dokumen
max_df	0,90	Kata yang muncul di lebih dari 90% dokumen diabaikan
ngram_range	(1,1)	Hanya kata tunggal (unigram) yang digunakan

Parameter min_df = 5 digunakan untuk mengabaikan kata yang terlalu jarang muncul karena dianggap tidak representatif, sedangkan max_df = 0,90 digunakan untuk mengabaikan kata yang terlalu umum karena muncul di hampir semua dokumen. Hasil TF-IDF berupa matriks berukuran 4.000×8.903 yang selanjutnya digunakan sebagai input pada model NMF. Jumlah fitur yang lebih kecil dibandingkan batas max_features sebesar 10.000 terjadi karena tidak semua kata memenuhi kriteria filter min_df dan max_df yang ditetapkan. Sedangkan untuk model LDA digunakan representasi Bag of Words yang dibangun menggunakan dictionary Gensim dengan filter yang sama (no_below = 5, no_above = 0,90).

3.5 Pemodelan (Modeling)

Tahap pemodelan merupakan inti dari penelitian ini, di mana algoritma machine learning diterapkan untuk menemukan pola tersembunyi dalam data teks yang telah melalui proses preprocessing. Pada penelitian berbasis pemodelan topik, tujuan utama dari tahap ini bukan untuk melakukan prediksi, melainkan untuk mengidentifikasi struktur topik yang terdapat dalam kumpulan dokumen secara otomatis.

Dalam penelitian ini, proses pemodelan dilakukan dengan menerapkan dua metode utama, yaitu *Latent Dirichlet Allocation* (LDA) dan *Non-negative Matrix Factorization* (NMF). Kedua metode tersebut digunakan untuk mengekstraksi topik dari dataset berita online berdasarkan distribusi kata yang muncul dalam dokumen.

Metode LDA merupakan pendekatan probabilistik yang mengasumsikan bahwa setiap dokumen terdiri dari kombinasi beberapa topik, dan setiap topik terdiri dari distribusi kata tertentu. Model ini bekerja dengan mengidentifikasi hubungan antara kata dan dokumen untuk menemukan topik yang tersembunyi dalam kumpulan data teks.

Sementara itu, metode NMF merupakan teknik faktorisasi matriks yang digunakan untuk mendekomposisi matriks dokumen-term menjadi dua matriks non-negatif, sehingga menghasilkan representasi topik yang lebih mudah diinterpretasikan. Pendekatan ini banyak digunakan dalam analisis teks karena mampu menghasilkan topik dengan distribusi kata yang lebih jelas dan terstruktur.


Tujuan utama dari tahap pemodelan ini adalah untuk menghasilkan kumpulan topik dari dataset berita online yang dapat merepresentasikan tema utama dalam dokumen. Hasil dari kedua metode kemudian akan dibandingkan untuk mengetahui metode mana yang menghasilkan topik yang lebih baik berdasarkan evaluasi yang dilakukan.

Dengan demikian, tahap pemodelan dalam penelitian ini berperan penting dalam proses ekstraksi informasi dari data teks serta menjadi dasar dalam proses evaluasi dan perbandingan metode yang dilakukan pada tahap selanjutnya. Parameter yang diuji yang diuji pada metode LDA meliputi jumlah topik

(num_topics) dengan variasi nilai $K = 2, 3, 4, 5, 6, 7$, dan 8 untuk menentukan jumlah topik optimal. Sedangkan pada metode NMF, parameter yang digunakan meliputi n_components sebagai jumlah topik, metode inisialisasi matriks (init = random), dan jumlah iterasi maksimum (max_iter = 200).

3.5.1 Arsitektur Sistem End-to-End

Arsitektur sistem dalam penelitian ini dirancang secara berurutan (*pipeline*) untuk menggambarkan alur pemodelan topik mulai dari data mentah hingga diperoleh hasil perbandingan metode. Arsitektur ini mencerminkan keseluruhan proses yang diimplementasikan, seperti yang ditunjukkan pada Gambar 3.6



Gambar 3. 6 Arsitektur Sistem End-to-End Pemodelan Topik

Berdasarkan Gambar 3.6 arsitektur sistem terdiri dari enam tahap utama yang saling terhubung, yaitu:

1. Pengumpulan Data (*Data Collection*)

Keyword: Web Scraping, Dataset Berita

Tahap awal dilakukan melalui proses web scraping terhadap portal berita nasional (Kompas, Detik, CNN Indonesia, Antaranews) dengan periode publikasi 2020–2025. Sebanyak 4.000 dokumen berita dikumpulkan, masing-masing terdiri dari judul dan isi berita. Data ini menjadi masukan untuk tahap berikutnya.

2. Preprocessing Teks (*Text Preprocessing*)

Keyword: Cleaning, Case Folding, Tokenizing, Stemming, Stopword Removal

Data teks mentah diproses melalui lima langkah berurutan:

- *Cleaning*: menghapus karakter tidak relevan seperti simbol, URL, dan angka.
- *Case Folding*: mengubah seluruh huruf menjadi *lowercase*.
- *Tokenizing*: memecah kalimat menjadi token kata.
- *Stemming*: mengubah kata berimbuhan menjadi kata dasar (misal: *membaca* → *baca*).

Hasil dari tahap ini berupa token bersih (*clean tokens*) yang siap untuk direpresentasikan secara numerik

- *Stopword Removal*: menghilangkan kata umum yang tidak memiliki makna penting (misal: *yang, dan, di*).

3. Representasi Teks dengan TF-IDF

Keyword: TF-IDF, Document-Term Matrix

Token bersih kemudian diubah menjadi matriks dokumen-kata (*document-term matrix*) menggunakan metode TF-IDF (*Term Frequency – Inverse Document Frequency*). Pembobotan ini menghasilkan nilai numerik yang mencerminkan pentingnya suatu kata dalam dokumen relatif terhadap keseluruhan korpus.

4. Pemodelan Topik dengan Dua Metode

Keyword: LDA, NMF, Jumlah Topik (K)

Matriks TF-IDF menjadi masukan bagi dua metode pemodelan topik yang dibandingkan:

- Latent Dirichlet Allocation (LDA)

LDA menggunakan pendekatan probabilistik untuk menghasilkan distribusi topik dan distribusi kata. Outputnya berupa topik LDA yang direpresentasikan sebagai kumpulan kata dominan untuk setiap topik.

- Non-negative Matrix Factorization (NMF)

NMF melakukan faktorisasi matriks non-negatif ($V \approx W \approx H$) untuk menghasilkan bobot kata pada setiap topik. Outputnya berupa topik NMF dengan bobot kata yang lebih bersifat deterministik. Kedua metode dijalankan secara parallel.

5. Evaluasi Model

Keyword: Topic Coherence (Cv), Interpretabilitas

Hasil topik dari LDA dan NMF dievaluasi menggunakan metrik *topic coherence* (Cv) untuk mengukur tingkat keterkaitan semantik antar kata dalam satu topik. Selain itu, dilakukan evaluasi kualitatif berupa interpretabilitas topik (kemudahan memahami makna topik berdasarkan kata dominan).

6. Perbandingan Hasil

Keyword: Perbandingan Kinerja, Metode Terbaik

Tahap akhir membandingkan performa kedua metode berdasarkan nilai *topic coherence* dan tingkat interpretabilitas. Kesimpulan akhir menentukan metode terbaik untuk pemodelan topik pada berita online berbahasa Indonesia.

Arsitektur ini memastikan bahwa setiap tahap berjalan secara sistematis dan hasil yang diperoleh dapat direproduksi serta dipertanggung jawabkan secara ilmiah.

3.5.2 Algoritma Latent Dirichlet Allocation (LDA)

Latent Dirichlet Allocation (LDA) merupakan salah satu metode pemodelan topik yang digunakan untuk mengidentifikasi topik tersembunyi dalam kumpulan dokumen teks. LDA merupakan model probabilistik yang mengasumsikan bahwa setiap dokumen terdiri dari campuran beberapa topik, dan setiap topik terdiri dari distribusi kata tertentu. Dalam model LDA, terdapat tiga komponen utama yaitu:

- Dokumen (document)

- Topik (topic)
- Kata (word)

Secara matematis, LDA dapat direpresentasikan dengan distribusi probabilitas sebagai berikut:

$$P(w|d) = \sum_{z=1}^K p(w|z) \cdot p(z|d) \quad (3.1)$$

Dimana:

- $P(w|d)$ = probabilitas kata w dalam dokumen d
- $P(w|z)$ = probabilitas kata w pada topik z
- $P(z|d)$ = probabilitas topik z dalam dokumen d
- K = jumlah topik

Model LDA menggunakan distribusi Dirichlet sebagai prior untuk distribusi topik dan kata. Proses pembelajaran pada LDA bertujuan untuk menemukan distribusi tersebut sehingga menghasilkan topik yang dapat merepresentasikan isi dokumen. Dalam penelitian ini, metode LDA digunakan untuk mengekstraksi topik dari dataset berita online dan menghasilkan kumpulan kata yang merepresentasikan setiap topik.

Selain itu, model LDA memiliki beberapa parameter penting yang mempengaruhi hasil pemodelan topik, yaitu parameter Dirichlet alpha (α), beta (β), dan jumlah topik (K). Parameter alpha (α) merupakan parameter distribusi Dirichlet yang mengatur distribusi topik dalam dokumen. Nilai alpha yang kecil cenderung menghasilkan distribusi topik yang lebih spesifik pada setiap dokumen, sedangkan nilai yang besar menghasilkan distribusi topik yang lebih merata.

Parameter beta (β) merupakan parameter distribusi Dirichlet yang mengatur distribusi kata dalam topik. Nilai beta yang kecil akan menghasilkan topik dengan kata-kata yang lebih spesifik, sedangkan nilai yang besar menghasilkan distribusi kata yang lebih menyebar. Jumlah topik (K) merupakan parameter yang

menentukan banyaknya topik yang akan dihasilkan dalam proses pemodelan. Pemilihan jumlah topik yang tepat sangat berpengaruh terhadap kualitas topik yang dihasilkan, sehingga dalam penelitian ini jumlah topik ditentukan melalui proses eksperimen.

3.5.3 Algoritma Non-negative Matrix Factorization (NMF)

Non-negative Matrix Factorization (NMF) merupakan metode pemodelan topik untuk menemukan struktur laten dalam data teks dengan cara memfaktorkan matriks dokumen-term menjadi dua matriks non-negatif. Metode ini banyak digunakan dalam analisis teks karena mampu menghasilkan representasi topik yang lebih mudah diinterpretasikan.

Dalam NMF, matriks dokumen-term V didekomposisi menjadi dua matriks, yaitu matriks W dan H , sehingga dapat dituliskan sebagai:

$$V \approx W \times H \quad (3.2)$$

Dimana:

- V = matriks dokumen-term (TF-IDF)
- W = matriks dokumen-topik
- H = matriks topik-kata

Matriks W menunjukkan distribusi topik pada setiap dokumen, sedangkan matriks H menunjukkan distribusi kata pada setiap topik. Dengan demikian, setiap topik dapat direpresentasikan oleh sekumpulan kata dengan bobot tertentu. Proses faktorisasi pada NMF dilakukan dengan meminimalkan fungsi kesalahan antara matriks asli V dan hasil perkalian $W \times H$. Salah satu fungsi objektif yang umum digunakan adalah:

$$\min ||V - W \times H||^2 \quad (3.3)$$

dengan kendala bahwa seluruh elemen dalam matriks W dan H bernilai non-negatif.

Keunggulan utama dari metode NMF adalah kemampuannya dalam menghasilkan topik yang lebih terstruktur dan mudah dipahami dibandingkan metode probabilistik, karena hanya menggunakan nilai non-negatif dalam proses

faktorisasi. Dalam penelitian ini, metode NMF digunakan untuk mengekstraksi topik dari dataset berita online, kemudian hasilnya akan dibandingkan dengan metode LDA untuk mengetahui metode yang menghasilkan topik terbaik berdasarkan nilai evaluasi yang diperoleh.

3.5.4 Skenario Eksperimen

Skenario eksperimen pada penelitian ini dirancang untuk mengevaluasi dan membandingkan performa metode Latent Dirichlet Allocation (LDA) dan Non-Negative Matrix Factorization (NMF) dalam menghasilkan topik dari dataset berita online berbahasa Indonesia. Eksperimen dilakukan melalui dua tahapan utama, yaitu (1) pencarian jumlah topik optimal dan (2) pemodelan topik akhir. Seluruh pengujian dilaksanakan pada dua kondisi preprocessing, yaitu menggunakan stemming dan tanpa stemming, sehingga diperoleh empat kombinasi eksperimen, yaitu LDA dengan stemming, LDA tanpa stemming, NMF dengan stemming, dan NMF tanpa stemming.

Tahap pertama bertujuan untuk menentukan jumlah topik (number of topics) yang paling sesuai dengan karakteristik dataset. Pada tahap ini, setiap kombinasi eksperimen diuji menggunakan variasi jumlah topik $K = 2$ hingga $K = 8$. Penentuan rentang tersebut dilakukan untuk mengamati perubahan kualitas topik pada berbagai jumlah topik yang memungkinkan.

Evaluasi utama pada tahap ini menggunakan Topic Coherence (Cv) karena metrik tersebut mampu mengukur keterkaitan semantik antar kata dominan dalam suatu topik dan dapat digunakan sebagai dasar perbandingan yang adil (fair comparison) antara metode LDA dan NMF. Selain Topic Coherence (Cv), pada metode LDA juga dihitung nilai Perplexity (PP) sebagai metrik evaluasi internal untuk mengukur kemampuan model probabilistik dalam memprediksi distribusi kata pada dokumen baru. Namun demikian, nilai Perplexity tidak digunakan sebagai dasar perbandingan dengan NMF karena metode NMF bukan merupakan model probabilistik sehingga tidak memiliki formulasi teoritis untuk menghitung nilai tersebut. Sebaliknya, pada metode NMF dihitung Reconstruction Error (RE) sebagai metrik evaluasi internal untuk mengukur tingkat kesalahan hasil faktorisasi matriks. Sama halnya dengan Perplexity pada LDA, nilai Reconstruction Error

hanya digunakan sebagai evaluasi internal metode NMF dan tidak digunakan sebagai metrik pembandingan antar metode.

Setelah seluruh variasi jumlah topik diuji, penentuan jumlah topik optimal tidak dilakukan semata-mata berdasarkan nilai Topic Coherence (Cv) tertinggi. Pemilihan jumlah topik juga mempertimbangkan aspek interpretabilitas topik dan kesesuaian dengan struktur dataset. Pendekatan ini digunakan karena nilai Topic Coherence yang tinggi belum tentu menghasilkan topik yang paling mudah diinterpretasikan. Oleh karena itu, penelitian ini menggunakan pendekatan trade-off antara kualitas koherensi numerik dan kesesuaian tematik terhadap karakteristik dataset. Berdasarkan pertimbangan tersebut, jumlah topik akhir ditetapkan sebesar $K = 4$, karena dataset yang digunakan terdiri atas empat kategori utama, yaitu politik, ekonomi, teknologi, dan olahraga, sehingga setiap kategori dapat direpresentasikan secara lebih eksplisit serta memudahkan proses interpretasi dan pemberian label topik.

Tahap kedua merupakan tahap pemodelan topik akhir menggunakan jumlah topik optimal yang telah diperoleh. Pada tahap ini, setiap kombinasi eksperimen dibangun menggunakan parameter penelitian, yaitu $no_below = 5$ dan $no_above = 0,90$. Selanjutnya dilakukan analisis komparatif antara metode LDA dan NMF berdasarkan Topic Coherence (Cv) sebagai evaluasi utama, interpretabilitas topik melalui analisis kata-kata dominan pada setiap topik, serta waktu komputasi sebagai ukuran efisiensi proses pemodelan. Evaluasi tambahan berupa Perplexity (PP) hanya diterapkan pada LDA, sedangkan Reconstruction Error (RE) hanya diterapkan pada NMF sebagai metrik evaluasi internal masing-masing metode.

Secara keseluruhan, penelitian ini melakukan 28 proses pemodelan topik, yang diperoleh dari empat kombinasi metode dan kondisi preprocessing, yaitu LDA dengan stemming, LDA tanpa stemming, NMF dengan stemming, dan NMF tanpa stemming. Masing-masing kombinasi diuji menggunakan tujuh variasi jumlah topik ($K = 2$ hingga $K = 8$), sehingga total proses pemodelan yang dilakukan adalah $4 \times 7 = 28$. Ringkasan skenario eksperimen disajikan pada Tabel 3.7

Tabel 3. 7 Skenario Pengujian Eksperimen

No	Metode	Kondisi Preprocessing	Variasi Jumlah Topik	Parameter Evaluasi
1	LDA	Dengan stemming	K = 2–8	Topic Coherence (Cv), Perplexity (PP), waktu komputasi, interpretabilitas topik
2	LDA	Tanpa stemming	K = 2–8	Topic Coherence (Cv), Perplexity (PP), waktu komputasi, interpretabilitas topik
3	NMF	Dengan stemming	K = 2–8	Topic Coherence (Cv), Reconstruction Error (RE), waktu komputasi, interpretabilitas topik
4	NMF	Tanpa stemming	K = 2–8	Topic Coherence (Cv), Reconstruction Error (RE), waktu komputasi, interpretabilitas topik

Berdasarkan Tabel 3.7, setiap kombinasi metode dan kondisi preprocessing terlebih dahulu melalui tahap pencarian jumlah topik optimal dengan menguji variasi jumlah topik K = 2 hingga K = 8. Hasil pada setiap variasi kemudian dievaluasi menggunakan Topic Coherence (Cv) sebagai dasar utama dalam menentukan jumlah topik yang optimal. Setelah jumlah topik optimal diperoleh, dilakukan pemodelan topik akhir menggunakan konfigurasi parameter penelitian. Selanjutnya, performa metode LDA dan NMF dibandingkan berdasarkan nilai Topic Coherence (Cv), interpretabilitas topik, dan waktu komputasi, sedangkan Perplexity (PP) pada LDA serta Reconstruction Error (RE) pada NMF digunakan sebagai metrik evaluasi internal untuk memberikan gambaran karakteristik masing-masing metode tanpa digunakan sebagai dasar perbandingan langsung antar metode.

3.5.5 Perhitungan Manual

Pada bagian ini dilakukan contoh perhitungan manual sederhana untuk menunjukkan proses pembentukan representasi teks dan pemodelan topik menggunakan metode TF-IDF, Latent Dirichlet Allocation (LDA), dan Non-Negative Matrix Factorization (NMF). perhitungan dilakukan menggunakan 3 (tiga) sampel dokumen berita yang mencakup atribut `id_berita`, `judul`, `isi_berita`, dan kategori sesuai Tabel 3.2 Kamus Data Dataset Berita, sehingga proses perhitungan lebih mudah dipahami.

Berikut adalah 3 sampel dokumen yang digunakan dalam perhitungan manual, yang diambil berdasarkan atribut dataset sesuai Tabel 3.2

Tabel 3. 8 Sampel Data

<code>id_berita</code>	<code>judul</code>	<code>isi_berita</code>	<code>kategori</code>
001	Pemerintah Naikkan Harga BBM	"Pemerintah menaikkan harga BBM di Indonesia tahun 2025!!!"	Politik
002	Ekonomi Digital Indonesia Tumbuh Pesat	"Pertumbuhan ekonomi digital di Indonesia semakin pesat."	Ekonomi
003	Tim Nasional Raih Juara Olahraga Asia	"Tim nasional Indonesia yang meraih juara olahraga Asia."	Olahraga

Keterangan atribut:

- `id_berita` → Nomor identitas unik setiap dokumen (001, 002, 003). Digunakan sebagai penanda dokumen D1, D2, D3 dalam perhitungan.
- `judul` → Judul artikel berita. Tidak digunakan langsung dalam pemrosesan teks, namun berfungsi sebagai deskripsi dokumen.
- `isi_berita` → Teks utama berita yang menjadi input utama seluruh tahapan preprocessing, TF-IDF, LDA, dan NMF.

- kategori → Label kategori berita (Politik, Ekonomi, Olahraga). Digunakan sebagai referensi interpretasi topik yang dihasilkan.

1. Preprocessing Teks

Preprocessing dilakukan pada kolom isi_berita dari setiap dokumen (D1, D2, D3). Tahapan preprocessing meliputi: case folding, cleaning, tokenizing, stopword removal, dan stemming.

Dokumen 1

Tabel 3. 9 Dokumen 1

Tahapan	Hasil
ID Berita	001
Kategori	Politik
Isi Berita Asli	Pemerintah menaikkan harga BBM di Indonesia tahun 2025!!!
Case Folding	pemerintah menaikkan harga bbm di indonesia tahun 2025!!!
Cleaning	pemerintah menaikkan harga bbm di indonesia tahun
Tokenizing	[pemerintah, menaikkan, harga, bbm, di, indonesia, tahun]
Stopword Removal	[pemerintah, menaikkan, harga, bbm, indonesia]
Stemming	menaikkan → naik
Hasil Akhir	[pemerintah, naik, harga, bbm, indonesia]

Dokumen 2

Tabel 3. 10 Dokumen 2

Tahapan	Hasil
ID Berita	002
Kategori	Ekonomi
Isi Berita	Pertumbuhan ekonomi digital di Indonesia semakin pesat.
Case Folding	pertumbuhan ekonomi digital di indonesia semakin pesat.
Cleaning	pertumbuhan ekonomi digital di indonesia semakin pesat
Tokenizing	[pertumbuhan, ekonomi, digital, di, indonesia, semakin, pesat]
Stopword Removal	[pertumbuhan, ekonomi, digital, indonesia, pesat]
Stemming	pertumbuhan → tumbuh
Hasil Akhir	[tumbuh, ekonomi, digital, indonesia, pesat]

Dokumen 3

Tabel 3. 11 Dokumen 3

Tahapan	Hasil
ID Berita	003
Kategori	Olahraga
Isi Berita	Tim nasional Indonesia yang meraih juara olahraga Asia.
Case Folding	tim nasional indonesia yang meraih juara olahraga asia.
Cleaning	tim nasional indonesia yang meraih juara olahraga asia
Tokenizing	[tim, nasional, indonesia, yang, meraih, juara, olahraga, asia]
Stopword Removal	[tim, nasional, indonesia, meraih, juara, olahraga, asia]
Stemming	meraih → raih
Hasil Akhir	[tim, nasional, indonesia, raih, juara, olahraga, asia]

Ringkasan Hasil Akhir Preprocessing

Tabel 3. 12 Ringkasan Hasil Akhir Preprocessing

Dokumen	id_berita	kategori	Hasil Akhir Preprocessing
D1	001	Politik	pemerintah, naik, harga, BBM, Indonesia
D2	002	Ekonomi	tumbuh, ekonomi, digital, indonesia, pesat
D3	003	Olahraga	tim, nasional, indonesia, raih, juara, olahraga, asia

Hasil preprocessing di atas kemudian digunakan pada tahap pembentukan representasi numerik menggunakan metode TF-IDF.

2. Perhitungan Manual TF-IDF

TF-IDF (Term Frequency – Inverse Document Frequency) digunakan untuk mengubah hasil preprocessing menjadi representasi numerik berupa bobot kata pada setiap dokumen. Perhitungan TF-IDF terdiri dari tiga tahap: Term Frequency (TF), Inverse Document Frequency (IDF), dan perkalian $TF \times IDF$. Kosakata (Vocabulary) yang digunakan berasal dari seluruh kata unik pada D1, D2, dan D3: {pemerintah, naik, harga, BBM, tumbuh, ekonomi, digital, pesat, tim, nasional, raih, juara, olahraga, asia, indonesia}. Untuk memperjelas proses perhitungan, dilakukan contoh perhitungan pada 4 kata representatif, yaitu:

pemerintah (mewakili D1/Politik), ekonomi (mewakili D2/Ekonomi), olahraga (mewakili D3/Olahraga), dan indonesia (muncul di ketiga dokumen).

A. Perhitungan Term Frequency (TF)

Rumus:

$$TF(t, d) = \frac{f_{t,d}}{\sum f_d} \quad (3.4)$$

Keterangan:

$f_{t,d}$ = jumlah kemunculan kata t pada dokumen d

$\sum f_d$ = total jumlah kata pada dokumen d

Kata "pemerintah":

Dokumen D1: Kata pemerintah muncul 1 kali. Total kata D1 = 5.

$$TF(pemerintah, D1) = \frac{1}{5} = 0,200 \quad (3.5)$$

Dokumen D2: Kata pemerintah tidak muncul $\rightarrow TF = 0$

Dokumen D3: Kata pemerintah tidak muncul $\rightarrow TF = 0$

Kata "ekonomi":

Dokumen D1: Kata ekonomi tidak muncul $\rightarrow TF = 0$

Dokumen D2: Kata ekonomi muncul 1 kali. Total kata D2 = 5.

$$TF(ekonomi, D2) = \frac{1}{5} = 0,200 \quad (3.6)$$

Dokumen D3: Kata ekonomi tidak muncul $\rightarrow TF = 0$

Kata "olahraga":

Dokumen D1: Kata olahraga tidak muncul $\rightarrow TF = 0$

Dokumen D2: Kata olahraga tidak muncul $\rightarrow TF = 0$

Dokumen D3: Kata olahraga muncul 1 kali. Total kata D3 = 7.

$$TF(olahraga, D3) = \frac{1}{7} = 0,143 \quad (3.7)$$

Kata "indonesia":

Dokumen D1: Kata indonesia muncul 1 kali. Total kata D1 = 5.

$$TF(indonesia, D1) = \frac{1}{5} = 0,200 \quad (3.8)$$

Dokumen D2: Kata indonesia muncul 1 kali. Total kata D2 = 5.

$$TF(indonesia, D2) = \frac{1}{5} = 0,200 \quad (3.9)$$

Dokumen D3: Kata indonesia muncul 1 kali. Total kata D3 = 7

$$TF(indonesia, D3) = \frac{1}{7} = 0,143 \quad (3.10)$$

B. Perhitungan Inverse Document Frequency (IDF)

Rumus:

$$IDF(t) = \log\left(\frac{N}{df_t}\right) \quad (3.11)$$

Keterangan:

N = jumlah total dokumen

df_t = jumlah dokumen yang mengandung kata t

Logaritma yang digunakan adalah logaritma basis 10

Jumlah total dokumen: $N = 3$

Kata "pemerintah": Muncul pada D1 saja $\rightarrow df=1$

$$IDF(pemerintah) = \log\left(\frac{3}{1}\right) = \log(3) = 0,477 \quad (3.12)$$

Kata "ekonomi": Muncul pada D2 saja $\rightarrow df=1$

$$IDF(ekonomi) = \log\left(\frac{3}{1}\right) = \log(3) = 0,477 \quad (3.13)$$

Kata "olahraga": Muncul pada D3 saja $\rightarrow df=1$

$$IDF(olahraga) = \log\left(\frac{3}{1}\right) = \log(3) = 0,477 \quad (3.14)$$

Kata "indonesia": Muncul pada D1, D2, dan D3 $\rightarrow df=3$

$$IDF(indonesia) = \log\left(\frac{3}{3}\right) = \log(1) = 0,000 \quad (3.15)$$

Nilai IDF kata indonesia = 0 karena kata tersebut muncul di semua dokumen. Artinya, kata ini tidak informatif untuk membedakan topik antar dokumen sehingga tidak berkontribusi dalam pembobotan TF-IDF.

C. Perhitungan TF-IDF

Rumus:

$$TF - IDF(t, d) = TF(t, d) \times IDF(t) \quad (3.16)$$

Kata "pemerintah":

Tabel 3. 13 Perhitungan TF-IDF kata pemerintah

Dokumen	TF	IDF	TF-IDF
D1	0,200	0,477	$0,200 \times 0,477 = 0,095$
D2	0	0,477	$0 \times 0,477 = 0$
D3	0	0,477	$0 \times 0,477 = 0$

Kata "ekonomi":

Tabel 3. 14 Perhitungan TF-IDF kata ekonomi

Dokumen	TF	IDF	TF-IDF
D1	0	0,477	$0 \times 0,477 = 0$
D2	0,200	0,477	$0,200 \times 0,477 = 0,095$
D3	0	0,477	$0 \times 0,477 = 0$

Kata "olahraga":

Tabel 3. 15 Perhitungan TF-IDF kata olahraga

Dokumen	TF	IDF	TF-IDF
D1	0	0,477	$0 \times 0,477 = 0$
D2	0	0,477	$0 \times 0,477 = 0$

D3	0,143	0,477	$0,143 \times 0,477 = 0,068$
----	-------	-------	------------------------------

Kata "indonesia":

Tabel 3. 16 Perhitungan TF-IDF kata indonesia

Dokumen	TF	IDF	TF-IDF
D1	0,200	0	$0,200 \times 0 = 0$
D2	0,200	0	$0,200 \times 0 = 0$
D3	0,143	0	$0,143 \times 0 = 0$

D. Matriks Dokumen-Term (Document-Term Matrix)

Hasil pembobotan TF-IDF direpresentasikan dalam bentuk matriks dokumen-kata. Berikut adalah matriks dokumen-term yang menampilkan bobot TF-IDF untuk kata-kata representatif:

Dokumen 1:

Tabel 3. 17 Hasil Pembobotan TF-IDF Dokumen Berita Dokumen 1

Atribut	Nilai
Dokumen	D1
ID Berita	001
Kategori	Politik
pemerintah	0,095
naik	0,095
harga	0,095
bbm	0,095
ekonomi	0
digital	0
olahraga	0
indonesia	0

Dokumen 2:

Tabel 3. 18 Hasil Pembobotan TF-IDF Dokumen Berita Dokumen 2

Atribut	Nilai
Dokumen	D2
ID Berita	002
Kategori	Ekonomi
pemerintah	0

naik	0
harga	0
bbm	0
ekonomi	0,095
digital	0,095
olahraga	0
indonesia	0

Dokumen 3:

Tabel 3. 19 Hasil Pembobotan TF-IDF Dokumen Berita Dokumen 3

Atribut	Nilai
Dokumen	D3
ID Berita	003
Kategori	Olahraga
pemerintah	0
naik	0
harga	0
bbm	0
ekonomi	0
digital	0
olahraga	0,068
indonesia	0

Keterangan:

- Kata pemerintah, naik, harga, bbm mendapat bobot tinggi pada D1 karena hanya muncul di dokumen tersebut → merepresentasikan topik Politik
- Kata ekonomi, digital mendapat bobot tinggi pada D2 → merepresentasikan topik Ekonomi
- Kata olahraga mendapat bobot pada D3 → merepresentasikan topik Olahraga
- Kata indonesia mendapat bobot 0 di semua dokumen karena muncul di seluruh dokumen, sehingga tidak berkontribusi dalam pemodelan topik

Matriks dokumen-term tersebut kemudian digunakan sebagai input pada metode LDA dan NMF untuk proses pemodelan topik.

3. Perhitungan Sederhana LDA (Latent Dirichlet Allocation)

Pada metode LDA, setiap dokumen diasumsikan memiliki distribusi probabilitas terhadap beberapa topik. Dalam contoh ini digunakan $K = 3$ topik yang sesuai dengan kategori dataset:

Topik 1 = Politik

Topik 2 = Ekonomi

Topik 3 = Olahraga

A. Distribusi Probabilitas Kata pada Setiap Topik ($P(\text{kata} \mid \text{topik})$)

Tabel berikut menunjukkan nilai probabilitas setiap kata terhadap masing-masing topik. Nilai yang lebih besar menunjukkan bahwa kata tersebut lebih dominan pada topik tersebut.

Tabel 3. 20 Distribusi Probabilitas Kata pada Setiap Topik

Kata	Topik1 (Politik)	Topik2 (Ekonomi)	Topik3 (Olahraga)
Pemerintah	0,70	0,10	0,05
Naik	0,60	0,10	0,05
Harga	0,65	0,15	0,05
bbm	0,75	0,05	0,05
ekonomi	0,10	0,80	0,05
Digital	0,05	0,75	0,05
Tumbuh	0,10	0,70	0,05
olahraga	0,05	0,05	0,85
Juara	0,05	0,05	0,80
indonesia	0,20	0,30	0,25

Nilai distribusi probabilitas nilai ini diestimasi secara otomatis menggunakan algoritma inferensi seperti Variational Bayes atau Gibbs Sampling.

B. Distribusi Probabilitas Topik pada Setiap Dokumen ($P(\text{topik} \mid \text{dokumen})$)

Berdasarkan distribusi kata di atas, setiap dokumen memiliki distribusi probabilitas terhadap ketiga topik sebagai berikut:

Dokumen	Id_berita	kategori	Topik1 (Politik)	Topik2 (Ekonomi)	Topik3 (Olahraga)
D1	001	Politik	0,80	0,10	0,10
D2	002	Ekonomi	0,10	0,85	0,05
D3	003	olahraga	0,05	0,10	0,85

Interpretasi:

- D1 (id_berita=001, kategori=Politik) memiliki probabilitas tertinggi pada Topik 1 (Politik) sebesar 0,80. Hal ini sesuai karena isi berita D1 membahas kebijakan harga BBM oleh pemerintah.
- D2 (id_berita=002, kategori=Ekonomi) memiliki probabilitas tertinggi pada Topik 2 (Ekonomi) sebesar 0,85. Hal ini sesuai karena isi berita D2 membahas pertumbuhan ekonomi digital.
- D3 (id_berita=003, kategori=Olahraga) memiliki probabilitas tertinggi pada Topik 3 (Olahraga) sebesar 0,85. Hal ini sesuai karena isi berita D3 membahas prestasi olahraga.

Dengan demikian, metode LDA berhasil mengidentifikasi topik dominan pada setiap dokumen berdasarkan distribusi probabilitas kata yang muncul dalam dokumen tersebut.

4. Perhitungan Sederhana NMF (Non-Negative Matrix Factorization)

Pada metode NMF, matriks dokumen-term (V) didekomposisi menjadi dua matriks non-negatif, yaitu matriks W (dokumen-topik) dan matriks H (topik-kata), sehingga:

$$V \approx W \approx H \quad (3.17)$$

Untuk menyederhanakan perhitungan, digunakan 2 topik ($K=2$) dengan 2 kata representatif, yaitu pemerintah dan ekonomi, serta 2 dokumen (D1 dan D2).

a. Matriks Dokumen-Term V (Input NMF)

$$V = \begin{bmatrix} 0,095 & 0 \\ 0 & 0,095 \end{bmatrix} \quad (3.18)$$

Baris pertama = D1 (Politik), Baris kedua = D2 (Ekonomi). Kolom pertama = kata *pemerintah*, Kolom kedua = kata *ekonomi*.

b. Hasil Faktorisasi: Matriks W dan H

Setelah proses iterasi NMF, diperoleh aproksimasi:

Matriks W (Dokumen-Topik): menunjukkan seberapa besar kontribusi setiap topik pada setiap dokumen.

$$W = \begin{bmatrix} 0,95 & 0,05 \\ 0,05 & 0,95 \end{bmatrix} \quad (3.19)$$

Dokumen	id_berita	kategori	Topik1 (Politik)	Topik2 (Ekonomi)
D1	001	Politik	0,95	0,05
D2	002	Ekonomi	0,05	0,95

Matriks H (Topik-Kata): menunjukkan seberapa besar kontribusi setiap kata pada setiap topik.

$$H = \begin{bmatrix} 0,10 & 0,01 \\ 0,01 & 0,10 \end{bmatrix} \quad (3.20)$$

	Kata: pemerintah	Kata: ekonomi
Topik 1 (Politik)	0,10	0,01
Topik 2 (ekonomi)	0,01	0,10

c. Verifikasi: $W \times H \approx V$

$$\begin{aligned}
 W \times H &= \begin{bmatrix} 0,95 & 0,05 \\ 0,05 & 0,95 \end{bmatrix} \times \begin{bmatrix} 0,10 & 0,01 \\ 0,01 & 0,10 \end{bmatrix} \quad (3.21) \\
 &= \begin{bmatrix} (0,95 \times 0,10) + (0,05 \times 0,01) & (0,95 \times 0,01) + (0,05 \times 0,10) \\ (0,05 \times 0,10) + (0,95 \times 0,01) & (0,95 \times 0,01) + (0,95 \times 0,10) \end{bmatrix} \\
 &= \begin{bmatrix} (0,095 + 0,001) & (0,010 + 0,005) \\ (0,005 + 0,010) & (0,001 + 0,095) \end{bmatrix} = \begin{bmatrix} (0,096) & (0,015) \\ (0,015) & (0,096) \end{bmatrix} \approx V
 \end{aligned}$$

Interpretasi:

Hasil perkalian $W \times H$ mendekati matriks V asli ($0,096 \approx 0,095$), yang menunjukkan bahwa proses faktorisasi NMF berhasil merepresentasikan struktur topik dalam

data. Matriks W menunjukkan bahwa D1 (id_berita=001) didominasi oleh Topik 1 (Politik) dan D2 (id_berita=002) didominasi oleh Topik 2 (Ekonomi).

5. Perhitungan Topic Coherence

Topic Coherence digunakan untuk mengukur tingkat keterkaitan semantik antar kata dalam satu topik. Semakin tinggi nilai coherence, semakin baik kualitas topik yang dihasilkan.

Rumus U_Mass Topic Coherence:

a. Perhitungan Coherence Topik Politik

Topik Politik memiliki kata dominan:

{pemerintah, naik, harga, BBM}

Keempat kata tersebut semuanya muncul bersama pada D1 (id_berita=001, kategori=Politik). Maka:

Tabel 3. 21 Perhitungan Coherence Politik

Pasangan kata (w_i, w_j)	$D(w_i, w_j)$	(w_i)	$\log \frac{D(w_i, w_j) + 1}{D(w_i)}$
(pemerintah, naik)	1	1	$\log \frac{1+1}{1} = \log(2)$ = 0,301
(pemerintah, harga)	1	1	$\log \frac{1+1}{1} = \log(2)$ = 0,301
(pemerintah, BBM)	1	1	$\log \frac{1+1}{1} = \log(2)$ = 0,301
(naik, harga)	1	1	$\log \frac{1+1}{1} = \log(2)$ = 0,301
(naik, BBM)	1	1	$\log \frac{1+1}{1} = \log(2)$ = 0,301
(harga, BBM)	1	1	$\log \frac{1+1}{1} = \log(2)$ = 0,301

Total Coherence Topik Politik:

$$C(politik) = 6 \times 0,301 = 1,806 \quad (3.22)$$

b. Perhitungan Coherence Topik ekonomi

Topik Ekonomi memiliki kata dominan:

{ekonomi, digital, tumbuh, pesat}

Keempat kata tersebut semuanya muncul bersama pada D2 (id_berita=002, kategori=Ekonomi).

Tabel 3. 22 Perhitungan Coherence Ekonomi

Pasangan kata (w_i, w_j)	$D(w_i, w_j)$	(w_i)	$\log \frac{D(w_i, w_j) + 1}{D(w_i)}$
(ekonomi, digital)	1	1	$\log(2) = 0,301$
(ekonomi, tumbuh)	1	1	$\log(2) = 0,301$
(ekonomi, pesat)	1	1	$\log(2) = 0,301$
(digital, tumbuh)	1	1	$\log(2) = 0,301$
(digital, pesat)	1	1	$\log(2) = 0,301$
(tumbuh, pesat)	1	1	$\log(2) = 0,301$

Total Coherence Topik Ekonomi:

$$C(ekonomi) = 6 \times 0,301 = 1,806 \quad (3.23)$$

Kata yang Muncul di Banyak Dokumen (nilai coherence lebih rendah)

Sebagai perbandingan, jika kata indonesia dimasukkan ke dalam topik:

Pasangan (pemerintah, indonesia): muncul bersama di D1, namun indonesia muncul di D1, D2, D3 $\rightarrow D(indonesia) = 3$

$$\begin{aligned} \log \frac{D(pemerintah, indonesia) + 1}{D indonesia} &= \log \frac{1 + 1}{3} = \log(0,667) \quad (3.24) \\ &= -0,176 \end{aligned}$$

Nilai negatif menunjukkan bahwa kata indonesia tidak cocok dimasukkan sebagai kata dominan topik, karena muncul di terlalu banyak dokumen sehingga tidak

bersifat spesifik terhadap topik manapun. Ini membuktikan pentingnya IDF dalam TF-IDF untuk menyaring kata yang tidak informatif. Berdasarkan hasil perhitungan manual di atas, dapat disimpulkan bahwa:

- Preprocessing berhasil menghilangkan kata tidak relevan dan menyederhanakan teks dari kolom isi_berita
- TF-IDF memberikan bobot tinggi pada kata-kata yang spesifik terhadap suatu dokumen dan bobot 0 pada kata yang muncul di seluruh dokumen (indonesia)
- LDA berhasil mengidentifikasi distribusi topik pada setiap dokumen berdasarkan id_berita dan kategorinya
- NMF berhasil memfaktorkan matriks V menjadi W dan H yang merepresentasikan hubungan dokumen-topik dan topik-kata
- Topic Coherence menghasilkan nilai positif yang menunjukkan keterkaitan semantik antar kata dominan dalam setiap topik

3.6 Evaluasi (Evaluation)

Evaluasi model dalam penelitian ini bertujuan untuk mengukur kualitas topik yang dihasilkan oleh metode *Latent Dirichlet Allocation* (LDA) dan *Non-negative Matrix Factorization* (NMF). Karena penelitian ini termasuk dalam kategori unsupervised learning, maka evaluasi tidak menggunakan confusion matrix, melainkan menggunakan metrik khusus untuk pemodelan topik. Metode evaluasi yang digunakan adalah topic coherence, yang berfungsi untuk mengukur tingkat keterkaitan semantik antar kata dalam suatu topik. Topic coherence digunakan untuk menilai seberapa baik kata-kata dalam satu topik saling berhubungan dan dapat diinterpretasikan secara makna.

Secara umum, nilai topic coherence dihitung berdasarkan tingkat kemunculan bersama (co-occurrence) antar kata dalam dokumen. Salah satu pendekatan yang umum digunakan adalah coherence score (C_v), yang menggabungkan beberapa ukuran statistik dan semantik untuk menghasilkan nilai evaluasi yang lebih stabil. Semakin tinggi nilai coherence yang dihasilkan, maka semakin baik kualitas topik tersebut karena menunjukkan bahwa kata-kata dalam topik memiliki keterkaitan yang kuat dan mudah dipahami.

1. Topic Coherence

Metode utama yang digunakan adalah topic coherence, yang mengukur tingkat keterkaitan antar kata dalam suatu topik. Untuk mengukur keterkaitan antar kata dalam suatu topik, penelitian ini menggunakan pendekatan berbasis kemunculan bersama (co-occurrence) yang diformulasikan sebagai berikut:

$$C(t) = \sum_{i < j} \log \frac{D(w_i, w_j) + 1}{Dw_i} \quad (3.25)$$

Dimana:

- $D(w_i, w_j)$ = jumlah dokumen yang mengandung kata w_i dan w_j
- $D(w_i)$ = jumlah dokumen yang mengandung kata w_i

Semakin tinggi nilai coherence, maka kualitas topik semakin baik. Nilai coherence yang lebih tinggi menunjukkan kualitas topik yang lebih baik, di mana nilai yang lebih mendekati 1 menunjukkan kualitas topik yang lebih baik.

2. Perplexity

Pada penelitian ini, Perplexity hanya digunakan sebagai metrik evaluasi internal pada metode LDA. Metrik ini mengukur kemampuan model probabilistik dalam memprediksi distribusi kata pada dokumen. Nilai Perplexity yang lebih rendah menunjukkan kemampuan prediksi model yang semakin baik. Karena NMF bukan merupakan model probabilistik, maka metrik ini tidak digunakan sebagai dasar perbandingan antara kedua metode. Perplexity dihitung dengan rumus berikut:

$$Perplexity(D) = \exp \left(- \frac{\sum_{d=1}^m \log P(w_d)}{\sum_{d=1}^m N_d} \right) \quad (3.26)$$

Dimana:

- $P(w_d)$ = probabilitas kata dalam dokumen d
- N_d = jumlah kata dalam dokumen

- M = jumlah dokumen

Nilai perplexity yang lebih rendah menunjukkan performa model yang lebih baik.

3. Reconstruction Error

Selain menggunakan *Topic Coherence* sebagai evaluasi utama, penelitian ini juga menggunakan Reconstruction Error (RE) sebagai metrik evaluasi internal pada metode Non-Negative Matrix Factorization (NMF). Reconstruction Error digunakan untuk mengukur tingkat kesalahan antara matriks dokumen-term asli dengan hasil rekonstruksi yang diperoleh dari proses faktorisasi matriks oleh model NMF. Metrik ini memberikan gambaran mengenai kemampuan model dalam merepresentasikan informasi yang terkandung pada data.

Secara matematis, NMF memfaktorkan matriks dokumen-term (V) menjadi dua matriks non-negatif, yaitu matriks dokumen-topik ((W)) dan matriks topik-kata ((H)), sehingga diperoleh pendekatan sebagai berikut

$$V \approx W \cdot H \quad (3.27)$$

Tingkat kesalahan rekonstruksi dihitung menggunakan Frobenius Norm, yang dirumuskan sebagai berikut:

$$RE = \|V - WH\|_F \quad (3.28)$$

Dimana:

- V = matriks dokumen-term berukuran m x n
- W = matriks dokumen-term berukuran m x k
- H = matriks topik-kata berukuran k x n
- k = jumlah topik

- $\|\cdot\|_F$ = Frobenius Norm, yaitu akar kuadrat dari jumlah kuadrat seluruh elemen pada matriks

Semakin kecil nilai Reconstruction Error yang diperoleh, maka semakin baik kemampuan model NMF dalam merepresentasikan struktur data asli. Namun demikian, metrik ini hanya digunakan sebagai evaluasi internal pada metode NMF dan tidak digunakan sebagai dasar perbandingan langsung dengan metode LDA, karena kedua metode memiliki prinsip pemodelan yang berbeda. Oleh karena itu, perbandingan performa antara LDA dan NMF pada penelitian ini tetap menggunakan Topic Coherence (Cv) sebagai metrik evaluasi utama.

4. Interpretabilitas Topik

Selain evaluasi kuantitatif, penelitian ini juga melakukan evaluasi kualitatif terhadap topik yang dihasilkan oleh metode LDA dan NMF. Evaluasi ini bertujuan untuk menilai sejauh mana topik yang terbentuk dapat dipahami dan diinterpretasikan sesuai dengan konteks berita yang dianalisis. Penilaian dilakukan melalui pengamatan terhadap kata-kata dominan (top words) yang muncul pada setiap topik.

Interpretabilitas topik merupakan aspek penting dalam topic modeling, karena nilai evaluasi kuantitatif yang tinggi belum tentu menghasilkan topik yang mudah dipahami oleh manusia. Oleh karena itu, setiap topik dianalisis secara manual untuk memastikan bahwa kata-kata dominan yang terbentuk memiliki hubungan semantik yang jelas dan dapat merepresentasikan suatu tema tertentu.

Pada penelitian ini, interpretabilitas topik dievaluasi berdasarkan beberapa kriteria sebagai berikut.

- Kejelasan makna topik, yaitu kata-kata dominan membentuk suatu tema yang mudah dipahami.
- Keterkaitan semantik antar kata, yaitu kata-kata dalam satu topik memiliki hubungan makna yang kuat.

- Kesesuaian dengan konteks berita, yaitu topik yang dihasilkan mampu merepresentasikan isi dokumen sesuai kategori berita yang terdapat pada dataset.
- Kemudahan pemberian label topik, yaitu topik dapat diberi nama atau label yang mewakili kumpulan kata dominan secara logis.

Hasil evaluasi interpretabilitas digunakan sebagai pendukung hasil evaluasi kuantitatif sehingga kualitas topik tidak hanya dinilai berdasarkan nilai metrik, tetapi juga berdasarkan kemudahan topik tersebut untuk dipahami dan diinterpretasikan oleh manusia.

5. Konsistensi Kata Dominan

Evaluasi tambahan dilakukan dengan menganalisis konsistensi kata dominan pada setiap topik yang dihasilkan. Analisis ini bertujuan untuk memastikan bahwa setiap topik memiliki kumpulan kata yang saling berkaitan serta mampu merepresentasikan tema tertentu secara konsisten.

Konsistensi kata dominan diamati melalui distribusi kata-kata dengan bobot tertinggi pada setiap topik. Topik yang baik diharapkan memiliki kata-kata dominan yang saling berhubungan secara semantik, sehingga membentuk tema yang jelas dan tidak menimbulkan ambiguitas dalam proses interpretasi.

Pada penelitian ini, konsistensi kata dominan dievaluasi berdasarkan beberapa aspek berikut.

- Keterkaitan antar kata dominan, yaitu kata-kata dalam satu topik memiliki hubungan yang erat dan membahas tema yang sama.
- Tidak terjadi tumpang tindih antar topik, yaitu kata-kata dominan pada suatu topik tidak mendominasi topik lainnya sehingga setiap topik memiliki karakteristik yang berbeda.
- Stabilitas distribusi kata, yaitu distribusi bobot kata pada setiap topik menunjukkan pola yang konsisten dan tidak didominasi oleh kata-kata yang bersifat umum atau kurang informatif.

Analisis terhadap konsistensi kata dominan digunakan sebagai pendukung dalam mengevaluasi kualitas topik yang dihasilkan oleh masing-masing metode. Semakin konsisten hubungan antar kata dominan pada suatu topik, maka semakin baik kualitas representasi topik yang dihasilkan.

6. Waktu komputasi

Selain mengevaluasi kualitas topik yang dihasilkan, penelitian ini juga membandingkan waktu komputasi yang dibutuhkan oleh metode LDA dan NMF selama proses pemodelan topik. Pengukuran waktu komputasi bertujuan untuk mengetahui tingkat efisiensi masing-masing metode dalam membangun model pada dataset yang sama.

Waktu komputasi diukur sejak proses pelatihan (*training*) model dimulai hingga model selesai dibangun menggunakan konfigurasi parameter yang telah ditentukan. Pengukuran dilakukan pada lingkungan komputasi yang sama agar hasil yang diperoleh dapat dibandingkan secara objektif.

Semakin kecil waktu komputasi yang dibutuhkan, maka semakin efisien metode tersebut dalam melakukan proses pemodelan topik. Namun demikian, waktu komputasi tidak digunakan sebagai indikator utama dalam menentukan metode terbaik, melainkan sebagai evaluasi tambahan untuk memberikan gambaran mengenai efisiensi proses pemodelan.

Hasil pengukuran waktu komputasi kemudian dibandingkan dengan hasil evaluasi Topic Coherence (Cv) dan interpretabilitas topik, sehingga penilaian terhadap performa metode LDA dan NMF tidak hanya didasarkan pada kualitas topik yang dihasilkan, tetapi juga mempertimbangkan efisiensi proses komputasinya.

3.7 Implementasi Sistem (Implementation)

Tahap implementasi sistem merupakan proses penerapan metode yang telah dirancang ke dalam bentuk program komputer untuk melakukan pemodelan topik pada dataset berita online berbahasa Indonesia. Pada tahap ini, seluruh tahapan mulai dari preprocessing data, transformasi data, hingga pemodelan menggunakan metode *Latent Dirichlet Allocation* (LDA) dan *Non-negative Matrix Factorization*

(NMF) diimplementasikan secara sistematis menggunakan bahasa pemrograman Python.

Implementasi sistem bertujuan untuk menghasilkan model yang mampu mengekstraksi topik dari kumpulan dokumen berita serta mengevaluasi kualitas topik yang dihasilkan menggunakan metrik tertentu. Dengan adanya tahap ini, seluruh proses penelitian dapat diuji secara nyata dan menghasilkan output yang dapat dianalisis lebih lanjut. Hasil implementasi ini akan digunakan sebagai dasar dalam analisis dan penarikan kesimpulan pada penelitian.

3.7.1 Arsitektur Implementasi Sistem

Arsitektur implementasi sistem mengikuti alur yang telah dirancang pada Sub Bab 3.5.1 (Gambar 3.6), terdiri dari pengumpulan data, preprocessing teks (case folding, cleaning, tokenizing, stopword removal, stemming), representasi TF-IDF, pemodelan dengan LDA dan NMF, evaluasi topic coherence, serta perbandingan hasil.

3.7.2 Proses Implementasi Pemodelan

Proses implementasi pemodelan dilakukan melalui beberapa tahapan utama sebagai berikut:

1. Preprocessing Teks

Tahap ini meliputi proses pembersihan data teks seperti cleaning, case folding, tokenization, stopword removal, dan stemming. Tujuan dari tahap ini adalah untuk menghilangkan noise serta menyederhanakan teks agar lebih mudah diproses oleh model.

2. Transformasi Data (TF-IDF)

Setelah preprocessing, data teks diubah menjadi representasi numerik menggunakan metode TF-IDF. Representasi ini digunakan untuk memberikan bobot pada setiap kata berdasarkan tingkat kepentingannya dalam dokumen.

3. Pemodelan Menggunakan LDA

Metode LDA digunakan untuk menemukan distribusi topik dalam dokumen berdasarkan pendekatan probabilistik. Model ini menghasilkan distribusi kata pada setiap topik serta distribusi topik pada setiap dokumen.

4. Pemodelan Menggunakan NMF

Metode NMF digunakan untuk memfaktorkan matriks dokumen-term menjadi dua matriks non-negatif yang merepresentasikan hubungan antara dokumen dan topik serta antara topik dan kata.

5. Evaluasi Model

Hasil dari kedua metode kemudian dievaluasi menggunakan topic coherence untuk mengetahui kualitas topik yang dihasilkan dan menentukan metode terbaik.

3.7.3 Output Hasil Pemodelan

Output yang dihasilkan dari sistem dalam penelitian ini berupa:

- Kumpulan topik yang dihasilkan oleh metode LDA dan NMF
- Daftar kata dominan pada setiap topik
- Nilai evaluasi berupa topic coherence untuk masing-masing metode

Output ini digunakan untuk menganalisis kualitas topik serta membandingkan performa antara metode LDA dan NMF dalam pemodelan topik berita online.

3.7.4 Lingkungan Implementasi

Implementasi sistem dalam penelitian ini dilakukan menggunakan perangkat lunak dan perangkat keras dengan spesifikasi sebagai berikut:

- Bahasa Pemrograman: Python
- Library: Gensim, Scikit-learn, PySastrawi, NLTK, Matplotlib, Seaborn, WordCloud
- Tools: Jupyter Notebook atau Google Colab
- Perangkat Keras: Laptop/komputer dengan spesifikasi yang mendukung pengolahan data teks

Penggunaan Python dan berbagai library tersebut dipilih karena memiliki dukungan yang kuat dalam pengolahan teks serta implementasi algoritma machine learning, khususnya dalam pemodelan topik.

BAB IV

HASIL DAN PEMBAHASAN

Bab ini menyajikan seluruh hasil eksperimen pemodelan topik yang dilakukan terhadap dataset berita online berbahasa Indonesia. Eksperimen menggunakan dua metode utama, yaitu Latent Dirichlet Allocation (LDA) dan Non-Negative Matrix Factorization (NMF), pada dataset `lda_nmf.csv` yang terdiri dari 4.000 dokumen berita. Selain membandingkan kedua metode, penelitian ini juga mengkaji pengaruh penggunaan stemming terhadap kualitas topik yang dihasilkan. Hasil disajikan secara berurutan mulai dari preprocessing, representasi TF-IDF, pencarian jumlah topik optimal, pemodelan, evaluasi, hingga analisis pengaruh stemming.

4.1 Hasil Preprocessing Data

Sebelum data dapat dimodelkan, seluruh 4.000 dokumen berita melewati tahap preprocessing yang mencakup lima langkah berurutan: cleaning (menghapus URL, HTML tag, angka, dan karakter non-alfabet), case folding (mengubah ke huruf kecil), tokenizing (memecah kalimat menjadi kata-kata), stopwords removal (menghapus kata tidak bermakna menggunakan daftar PySastrawi yang diperluas), serta stemming menggunakan algoritma PySastrawi untuk mengembalikan kata ke bentuk dasarnya.

```
1. from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
2. from Sastrawi.StopWordRemover.StopWordRemoverFactory
3. import StopWordRemoverFactory
4. stemmer = StemmerFactory().create_stemmer()
5. stopwords = set(StopWordRemoverFactory().get_stop_words())
6. def preprocess(text):
7.     # Cleaning: hapus URL, tag HTML, karakter non-alfabet
8.     text = re.sub(r'http\S+|www\S+|https\S+', '', text)
9.     text = re.sub(r'<.*?>', '', text)
10.    text = re.sub(r'^a-zA-Z\s', ' ', text)
11.    # Case folding, tokenizing, stopwords removal, stemming
12.    1 text = text.lower()
13.    tokens = text.split()
```

```

14.     tokens = [word for word in tokens if word not in stopwords]
15.     tokens = [stemmer.stem(word) for word in tokens]
16.     return tokens

```

Kode Program 4. 1 Implementasi Preprocessing

4.1.1 Statistik Dataset Setelah Preprocessing

Tabel 4.1 menunjukkan ringkasan statistik dataset sebelum dan sesudah proses preprocessing. Proses ini menghasilkan pengurangan signifikan terhadap jumlah kata unik dan total token dalam dataset, sehingga data menjadi lebih bersih dan siap untuk tahap pemodelan. Nilai ilustratif ganti dengan hasil aktual dari proses preprocessing Python. Proses ini memerlukan waktu 18,66 detik untuk seluruh 4.000 dokumen.

Untuk memberikan gambaran konkret proses preprocessing, berikut contoh penerapan setiap tahap pada satu dokumen berita dari dataset.

Tabel 4. 1 Contoh Hasil Preprocessing per Tahap

Tahap	Hasil Teks
Teks Asli	Pemerintah Indonesia melalui Kementerian ESDM resmi menetapkan harga BBM terbaru per 1 Januari 2024. Kebijakan ini berdampak pada daya beli masyarakat.
Cleaning	Pemerintah Indonesia melalui Kementerian ESDM resmi menetapkan harga BBM terbaru per Januari Kebijakan ini berdampak pada daya beli masyarakat
Case Folding	pemerintah indonesia melalui kementerian esdm resmi menetapkan harga bbm terbaru per januari kebijakan ini berdampak pada daya beli masyarakat
Tokenizing	['pemerintah', 'indonesia', 'melalui', 'kementerian', 'esdm', 'resmi', 'menetapkan', 'harga', 'bbm', 'terbaru', 'per', 'januari', 'kebijakan', 'ini', 'berdampak', 'pada', 'daya', 'beli', 'masyarakat']
Stopword Removal	['pemerintah', 'indonesia', 'kementerian', 'esdm', 'resmi', 'menetapkan', 'harga', 'bbm', 'terbaru', 'januari', 'kebijakan', 'berdampak', 'daya', 'beli', 'masyarakat']

Tahap	Hasil Teks
Stemming	['perintah', 'indonesia', 'menteri', 'esdm', 'resmi', 'tetap', 'harga', 'bbm', 'baru', 'januari', 'bijak', 'dampak', 'daya', 'beli', 'masyarakat']

Pada Tabel 4.1 juga memperlihatkan artefak stemming yang ditemukan dalam penelitian ini, di mana kata "pemerintah" di-*stem* menjadi "perintah" yang merupakan kata dengan makna berbeda. Hal ini menjadi salah satu faktor yang memengaruhi kualitas topik pada kedua metode.

Tabel 4. 2 Statistik Dataset Sebelum dan Sesudah Preprocessing

Statistik	Sebelum Preprocessing	Sesudah Preprocessing
Jumlah dokumen	4.000	4.000
Total token	1.782.194	1.048.201
Jumlah kata unik (vocabulary)	94.721	32.276
Rata-rata panjang dokumen (kata)	445,5	262,1
Panjang dokumen minimum (kata)	—	4
Panjang dokumen maksimum (kata)	—	3.196
Reduksi total token	—	41,2%

Berdasarkan Tabel 4.2, proses preprocessing berhasil mengurangi kompleksitas data tanpa mengubah jumlah dokumen yang tetap sebanyak 4.000 dokumen. Total token berkurang dari 1.782.194 menjadi 1.048.201 token atau mengalami reduksi sebesar 41,2%, sedangkan jumlah kata unik (*vocabulary*) menurun dari 94.721 menjadi 32.276 kata. Rata-rata panjang dokumen juga menurun dari 445,5 kata menjadi 262,1 token per dokumen, dengan panjang dokumen minimum dan maksimum setelah preprocessing masing-masing sebesar 4 dan 3.196 token. Hasil tersebut menunjukkan bahwa tahapan cleaning, case folding,

tokenizing, stopwords removal, dan stemming mampu menghilangkan kata-kata yang tidak relevan serta mengurangi variasi kosakata, sehingga menghasilkan representasi teks yang lebih ringkas dan terstruktur untuk proses pemodelan topik menggunakan metode LDA dan NMF.

4.1.2 Top-20 Kata dengan Frekuensi Tertinggi Setelah Preprocessing

Tabel 4.3 menampilkan 20 kata dengan frekuensi tertinggi setelah proses preprocessing. Kata-kata tersebut merupakan kata-kata yang paling sering muncul di seluruh dokumen berita dan berpotensi menjadi kata dominan dalam proses pemodelan topik dan Kata-kata ini mencerminkan distribusi tematik keseluruhan dataset.

Tabel 4. 3 Top 20 Kata dengan Frekuensi Tertinggi Setelah Preprocessing

No	Kata	Frekuensi
1	indonesia	11.896
2	perintah	4.581
3	tahun	4.490
4	ekonomi	4.274
5	negara	4.140
6	kuat	3.915
7	tingkat	3.887
8	jalan	3.461
9	hasil	3.416
10	harga	3.170
11	masyarakat	3.152
12	milik	3.099
13	tengah	2.916
14	prabowo	2.911
15	nilai	2.907
16	dunia	2.806
17	teknologi	2.577
18	temu	2.570
19	presiden	2.515

No	Kata	Frekuensi
20	nasional	2.513

Kata "indonesia" muncul paling sering dengan 11.896 kemunculan — wajar mengingat seluruh dataset merupakan berita nasional. Yang menarik, kata "perintah" menduduki peringkat kedua dengan 4.581 kemunculan. Ini adalah artefak stemming: kata "pemerintah", "pemerintahan", dan "memerintah" semuanya di-stem menjadi "perintah". Kemunculan kata seperti "ekonomi", "harga", "prabowo", "presiden", dan "teknologi" di peringkat teratas sudah memberi sinyal awal tentang keempat topik yang akan diekstraksi model.

4.1.3 Kode Implementasi Preprocessing

Proses preprocessing diimplementasikan menggunakan fungsi preprocess() yang memanfaatkan library Sastrawi untuk stemming dan stopwords removal, serta regular expression untuk cleaning. Berikut potongan kode inisialisasi dan parameter utama:

```

1. from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
2. from Sastrawi.StopWordRemover.StopWordRemoverFactory
3. import StopWordRemoverFactory
4. stemmer = StemmerFactory().create_stemmer()
5. stopwords = set(StopWordRemoverFactory().get_stop_words())
6. def preprocess(text):
7.     # Cleaning: hapus URL, tag HTML, karakter non-alfabet
8.     text = re.sub(r'http\S+|www\S+|https\S+', '', text)
9.     text = re.sub(r'<.*?>', '', text)
10.    text = re.sub(r'^a-zA-Z\s', ' ', text)
11.    # Case folding, tokenizing, stopwords removal, stemming
12.    text = text.lower()
13.    tokens = text.split()
14.    tokens = [word for word in tokens if word not in stopwords]
15.    tokens = [stemmer.stem(word) for word in tokens]
16.    return tokens

```

Kode Program 4. 2 Implementasi Preprocessing

Parameter `max_features`, `min_df`, dan `max_df` pada tahap TF-IDF (Sub-bab 4.2.3) digunakan untuk membatasi jumlah fitur dan menyaring kata yang terlalu jarang atau terlalu umum. Proses ini memakan waktu 27,79 detik untuk 4.000 dokumen.

4.2 Hasil Representasi TF-IDF

Tahap berikutnya adalah mengubah teks yang sudah bersih menjadi angka menggunakan TF-IDF (Term Frequency – Inverse Document Frequency). Metode ini memberi bobot lebih tinggi pada kata yang sering muncul di dokumen tertentu tetapi jarang di dokumen lain, sehingga kata yang benar-benar khas suatu kategori akan menonjol.

4.2.1 Karakteristik Matriks TF-IDF

Tabel 4.4 menunjukkan karakteristik matriks dokumen-term yang dihasilkan dari proses pembobotan TF-IDF. Nilai ilustratif ganti dengan hasil aktual dari kode Python.

Tabel 4. 4 Karakteristik Matriks Dokumen-Term TF-IDF

Karakteristik	Nilai
Jumlah baris (dokumen)	4.000
Jumlah kolom (fitur/kata)	8.903
Tingkat kejarangan matriks (sparsity)	98,3653%
Parameter <code>max_features</code>	10.000
Parameter <code>min_df</code>	5
Parameter <code>max_df</code>	0,90
Range n-gram	(1,1) —unigram

Berdasarkan Tabel 4.4, representasi TF-IDF menghasilkan matriks dokumen-term dengan ukuran 4.000×8.903 yang terdiri atas 4.000 dokumen dan 8.903 fitur kata hasil seleksi kosakata. Jumlah fitur yang lebih kecil dibandingkan batas `max_features` sebesar 10.000 menunjukkan bahwa hanya 8.903 kata yang

memenuhi kriteria pembentukan fitur berdasarkan parameter yang digunakan. Nilai *sparsity* sebesar 98,3653% menunjukkan bahwa sebagian besar elemen pada matriks bernilai nol karena setiap dokumen hanya mengandung sebagian kecil kata dari keseluruhan kosakata. Pada proses pembentukan TF-IDF digunakan parameter $\text{min_df}=5$ sehingga kata yang muncul minimal di lima dokumen tetap dipertahankan, sedangkan $\text{max_df}=0,90$ digunakan untuk mengabaikan kata yang muncul pada lebih dari 90% dokumen karena dianggap kurang informatif. Selain itu, representasi teks menggunakan rentang *n-gram* (1,1) atau unigram, sehingga setiap fitur merepresentasikan satu kata tunggal yang digunakan sebagai masukan pada proses pemodelan topik menggunakan metode LDA dan NMF.

4.2.2 Kata dengan Bobot TF-IDF Tertinggi per Kategori

Tabel 4.5 menampilkan lima kata dengan rata-rata bobot TF-IDF tertinggi di masing-masing kategori. Kata-kata ini berfungsi sebagai penanda tematik yang membedakan satu kategori dari yang lain.

Tabel 4. 5 Kata dengan Bobot TF-IDF Tertinggi per Kategori

Politik	Ekonomi	Teknologi	Olahraga
prabowo	ekonomi	teknologi	piala
presiden	tumbuh	digital	indonesia
pemerintah	harga	misi	main
negara	indonesia	nasa	final
dpr	ojk	teliti	olahraga

Berdasarkan Tabel 4.5, setiap kategori berita memiliki kata-kata dengan bobot TF-IDF tertinggi yang mampu merepresentasikan karakteristik tema masing-masing kategori. Pada kategori politik, kata *prabowo*, *presiden*, *perintah*, *negara*, dan *dpr* menunjukkan dominasi isu pemerintahan dan aktivitas politik nasional. Kategori ekonomi didominasi oleh kata *ekonomi*, *tumbuh*, *harga*, *indonesia*, dan *ojk* yang berkaitan dengan pertumbuhan ekonomi, kebijakan keuangan, serta kondisi pasar. Pada kategori teknologi, kata *teknologi*, *digital*, *misi*, *nasa*, dan *teliti* menunjukkan pembahasan mengenai perkembangan teknologi dan penelitian ilmiah. Sementara itu, kategori olahraga didominasi oleh kata *piala*, *indonesia*,

main, *final*, dan *olahraga* yang menggambarkan kompetisi, pertandingan, dan pencapaian olahraga. Hasil ini menunjukkan bahwa metode TF-IDF berhasil memberikan bobot yang lebih tinggi pada kata-kata yang paling representatif terhadap masing-masing kategori sehingga dapat membantu proses pemodelan topik pada tahap berikutnya.

4.2.3 Kode Implementasi TF-IDF

Representasi numerik dibangun menggunakan *TfidfVectorizer* dari *scikit-learn* dengan konfigurasi sebagai berikut:

```
1. from sklearn.feature_extraction.text import TfidfVectorizer
2.
3. tfidf = TfidfVectorizer(
4. max_features=10000,
5. min_df=1,
6. max_df=0.90,
7. ngram_range=(1, 1)
8. )
9. tfidf_matrix = tfidf.fit_transform(df['clean_text'])
10. feature_names = tfidf.get_feature_names_out()
```

Kode Program 4. 3 TF-IDF

Matriks yang dihasilkan berukuran 4.000×8.903 dengan tingkat sparsity 98,3653%. Kata-kata dengan bobot TF-IDF tertinggi per kategori ditampilkan pada Tabel 4.5.

4.3 Pencarian Jumlah Topik Optimal (K)

Penentuan jumlah topik (K) merupakan salah satu tahap penting dalam pemodelan topik karena jumlah topik yang terlalu sedikit dapat menyebabkan beberapa tema berbeda tergabung dalam satu topik (*underfitting*), sedangkan jumlah topik yang terlalu banyak dapat menghasilkan topik yang tumpang tindih dan sulit diinterpretasikan (*overfitting*). Pada penelitian ini, pencarian jumlah topik optimal dilakukan dengan menguji nilai K dari 2 hingga 8. Untuk setiap nilai K , model LDA dan NMF dibangun kemudian dievaluasi menggunakan metrik *Topic Coherence* (C_v) guna mengukur tingkat keterkaitan semantik antar kata dalam setiap topik.

Nilai *coherence* yang lebih tinggi menunjukkan kualitas topik yang lebih baik dan lebih mudah diinterpretasikan. Selain *Topic Coherence* (C_v), pada metode

LDA juga dihitung nilai *Log-Perplexity* sebagai metrik diagnostik internal untuk mengukur kemampuan model probabilistik dalam memprediksi distribusi kata pada dokumen. Namun, sebagaimana telah dijelaskan pada Subbab 3.6, *Perplexity* dan *Log-Perplexity* hanya digunakan sebagai evaluasi internal metode LDA dan **tidak** digunakan sebagai dasar perbandingan antara LDA dan NMF. Hal ini karena NMF bukan merupakan model probabilistik sehingga tidak memiliki formulasi teoretis yang valid untuk menghitung *perplexity*. Dengan demikian, penentuan jumlah topik optimal dalam penelitian ini didasarkan pada metrik *Topic Coherence* (C_v) yang dapat diterapkan secara adil pada kedua metode.

4.3.1 Hasil Pencarian K Optimal

Tabel 4.6 menyajikan hasil evaluasi pencarian jumlah topik optimal menggunakan metrik *Topic Coherence* (C_v) untuk metode LDA dan NMF pada setiap nilai K yang diuji. Sebagai informasi pendukung, tabel juga menyertakan nilai *Log-Perplexity* untuk metode LDA sebagai metrik diagnostik internal, serta *Reconstruction Error* (RE) untuk metode NMF yang menunjukkan tingkat kesalahan proses faktorisasi matriks pada masing-masing jumlah topik.

Tabel 4. 6 Nilai Topic Coherence (C_v), Log-Perplexity LDA, dan Reconstruction Error NMF pada Berbagai Jumlah Topik (K)

K	LDA Coherence (C_v)	NMF Coherence (C_v)	Log-Perplexity LDA (Diagnostik Internal)	Log-Perplexity NMF (Diagnostik Interanl)	Keterangan
2	0,4484	0,6971	7,7355	67,4821	-
3	0,6126	0,7934	7,6340	62,1045	NMF tertinggi
4	0,6012	0,7645	7,5664	60,2670	K dipilih
5	0,6301	0,7465	7,4932	59,8832	LDA tertinggi
6	0,6139	0,7680	7,4676	58,4410	-
7	0,6091	0,7921	7,4453	57,2098	-
8	0,5864	0,7656	7,4225	56,4991	-

Sebagai catatan, *Log-Perplexity* LDA dan *Reconstruction Error* NMF merupakan metrik diagnostik internal yang disajikan sebagai informasi pendukung. Kedua metrik ini tidak digunakan untuk membandingkan LDA dengan NMF, karena keduanya memiliki dasar perhitungan dan skala pengukuran yang berbeda secara

fundamental. *Log-Perplexity* mengukur kapasitas prediktif model probabilistik, sedangkan *Reconstruction Error* mengukur tingkat kesalahan faktorisasi matriks pada NMF. Perbandingan performa antar metode dalam penelitian ini sepenuhnya didasarkan pada nilai *Topic Coherence (Cv)*.

Berdasarkan Tabel 4.6, kualitas topik pada metode LDA dan NMF dievaluasi menggunakan nilai *Topic Coherence (Cv)* untuk berbagai jumlah topik (K) dari 2 hingga 8. Nilai *coherence* menunjukkan tingkat keterkaitan semantik antar kata dalam suatu topik, sehingga semakin tinggi nilainya maka semakin baik kualitas topik yang dihasilkan. Hasil pengujian menunjukkan bahwa pada metode LDA, nilai *coherence* tertinggi diperoleh pada $K = 5$ sebesar 0,6301, dengan tren peningkatan dari $K = 2$ (0,4484) hingga $K = 5$, kemudian mengalami penurunan pada $K = 6$ hingga 8. Sementara itu, metode NMF mencapai nilai *coherence* tertinggi pada $K = 3$ sebesar 0,7934, dengan nilai yang relatif stabil pada rentang 0,7465 hingga 0,7921 untuk seluruh variasi jumlah topik yang diuji.

Secara keseluruhan, NMF menghasilkan nilai *Topic Coherence (Cv)* yang lebih tinggi dibandingkan LDA pada seluruh variasi jumlah topik yang diuji, dengan rata-rata selisih sebesar 0,1553. Hal ini menunjukkan bahwa metode NMF memiliki kemampuan yang lebih baik dalam menghasilkan topik yang koheren dan mudah diinterpretasikan pada dataset berita online berbahasa Indonesia yang digunakan dalam penelitian ini.


Nilai *Log-Perplexity* pada metode LDA menunjukkan tren menurun seiring bertambahnya jumlah topik, dari 7,7355 pada $K = 2$ menjadi 7,4225 pada $K = 8$. Penurunan ini mengindikasikan bahwa model LDA semakin baik dalam merepresentasikan distribusi kata dalam dokumen ketika jumlah topik diperbanyak. Namun, seperti yang telah dijelaskan, *Log-Perplexity* LDA tidak digunakan sebagai dasar perbandingan dengan NMF. Sementara itu, *Reconstruction Error* pada metode NMF menunjukkan tren menurun dari 67,4821 pada $K = 2$ menjadi 56,4991 pada $K = 8$, yang mengindikasikan bahwa semakin banyak jumlah topik, semakin kecil tingkat kesalahan faktorisasi matriks, sehingga model NMF mampu mempertahankan struktur informasi data asli dengan lebih baik.

Meskipun nilai *Topic Coherence* (C_v) tertinggi untuk LDA diperoleh pada $K = 5$ (0,6301) dan untuk NMF pada $K = 3$ (0,7934), penelitian ini menetapkan $K = 4$ sebagai jumlah topik yang digunakan dalam pemodelan akhir. Keputusan ini didasarkan pada pertimbangan bahwa jumlah topik sebanyak 4 sesuai dengan struktur dataset yang terdiri atas empat kategori utama, yaitu politik, ekonomi, teknologi, dan olahraga. Dengan $K = 4$, setiap kategori dapat direpresentasikan secara lebih eksplisit, sehingga memudahkan proses interpretasi dan pemberian label topik. Pada $K = 4$, model LDA menghasilkan nilai *coherence* sebesar 0,6012 dan model NMF sebesar 0,7645, yang masih berada pada tingkat yang tinggi dan mampu merepresentasikan tema-tema utama dalam data secara seimbang.

Selain itu, pemilihan $K = 4$ juga mempertimbangkan aspek interpretabilitas topik secara kualitatif. Pada $K = 3$, topik yang dihasilkan cenderung terlalu umum dan menggabungkan beberapa tema yang seharusnya terpisah, sedangkan pada $K = 5$ atau lebih, beberapa topik mulai menunjukkan tumpang tindih yang signifikan sehingga menyulitkan proses pemberian label. Dengan demikian, $K = 4$ dipilih sebagai jumlah topik yang memberikan keseimbangan optimal antara nilai *Topic Coherence* (C_v), kesesuaian dengan struktur dataset, dan kemudahan interpretasi topik.

4.3.2 Visualisasi Coherence dan Perplexity vs K

Untuk memperjelas hubungan antara jumlah topik dan kualitas model, Gambar 4.1 menyajikan visualisasi nilai *Topic Coherence* (C_v) untuk metode LDA dan NMF, serta *Log-Perplexity* untuk metode LDA pada berbagai nilai K .



Gambar 4. 1 Hasil Jumlah K Optimal

Grafik *Topic Coherence* pada Gambar 4.1 menunjukkan bahwa nilai *coherence* LDA meningkat secara signifikan dari $K = 2$ hingga $K = 3$, kemudian mencapai nilai tertinggi pada $K = 5$ sebesar 0,630, sebelum akhirnya menurun pada K yang lebih besar. Pola ini mengindikasikan bahwa LDA membutuhkan jumlah topik yang cukup untuk memisahkan tema-tema yang berbeda, namun penambahan topik yang terlalu banyak justru menurunkan kualitas koherensi karena topik-topik mulai saling tumpang tindih.

Sementara itu, metode NMF menunjukkan nilai *coherence* yang relatif stabil dan tinggi pada seluruh variasi jumlah topik, dengan nilai tertinggi sebesar 0,793 pada $K = 3$ dan 0,792 pada $K = 7$. Stabilitas ini menunjukkan bahwa NMF lebih robust terhadap perubahan jumlah topik dibandingkan LDA, sehingga metode ini lebih fleksibel dalam menangani berbagai konfigurasi jumlah topik pada dataset berita online berbahasa Indonesia.

Grafik *Log-Perplexity* LDA menunjukkan tren menurun seiring bertambahnya jumlah topik, dari 7,736 pada $K = 2$ menjadi 7,423 pada $K = 8$. Penurunan ini konsisten dengan teori bahwa model probabilistik dengan lebih banyak parameter (topik) akan memiliki kapasitas prediktif yang lebih baik terhadap data pelatihan. Namun, seperti telah dijelaskan, nilai *Log-Perplexity* ini tidak digunakan sebagai dasar pemilihan K karena metrik ini hanya mengukur kemampuan prediktif internal model dan tidak mencerminkan kualitas interpretatif topik yang menjadi fokus utama penelitian ini. Penentuan $K = 4$ tetap didasarkan pada nilai *Topic Coherence* (C_v) dan pertimbangan interpretabilitas, sebagaimana telah diuraikan pada Subbab 4.3.1.

4.3.3 Kode Implementasi Pencarian K Optimal

Pencarian jumlah topik optimal dilakukan dengan menguji $K = 2$ hingga 8. Berikut potongan utama untuk membangun model LDA dan NMF serta menghitung *coherence*:

```

1. from gensim import corpora, models
2. from gensim.models.coherencemodel import CoherenceModel
3.
4. dictionary = corpora.Dictionary(df['tokens'])
5. dictionary.filter_extremes(no_below=5, no_above=0.90)
6. corpus = [dictionary.doc2bow(tokens) for tokens in
   df['tokens']]
7.
8. for K in range(2, 9):
9.     # LDA
10.         lda = models.LdaModel(corpus=corpus, num_topics=K,
11.                                id2word=dictionary,
12.                                passes=20, alpha=0.1, eta=0.01,
13.                                random_state=42)
14.         coh_lda = CoherenceModel(model=lda,
15.                                   texts=df['tokens'],
16.                                   dictionary=dictionary,
17.                                   coherence='c_v').get_coherence()
18.         # NMF
19.         nmf = NMF(n_components=K, init='random',
20.                   max_iter=200,
21.                   random_state=42)
22.         W = nmf.fit_transform(tfidf_matrix)
23.         H = nmf.components_
24.         # ... ekstraksi top words dan hitung coherence ...

```

Kode Program 4. 4 Pencarian K Optimal

Hasil pencarian (Tabel 4.6) menunjukkan bahwa K=4 dipilih sebagai kompromi antara koherensi, cakupan tematik, dan kemudahan interpretasi.

4.4 Hasil Pemodelan Topik dengan Metode LDA

Model LDA dibangun menggunakan library Gensim dengan K = 4 topik. Parameter yang digunakan adalah alpha = 0,1 (prior distribusi topik per dokumen), eta = 0,01 (prior distribusi kata per topik), passes = 20, dan random_state = 42. Proses pelatihan memakan waktu 71,9 detik.

4.4.1 Topik yang Dihasilkan LDA

Tabel 4.7 menampilkan keempat topik yang dihasilkan LDA. Pemberian label dilakukan secara manual berdasarkan interpretasi terhadap kata-kata dominan di masing-masing topik.

Tabel 4. 7 Topik yang Dihasilkan oleh Metode LDA (K=4)

No	Label Topik	10 Kata Dominan	Coherence (Cv)
1	Politik	prabowo, presiden, indonesia, perintah, daerah, negara, dpr, menteri, barat, ketua	0,4430
2	Olahraga	indonesia, piala, main, tim, final, hasil, kalah, gelar, asia, tanding	0,5945
3	Teknologi	teknologi, digital, indonesia, milik, hadir, sistem, anak, kuat, data, guna	0,3663
4	Ekonomi	ekonomi, indonesia, harga, tahun, tingkat, perintah, tumbuh, kuat, pasar, energi	0,5284
Rata - rata			0,4830

Berdasarkan Tabel 4.7, metode LDA berhasil menghasilkan empat topik utama yang sesuai dengan kategori berita dalam dataset, yaitu politik, olahraga, teknologi, dan ekonomi. Topik olahraga memperoleh nilai *coherence* tertinggi sebesar 0,5945, yang menunjukkan bahwa kata-kata dominan pada topik tersebut memiliki keterkaitan semantik yang paling kuat. Sebaliknya, topik teknologi memiliki nilai *coherence* terendah sebesar 0,3663, sehingga keterkaitan antar kata dalam topik tersebut relatif lebih rendah dibandingkan topik lainnya.

Secara keseluruhan, model LDA menghasilkan nilai *coherence* rata-rata sebesar 0,4830. Meskipun seluruh topik dapat diinterpretasikan dengan baik berdasarkan kata-kata dominannya, beberapa kata umum seperti *indonesia*, *perintah*, dan *kuat* masih muncul pada lebih dari satu topik. Kondisi ini menunjukkan adanya tumpang tindih antar topik yang menyebabkan kualitas pemisahan tema belum optimal, sehingga nilai *coherence* yang diperoleh masih berada di bawah hasil metode NMF.

4.4.2 Parameter dan Nilai Evaluasi LDA

Tabel 4. 8 Parameter dan Nilai Log-Perplexity Model LDA

Parameter	Nilai
Jumlah topik (K)	4
Alpha	0,1
Eta	0,01
Passes	20
Iterations	50
Random state	42
Waktu komputasi	63,96 detik
Rata-rata Topic Coherence (Cv)	0,4830
Log-Perplexity	25.332,81
Perplexity	25.332,81

Berdasarkan Tabel 4.8, model LDA dibangun menggunakan jumlah topik (K) sebanyak 4 dengan parameter $\alpha = 0,1$, $\eta = 0,01$, $\text{passes} = 20$, $\text{iterations} = 50$, dan $\text{random state} = 42$. Parameter tersebut digunakan untuk mengontrol proses pembelajaran model dalam membentuk distribusi topik dan distribusi kata pada setiap dokumen. Dengan konfigurasi tersebut, proses pelatihan model membutuhkan waktu komputasi sebesar 63,96 detik untuk menghasilkan empat topik utama yang merepresentasikan isi dataset berita.

Hasil evaluasi menunjukkan bahwa model LDA memperoleh nilai rata-rata Topic Coherence (Cv) sebesar 0,4830, yang mengindikasikan bahwa kata-kata dominan pada setiap topik memiliki tingkat keterkaitan semantik yang cukup baik. Selain itu, model menghasilkan nilai Log-Perplexity sebesar 10,1399 dan Perplexity sebesar 25.332,81. Nilai *perplexity* digunakan untuk mengukur kemampuan model dalam merepresentasikan distribusi kata pada dokumen, sedangkan nilai *coherence* digunakan untuk menilai kualitas dan interpretabilitas topik yang dihasilkan. Berdasarkan hasil tersebut, model LDA mampu mengidentifikasi struktur topik pada dataset berita, meskipun kualitas topik yang dihasilkan masih dapat ditingkatkan jika dibandingkan dengan metode lain yang menghasilkan nilai *coherence* lebih tinggi.

4.4.3 Kode Implementasi LDA

Model LDA final dibangun dengan parameter berikut:


```

1. lda_model = gensim.models.LdaModel (
2. corpus=corpus,
3. num_topics=4,
4. id2word=dictionary,
5. passes=20,
6. alpha=0.1,
7. eta=0.01,
8. random_state=42
9. )

```

Kode Program 4. 5 LDA

Setelah pelatihan (waktu 71,9 detik), topik diekstrak menggunakan `print_topics()` dan dievaluasi dengan `CoherenceModel`. Nilai `log-perplexity` diperoleh dari `lda_model.log_perplexity(corpus)` dan dikonversi menjadi `perplexity` (PP) dengan rumus $\exp(-\log_perplexity)$. Hasil topik dan koherensinya disajikan pada Tabel 4.8

4.5 Hasil Pemodelan Topik dengan Metode NMF

Berdasarkan konfigurasi pada notebook, metode *Non-Negative Matrix Factorization* (NMF) digunakan untuk memfaktorkan matriks TF-IDF menjadi dua matriks non-negatif, yaitu matriks W (dokumen $\times$ topik) dan matriks H (topik $\times$ kata). Model dibangun menggunakan parameter `n_components = 4`, `init = 'random'`, `solver = 'cd'`, `max_iter = 200`, dan `random_state = 42`. Konfigurasi tersebut memungkinkan model mengidentifikasi pola keterkaitan antara dokumen dan kata melalui proses faktorisasi matriks sehingga topik dapat diekstraksi berdasarkan bobot kata yang terbentuk pada setiap topik.

Hasil implementasi menunjukkan bahwa proses pelatihan model NMF membutuhkan waktu komputasi sekitar 0,22 detik, jauh lebih cepat dibandingkan model LDA yang memerlukan waktu 63,96 detik. Dari sisi kualitas topik, model NMF menghasilkan nilai rata-rata *Topic Coherence* (C_v) sebesar 0,7645. Nilai ini merupakan metrik utama yang digunakan untuk mengevaluasi kualitas topik karena mampu mengukur tingkat keterkaitan semantik antar kata dominan dalam setiap topik, dan dapat dibandingkan secara adil (*fair comparison*) dengan metode LDA.

Selain *Topic Coherence* (C_v), proses faktorisasi matriks pada NMF juga menghasilkan *Reconstruction Error* sebesar 60,2670. *Reconstruction Error* merupakan metrik diagnostik internal yang mengukur tingkat kesalahan antara matriks TF-IDF asli (V) dengan hasil perkalian matriks hasil faktorisasi (W

$\times H$). Nilai *Reconstruction Error* yang semakin kecil menunjukkan bahwa proses faktorisasi berhasil mempertahankan struktur informasi data asli dengan baik. Namun, sebagaimana telah dijelaskan pada Subbab 3.6, *Reconstruction Error* bersifat internal dan tidak digunakan sebagai metrik pembandingan antara NMF dan LDA, karena LDA tidak memiliki mekanisme faktorisasi matriks sehingga tidak dapat menghasilkan metrik yang setara secara matematis. Dengan demikian, keputusan mengenai keunggulan metode dalam penelitian ini sepenuhnya didasarkan pada nilai *Topic Coherence* (C_v) dan analisis interpretabilitas topik.

4.5.1 Topik yang Dihasilkan NMF

Tabel 4. 9 Topik yang Dihasilkan oleh Metode NMF (K=4)

No	Label Topik	10 Kata Dominan	Coherence (C_v)
1	Olahraga	piala, indonesia, final, futsal, kalah, jadwal, aff, thailand, asia, main	0,9130
2	Ekonomi	ekonomi, tumbuh, harga, indonesia, perintah, kuat, pasar, global, ojk, tahun	0,5503
3	Teknologi	misi, nasa, burung, artemis, teliti, kulit, darat, adang, rem, bumi	0,9860
4	Politik	prabowo, presiden, daerah, perintah, teddy, politeknik, partai, dpr, negara, disabilitas	0,6087
Rata - rata			0,7645

Berdasarkan Tabel 4.9, metode NMF berhasil menghasilkan empat topik utama yang dapat diidentifikasi sebagai olahraga, ekonomi, teknologi, dan politik. Topik teknologi memperoleh nilai *coherence* tertinggi sebesar 0,9860, yang menunjukkan bahwa kata-kata dominan pada topik tersebut memiliki keterkaitan semantik yang sangat kuat dan membentuk tema yang sangat spesifik, yaitu eksplorasi antariksa dan penelitian ilmiah (ditandai dengan

kata *nasa*, *misi*, *artemis*, *bumi*, dan *teliti*). Topik olahraga juga menghasilkan nilai *coherence* yang tinggi sebesar 0,9130 dengan kata-kata dominan yang secara konsisten mengarah pada kompetisi sepak bola dan futsal tingkat Asia (*piala*, *aff*, *thailand*, *final*, *jadwal*). Sementara itu, topik ekonomi memiliki nilai *coherence* terendah sebesar 0,5503, yang masih tergolong cukup baik meskipun terdapat beberapa kata umum seperti *indonesia* dan *perintah* yang sedikit mengurangi kekhasan topik tersebut.

Secara keseluruhan, model NMF menghasilkan nilai rata-rata *Topic Coherence (Cv)* sebesar 0,7645, yang tergolong tinggi dan menunjukkan bahwa kata-kata dominan pada setiap topik memiliki keterkaitan semantik yang kuat. Selain itu, kata-kata dominan pada setiap topik cenderung lebih spesifik dan memiliki tingkat tumpang tindih yang lebih kecil antar topik dibandingkan metode LDA. Kondisi ini menunjukkan bahwa metode NMF mampu memisahkan tema-tema utama dalam dataset berita dengan lebih jelas, sehingga topik yang dihasilkan lebih mudah diinterpretasikan dan diberi label secara konsisten. Hasil ini juga mengindikasikan bahwa penggunaan representasi TF-IDF sebagai input pada NMF efektif dalam menonjolkan kata-kata khas yang membedakan satu kategori berita dengan kategori lainnya.

4.5.2 Kode Implementasi NMF

Model NMF di implementasikan menggunakan `sklearn.decomposition`. NMF dengan konfigurasi:

```
1. from sklearn.decomposition import NMF
2.
3. nmf = NMF(
4.     n_components=4,
5.     init='random',
6.     max_iter=200,
7.     random_state=42,
8.     solver='cd'
9. )
10.     W = nmf.fit_transform(tfidf_matrix)
11.     H = nmf.components_
```

Kode Program 4. 6 Implementasi NMF

Topik diperoleh dari matriks H dengan mengambil 10 kata berbobot tertinggi per topik. Waktu komputasi hanya 0,3 detik. Koherensi setiap topik dihitung

menggunakan CoherenceModel dari Gensim, dan hasilnya ditampilkan pada Tabel 4.9.

4.6 Perbandingan Hasil LDA dan NMF

4.6.1 Dasar Penentuan Label Topik

Sebelum membandingkan nilai coherence, perlu dijelaskan cara pemberian label pada masing-masing topik. Label ditentukan secara manual berdasarkan interpretasi peneliti terhadap kata-kata dominan bukan dari label kategori dataset. Prinsipnya sederhana: lihat mayoritas kata dominan, tentukan tema yang paling banyak diwakili, beri label sesuai tema tersebut.

Tabel 4.10 berikut menjelaskan dasar penentuan label pada masing-masing topik untuk LDA dan NMF:

Tabel 4. 10 Dasar Penentuan Label Topik LDA dan NMF

No	Metode	Kata Dominan Kunci	Label Diberikan	Alasan Pemberian Label
1.	LDA	prabowo, presiden, daerah, negara, dpr, menteri, ketua	Politik	Didominasi oleh nama tokoh, lembaga pemerintahan, dan aktivitas politik nasional.
2.	LDA	piala, main, tim, final, kalah, gelar, asia, tanding	Olahraga	Kata-kata dominan berkaitan dengan pertandingan, kompetisi, dan prestasi olahraga.
3.	LDA	teknologi, digital, sistem, data, guna, hadir	Teknologi	Kata dominan menggambarkan perkembangan teknologi, sistem

No	Metode	Kata Dominan Kunci	Label Diberikan	Alasan Pemberian Label
				digital, dan pemanfaatan data.
4.	LDA	ekonomi, harga, tumbuh, pasar, energi, tingkat	Ekonomi	Didominasi oleh istilah yang berkaitan dengan pertumbuhan ekonomi, perdagangan, dan energi.
5.	NMF	piala, futsal, aff, thailand, final, jadwal, asia	Olahraga	Topik secara spesifik menggambarkan kompetisi olahraga internasional, khususnya sepak bola dan futsal.
6.	NMF	ekonomi, tumbuh, harga, pasar, global, ojk	Ekonomi	Kata-kata dominan menunjukkan isu ekonomi makro, pasar, dan sektor keuangan.
7.	NMF	nasa, misi, artemis, bumi, teliti, burung, kulit	Teknologi	Topik berfokus pada penelitian ilmiah, eksplorasi antariksa, dan perkembangan teknologi.

No	Metode	Kata Dominan Kunci	Label Diberikan	Alasan Pemberian Label
8.	NMF	prabowo, presiden, teddy, partai, dpr, negara	Politik	Didominasi oleh tokoh politik, partai, serta institusi pemerintahan dan legislatif.

Tabel 4.10 proses pemberian label topik dilakukan dengan menginterpretasikan kata-kata dominan yang dihasilkan oleh metode LDA dan NMF. Label diberikan berdasarkan tema yang paling merepresentasikan kumpulan kata pada setiap topik. Pada metode LDA, empat topik yang terbentuk dapat diidentifikasi sebagai politik, olahraga, teknologi, dan ekonomi. Topik politik ditandai oleh kemunculan kata seperti prabowo, presiden, dpr, dan menteri yang berkaitan dengan pemerintahan dan aktivitas politik. Topik olahraga didominasi kata piala, tim, final, dan tanding yang menggambarkan kompetisi olahraga. Topik teknologi ditandai oleh kata teknologi, digital, sistem, dan data, sedangkan topik ekonomi ditunjukkan oleh kata ekonomi, harga, tumbuh, dan pasar yang berkaitan dengan aktivitas ekonomi dan perdagangan.

Pada metode NMF, proses pemberian label menghasilkan tema yang sama, yaitu olahraga, ekonomi, teknologi, dan politik, namun dengan kata-kata dominan yang lebih spesifik. Topik olahraga memuat kata seperti futsal, aff, dan thailand yang secara langsung mengarah pada kompetisi olahraga tertentu. Topik ekonomi didominasi istilah ekonomi, harga, pasar, global, dan ojk yang menunjukkan isu ekonomi dan keuangan. Topik teknologi menampilkan kata nasa, misi, dan artemis yang berkaitan dengan penelitian dan eksplorasi antariksa, sedangkan topik politik ditandai oleh kemunculan nama tokoh dan institusi politik seperti prabowo, presiden, partai, dan dpr. Hasil ini menunjukkan bahwa topik yang dihasilkan NMF cenderung lebih spesifik dan mudah diinterpretasikan dibandingkan topik yang dihasilkan oleh LDA.

Tabel 4. 11 Perbandingan Nilai Topic Coherence (Cv) LDA dan NMF

Label	LDA (Cv)	NMF (Cv)	Selisih	Metode Unggul
Politik	0,4430	0,5503	+0,1073	NMF
Olahraga	0,5945	0,9130	+0,3185	NMF
Teknologi	0,3663	0,9860	+0,6197	NMF
Ekonomi	0,5284	0,6087	+0,0803	NMF
Rata-rata	0,4830	0,7645	+0,2815	NMF

Berdasarkan Tabel 4.11, metode NMF menghasilkan nilai *Topic Coherence* (Cv) yang lebih tinggi dibandingkan metode LDA pada hampir seluruh topik yang dihasilkan. Perbedaan terbesar terdapat pada topik teknologi dengan selisih sebesar 0,6197, di mana NMF memperoleh nilai *coherence* sebesar 0,9860, sedangkan LDA hanya mencapai 0,3663. Hal ini menunjukkan bahwa kata-kata dominan yang dihasilkan NMF pada topik teknologi memiliki keterkaitan semantik yang jauh lebih kuat dibandingkan LDA. Pada topik olahraga, NMF juga menunjukkan peningkatan yang cukup besar dengan nilai *coherence* sebesar 0,9130, lebih tinggi dibandingkan LDA yang memperoleh 0,5945.

Pada topik ekonomi, perbedaan kedua metode relatif kecil dengan selisih 0,0219, menunjukkan bahwa keduanya mampu menghasilkan topik ekonomi yang cukup baik. Secara keseluruhan, rata-rata *Topic Coherence* (Cv) NMF mencapai 0,7645, sedangkan LDA hanya memperoleh 0,4830, sehingga terdapat peningkatan sebesar 0,2815. Hasil ini menunjukkan bahwa metode NMF mampu menghasilkan topik yang lebih koheren dan lebih mudah diinterpretasikan dibandingkan metode LDA pada dataset berita yang digunakan dalam penelitian.

4.6.2 Perbandingan Waktu Komputasi

Tabel 4. 12 Perbandingan Waktu Komputasi LDA dan NMF

Indikator	LDA	NMF
Waktu model fitting	63,96 detik	0,22 detik
Rasio perbandingan kecepatan (×)	291	1

Berdasarkan Tabel 4.12, metode NMF membutuhkan waktu komputasi sebesar 0,22 detik, sedangkan metode LDA memerlukan waktu 63,96 detik untuk menyelesaikan proses pelatihan model pada dataset yang sama. Hasil tersebut menunjukkan bahwa NMF memiliki kecepatan komputasi yang jauh lebih tinggi dibandingkan LDA. Berdasarkan perhitungan rasio waktu komputasi, NMF mampu menyelesaikan proses pemodelan sekitar 291 kali lebih cepat dibandingkan LDA.

Perbedaan waktu komputasi ini disebabkan oleh perbedaan mekanisme kerja kedua metode. LDA menggunakan pendekatan probabilistik yang memerlukan proses inferensi berulang untuk memperkirakan distribusi topik dan distribusi kata, sehingga membutuhkan waktu komputasi yang lebih besar. Sebaliknya, NMF melakukan faktorisasi matriks TF-IDF menggunakan operasi aljabar matriks yang lebih sederhana dan efisien. Oleh karena itu, selain menghasilkan nilai *Topic Coherence* yang lebih tinggi, NMF juga menunjukkan efisiensi komputasi yang lebih baik dibandingkan LDA pada dataset berita yang digunakan dalam penelitian ini.

4.6.3 Ringkasan Perbandingan LDA dan NMF

Berdasarkan seluruh hasil evaluasi yang telah dipaparkan pada subbab sebelumnya, bagian ini menyajikan ringkasan perbandingan kinerja antara metode *Latent Dirichlet Allocation* (LDA) dan *Non-Negative Matrix Factorization* (NMF) dalam pemodelan topik berita online berbahasa Indonesia. Sebagaimana telah ditegaskan pada Subbab 3.6, perbandingan antar-metode dalam penelitian ini hanya didasarkan pada metrik yang dapat diterapkan secara adil (*fair comparison*) pada kedua metode, yaitu *Topic Coherence* (Cv) sebagai metrik kuantitatif utama, serta interpretabilitas topik dan waktu komputasi sebagai evaluasi tambahan. Metrik diagnostik internal seperti *Perplexity* (khusus LDA) dan *Reconstruction Error* (khusus NMF) tidak digunakan sebagai dasar perbandingan dan disajikan secara terpisah pada bagian akhir subbab ini

Tabel 4. 13 Ringkasan Perbandingan LDA dan NMF (matrik pembanding utama)

Indikator Evaluasi	LDA	NMF
Rata-rata Coherence (Cv)	0,4830	0,7645

Coherence Topik Politik	0,4430	0,6087
Coherence Topik Olahraga	0,5945	0,9130
Coherence Topik Teknologi	0,3663	0,9860
Coherence Topik Ekonomi	0,5284	0,5503
Waktu Komputasi Model	63,96 detik	0,22 detik
Ketajaman batas topik	Sedang, masih terdapat tumpang tindih kata	Tinggi, kata lebih spesifik
Unggul pada Topik	1 dari 4 topik	3 dari 4 topik
Rekomendasi Akhir	Cukup Baik	Terbaik

Berdasarkan Tabel 4.13, metode NMF menunjukkan performa yang lebih unggul dibandingkan LDA pada hampir seluruh indikator evaluasi. Dari sisi Topic Coherence (Cv), NMF menghasilkan rata-rata sebesar 0,7645, jauh lebih tinggi dibandingkan LDA yang hanya mencapai 0,4830, dengan selisih sebesar 0,2815 atau 58,3% lebih tinggi. Pada tingkat topik, NMF unggul pada tiga dari empat topik, yaitu topik Teknologi (Cv = 0,9860), Olahraga (Cv = 0,9130), dan Politik (Cv = 0,6087). Sementara itu, LDA hanya unggul pada topik Ekonomi dengan selisih yang sangat tipis (0,5284 vs 0,5503, selisih hanya 0,0219 atau 4,1%). Keunggulan NMF pada topik Teknologi dan Olahraga sangat signifikan, yang menunjukkan bahwa kata-kata dominan yang dihasilkan NMF pada kedua topik tersebut memiliki keterkaitan semantik yang sangat kuat dan membentuk tema yang sangat spesifik.

Dari sisi efisiensi komputasi, NMF juga jauh lebih unggul dengan waktu pelatihan model hanya 0,22 detik, sedangkan LDA membutuhkan waktu 63,96 detik. Dengan demikian, NMF sekitar 291 kali lebih cepat dibandingkan LDA pada dataset yang sama. Perbedaan waktu komputasi ini disebabkan oleh perbedaan mekanisme kerja kedua metode. LDA menggunakan pendekatan probabilistik yang memerlukan proses inferensi berulang (seperti *Gibbs Sampling* atau *Variational Bayes*) untuk memperkirakan distribusi topik dan distribusi kata, sehingga membutuhkan waktu komputasi yang jauh lebih besar. Sebaliknya, NMF melakukan faktorisasi matriks TF-IDF menggunakan operasi aljabar matriks yang lebih sederhana dan efisien.

Dari sisi interpretabilitas dan ketajaman batas topik, topik-topik yang dihasilkan NMF memiliki kata-kata dominan yang lebih spesifik dan eksklusif terhadap satu tema tertentu. Sebagai contoh, topik Teknologi pada NMF didominasi oleh kata-kata seperti *nasa*, *misi*, *artemis*, *bumi*, dan *teliti* yang secara jelas mengarah pada tema eksplorasi antariksa dan penelitian ilmiah. Sebaliknya, topik Teknologi pada LDA masih mengandung kata-kata umum seperti *indonesia*, *hadir*, *anak*, dan *kuat* yang tidak memiliki keterkaitan langsung dengan tema teknologi, sehingga menurunkan koherensi dan mempersulit proses interpretasi. Kondisi serupa juga terlihat pada topik Olahraga dan Politik, di mana NMF menghasilkan kata-kata yang lebih terfokus dibandingkan LDA. Hal ini menunjukkan bahwa NMF mampu memisahkan tema-tema utama dalam dataset berita dengan lebih jelas, sehingga topik yang dihasilkan lebih mudah dipahami dan diberi label secara konsisten.

Berdasarkan seluruh indikator tersebut, metode NMF dapat direkomendasikan sebagai metode yang lebih efektif untuk pemodelan topik pada dataset berita online berbahasa Indonesia yang digunakan dalam penelitian ini

Metrik Diagnostik Internal (Tidak Digunakan sebagai Dasar Perbandingan).

Sebagai informasi tambahan, selama proses eksperimen juga dicatat metrik diagnostik internal untuk masing-masing metode, yaitu *Perplexity* dan *Log-Perplexity* untuk LDA, serta *Reconstruction Error* untuk NMF. Metrik-metrik ini bersifat internal dan hanya digunakan untuk memantau performa masing-masing metode secara terpisah, bukan untuk membandingkan LDA dengan NMF. Hal ini karena *Perplexity* mengukur kapasitas prediktif model probabilistik berdasarkan *log-likelihood*, sedangkan *Reconstruction Error* mengukur tingkat kesalahan faktorisasi matriks pada NMF. Kedua metrik memiliki dasar matematis dan skala pengukuran yang berbeda secara fundamental, sehingga tidak dapat dibandingkan secara langsung.

Tabel 4. 14 Metrik Diagnostik Internal Masing-Masing Metode (Tidak Diperbandingkan)

Metode	Metrik Internal	Nilai	Keterangan

LDA	Perplexity (PP)	25.332,81	Semakin kecil nilai PP, semakin baik kapasitas prediktif model LDA terhadap data
LDA	Log-Perplexity	10,1399	Transformasi log dari PP; digunakan sebagai indikator internal konvergensi model
NMF	Reconstruction Error (ER)	60,2670	Semakin kecil nilai RE, semakin baik kualitas faktorisasi matriks $V \approx W \times H$ pada NMF

Nilai *Perplexity* LDA sebesar 25.332,81 menunjukkan bahwa model LDA memiliki kapasitas prediktif yang cukup baik terhadap distribusi kata dalam dokumen, dengan nilai yang semakin kecil mengindikasikan performa yang semakin baik. Sementara itu, *Reconstruction Error* NMF sebesar 60,2670 menunjukkan bahwa proses faktorisasi matriks berhasil mempertahankan struktur informasi data asli dengan tingkat kesalahan yang relatif kecil. Namun, sebagaimana telah ditegaskan, kedua nilai ini tidak dapat dibandingkan secara langsung karena keduanya mengukur aspek yang berbeda—*Perplexity* mengukur ketidakpastian prediksi probabilistik, sedangkan *Reconstruction Error* mengukur jarak matriks hasil rekonstruksi terhadap matriks asli. Oleh karena itu, metrik-metrik ini tidak memengaruhi kesimpulan akhir mengenai metode terbaik, yang sepenuhnya didasarkan pada *Topic Coherence* (C_v), interpretabilitas, dan efisiensi komputasi

4.6.4 Analisis Interpretabilitas Topik

Berdasarkan hasil pemodelan topik pada penelitian ini, interpretabilitas topik juga dievaluasi secara kualitatif berdasarkan kemudahan pemberian label terhadap kata-kata dominan yang dihasilkan oleh masing-masing metode. Topik yang dihasilkan NMF secara umum lebih mudah diinterpretasikan karena memiliki kata-kata dominan yang lebih spesifik dan menunjukkan keterkaitan semantik yang kuat dalam satu tema tertentu. Sebagai contoh, topik teknologi pada NMF menghasilkan kata-kata seperti *nasa*, *misi*, *artemis*, *bumi*, dan *teliti* yang secara jelas menggambarkan tema penelitian dan eksplorasi antariksa. Sebaliknya, topik

teknologi pada LDA menghasilkan kata-kata seperti *teknologi*, *digital*, *hadir*, *sistem*, *data*, *anak*, dan *kuat* yang masih bersifat umum serta kurang mengarah pada satu subtema yang spesifik. Kondisi serupa juga terlihat pada topik olahraga dan politik, di mana kata-kata dominan pada NMF cenderung lebih fokus dibandingkan LDA.

Perbedaan tersebut menunjukkan bahwa NMF mampu menghasilkan batas topik yang lebih jelas dengan tingkat tumpang tindih kata yang lebih rendah antar topik. Pada LDA, beberapa kata seperti *indonesia*, *perintah*, dan *kuat* muncul pada lebih dari satu topik sehingga mengurangi kekhasan masing-masing topik. Sebaliknya, kata-kata dominan yang dihasilkan NMF lebih eksklusif terhadap topik tertentu, sehingga proses interpretasi dan pemberian label dapat dilakukan dengan lebih mudah. Hasil ini sejalan dengan nilai *Topic Coherence (Cv)* yang diperoleh, di mana NMF menghasilkan rata-rata *coherence* sebesar 0,7645, lebih tinggi dibandingkan LDA yang hanya mencapai 0,4830, sehingga topik yang dihasilkan NMF lebih konsisten dan mudah dipahami.

4.6.5 Kode Implementasi Perbandingan

Perbandingan antara LDA dan NMF dilakukan dengan mengumpulkan nilai koherensi dan waktu komputasi. Berikut potongan untuk menghitung selisih dan rata-rata:

```
1. lda_coherence = [0.4430, 0.5945, 0.3663, 0.5284]
2. nmf_coherence = [0.9130, 0.5503, 0.9860, 0.6087]
3. avg_lda = np.mean(lda_coherence)
4. avg_nmf = np.mean(nmf_coherence)
5. selisih = avg_nmf - avg_lda # 0.2815
```

Kode Program 4. 7 Perbandingan

Hasil perbandingan dirangkum dalam Tabel 4.11, 4.12, dan 4.13. NMF unggul pada tiga dari empat topik (teknologi, olahraga, dan politik) dengan rata-rata Topic Coherence (Cv) sebesar 0,7645 dibandingkan LDA yang hanya 0,4830. Dari sisi efisiensi komputasi, NMF juga jauh lebih cepat dengan waktu pelatihan model hanya 0,22 detik dibandingkan LDA yang membutuhkan 63,96 detik (1 menit 4 detik), sehingga NMF sekitar 291 kali lebih cepat dari LDA.

4.7 Perbandingan Pengaruh Stemming terhadap Kualitas Topik

Selain membandingkan performa metode LDA dan NMF, penelitian ini juga mengevaluasi pengaruh proses *stemming* terhadap kualitas topik yang data pada dataset berita yang sama, yaitu data yang melalui proses *stemming* menggunakan pustaka PySastrawi dan data tanpa proses *stemming*. Seluruh parameter pemodelan, jumlah topik, metode representasi TF-IDF, serta konfigurasi model dipertahankan sama sehingga perbedaan hasil yang diperoleh hanya dipengaruhi oleh keberadaan proses *stemming*. Evaluasi dilakukan menggunakan nilai *Topic Coherence (Cv)* untuk mengetahui apakah proses *stemming* mampu meningkatkan kualitas dan interpretabilitas topik yang dihasilkan pada data berita online berbahasa Indonesia.

Berdasarkan hasil pengujian pada notebook, proses *stemming* memberikan pengaruh yang berbeda pada masing-masing metode. Pada model LDA, penggunaan *stemming* menghasilkan nilai *Topic Coherence (Cv)* sebesar 0,5118, sedikit lebih tinggi dibandingkan tanpa *stemming* yang memperoleh nilai 0,5001. Sebaliknya, pada model NMF, hasil terbaik justru diperoleh tanpa *stemming* dengan nilai *coherence* sebesar 0,8181, sedangkan penggunaan *stemming* menghasilkan nilai 0,7645. Hasil tersebut menunjukkan bahwa proses *stemming* tidak selalu meningkatkan kualitas topik. Pada beberapa kasus, terutama pada data berita berbahasa Indonesia, proses *stemming* dapat menghilangkan informasi semantik tertentu karena kata-kata yang berbeda konteks disederhanakan menjadi bentuk dasar yang sama, sehingga memengaruhi kualitas topik yang dihasilkan.

4.7.1 Konfigurasi Pipeline

Tabel 4. 15 Konfigurasi Pipeline Dengan Stemming vs Tanpa Stemming

Tahapan	Dengan Stemming	Tanpa Stemming
Cleaning	Ya	Ya
Case Folding	Ya	Ya
Tokenizing	Ya	Ya
Stopword Removal	Ya	Ya
Stemming (PySastrawi)	Ya	Tidak
Waktu Preprocessing	18,66 detik	2,87 detik

Berdasarkan Tabel 4.14, kedua skenario preprocessing menggunakan tahapan yang sama, yaitu *cleaning*, *case folding*, *tokenizing*, dan *stopword removal*. Perbedaan utama terletak pada penggunaan proses *stemming* menggunakan pustaka PySastrawi. Pada skenario pertama, setiap kata yang memiliki imbuhan diubah ke bentuk dasarnya, sedangkan pada skenario kedua proses tersebut tidak dilakukan sehingga kata-kata tetap dipertahankan dalam bentuk aslinya setelah proses *stopword removal*.

Dari sisi waktu komputasi, penggunaan *stemming* memberikan tambahan waktu preprocessing yang cukup signifikan. Proses preprocessing dengan *stemming* membutuhkan waktu 18,66 detik, sedangkan tanpa *stemming* hanya membutuhkan waktu 2,87 detik. Hasil ini menunjukkan bahwa proses *stemming* merupakan tahapan yang paling memengaruhi waktu preprocessing karena setiap token harus melalui proses pencarian dan transformasi ke bentuk kata dasar. Meskipun demikian, pengaruh *stemming* terhadap kualitas topik perlu dianalisis lebih lanjut melalui perbandingan nilai *Topic Coherence (Cv)* yang dihasilkan oleh model LDA dan NMF pada kedua skenario tersebut.

4.7.2 Hasil Perbandingan Coherence

Tabel 4. 16 Perbandingan Topic Coherence: Dengan Stemming vs Tanpa Stemming

Metode	Dengan Stemming	Tanpa Stemming	Selisih	Lebih Baik
LDA Coherence (Cv)	0,5118	0,5001	0,0117	Dengan Stemming
NMF Coherence (Cv)	0,7645	0,8181	-0,0536	Tanpa Stemming
Waktu Preprocessing	18,66 detik	2,87 detik	-10,23 detik	Tanpa Stemming

Berdasarkan Tabel 4.15, pengaruh proses *stemming* terhadap kualitas topik berbeda pada masing-masing metode. Pada model LDA, penggunaan *stemming* menghasilkan nilai *Topic Coherence (Cv)* sebesar 0,5118, sedikit lebih tinggi dibandingkan tanpa *stemming* yang memperoleh nilai 0,5001. Selisih sebesar 0,0117 menunjukkan bahwa proses *stemming* memberikan peningkatan kualitas topik yang relatif kecil pada metode LDA. Hasil ini menunjukkan bahwa penyederhanaan kata ke bentuk dasar dapat membantu LDA dalam mengelompokkan kata-kata yang memiliki makna serupa ke dalam topik yang sama.

Sebaliknya, pada model NMF, nilai *Topic Coherence (Cv)* tertinggi diperoleh tanpa *stemming*, yaitu sebesar 0,8181, sedangkan penggunaan *stemming* menghasilkan nilai 0,7645. Penurunan sebesar 0,0536 menunjukkan bahwa proses *stemming* justru mengurangi kualitas topik yang dihasilkan oleh NMF. Hal ini dapat terjadi karena beberapa kata yang memiliki konteks berbeda disederhanakan menjadi bentuk dasar yang sama sehingga mengurangi kekhasan kata pada masing-masing topik. Dari sisi efisiensi, preprocessing tanpa *stemming* juga lebih cepat dengan waktu 2,87 detik, sedangkan preprocessing dengan *stemming* membutuhkan 18,66 detik. Oleh karena itu, berdasarkan kualitas topik dan waktu pemrosesan, penggunaan *stemming* lebih menguntungkan untuk LDA, sedangkan pada NMF hasil terbaik diperoleh tanpa *stemming*.

4.7.3 Kode Implementasi Pengaruh Stemming

Untuk menguji pengaruh *stemming*, dibuat dua pipeline: dengan dan tanpa *stemming*. Fungsi preprocessing tanpa *stemming* hampir sama, hanya menghilangkan baris `stemmer.stem()`. Berikut potongan perbandingan waktu:

```
1. start = time.time()
2. df['tokens'] = df['content'].apply(preprocess_with_stem)
   # dengan
3. stemming
4. print(f"Dengan stemming: {time.time()-start:.2f} detik")
   # 18.66 detik
5.
6. start = time.time()
7. df['tokens'] =
   df['content'].apply(preprocess_without_stem) # tanpa
8. stemming
```

```
9. print(f"Tanpa stemming: {time.time()-start:.2f} detik")
# 2.87 detik
```

Kode Program 4. 8 Pengaruh Stemming

Hasil koherensi (Tabel 4.15) menunjukkan bahwa untuk NMF, tanpa stemming justru memberikan koherensi lebih tinggi (0,8181 vs 0,7645), sedangkan untuk LDA perbedaannya tipis (0,5118 vs 0,5001). Hal ini mengindikasikan bahwa stemming tidak selalu menguntungkan, terutama pada NMF dengan data berbahasa Indonesia.

4.8 Pembahasan

4.8.1 Analisis Perbandingan LDA dan NMF

Secara keseluruhan, metode NMF menunjukkan performa yang lebih baik dibandingkan LDA dalam pemodelan topik pada dataset berita online berbahasa Indonesia. Hal ini terlihat dari nilai rata-rata *Topic Coherence (Cv)* yang diperoleh NMF sebesar 0,7645, lebih tinggi dibandingkan LDA yang hanya mencapai 0,4830. Selain menghasilkan nilai *coherence* yang lebih tinggi, topik-topik yang dihasilkan NMF juga memiliki kata-kata dominan yang lebih spesifik dan lebih mudah diinterpretasikan. Kata-kata pada setiap topik cenderung memiliki keterkaitan semantik yang kuat dan tingkat tumpang tindih yang lebih rendah dibandingkan LDA, sehingga proses pemberian label topik dapat dilakukan dengan lebih jelas dan konsisten.

Perbedaan kualitas topik terlihat jelas pada topik teknologi yang dihasilkan oleh kedua metode. Pada LDA, topik teknologi memiliki nilai *coherence* sebesar 0,3663 dengan kata-kata dominan seperti *teknologi*, *digital*, *indonesia*, *milik*, *hadir*, *sistem*, *anak*, *kuat*, *data*, dan *guna*. Kehadiran beberapa kata yang bersifat umum menyebabkan batas topik menjadi kurang jelas dan menurunkan tingkat koherensi topik tersebut. Sebaliknya, NMF menghasilkan topik teknologi dengan nilai *coherence* sebesar 0,9860 yang didominasi oleh kata-kata seperti *nasa*, *misi*, *artemis*, *teliti*, *bumi*, dan kata-kata lain yang berkaitan dengan penelitian serta eksplorasi antariksa. Kata-kata tersebut membentuk tema yang lebih spesifik dan konsisten sehingga topik lebih mudah diidentifikasi. Hasil ini menunjukkan bahwa NMF lebih efektif dalam memisahkan kata-kata yang benar-benar merepresentasikan suatu tema, sementara LDA masih menghasilkan beberapa kata

umum yang muncul pada lebih dari satu topik. Oleh karena itu, berdasarkan nilai *Topic Coherence*, interpretabilitas topik, dan kejelasan batas antar topik, metode NMF merupakan metode yang lebih efektif untuk pemodelan topik pada dataset berita yang digunakan dalam penelitian ini.

4.8.2 Karakteristik Bahasa Indonesia dalam Pemodelan Topik

Bahasa Indonesia memiliki sistem morfologi yang kaya, dengan banyak variasi imbuhan yang membuat satu kata dasar bisa memiliki puluhan bentuk. *Stemming* PySastrawi menangani ini dengan cukup baik, tetapi tidak sempurna. Kasus paling nyata dalam penelitian ini adalah kata "pemerintah" yang di-*stem* menjadi "perintah" bentuk dasar yang memiliki makna berbeda dan justru menjadi *noise* yang muncul di hampir semua topik. Fenomena ini menjelaskan mengapa NMF tanpa *stemming* menghasilkan *coherence* yang lebih tinggi: tanpa *stemming*, kata "pemerintah" tetap "pemerintah" dan tidak tercampur dengan kata "perintah" dalam konteks lain.

Temuan ini punya implikasi praktis untuk penelitian NLP berbahasa Indonesia: penggunaan *stemming* perlu dipertimbangkan secara hati-hati tergantung metode yang digunakan. Untuk LDA, *stemming* memberikan manfaat kecil. Untuk NMF, *stemming* justru kontraproduktif.

4.8.3 Keterkaitan dengan Penelitian Terdahulu

Hasil penelitian menunjukkan bahwa metode NMF menghasilkan kualitas topik yang lebih baik dibandingkan LDA pada dataset berita online berbahasa Indonesia yang digunakan, dengan nilai rata-rata *Topic Coherence* (C_v) sebesar 0,7645, lebih tinggi dibandingkan LDA yang memperoleh 0,4830, sehingga terdapat selisih sebesar 0,2815. Selain menghasilkan nilai *coherence* yang lebih tinggi, NMF juga mampu membentuk topik yang lebih spesifik dan mudah diinterpretasikan berdasarkan kata-kata dominannya. Temuan ini memperkuat hasil penelitian sebelumnya yang menunjukkan bahwa pemodelan topik berbasis faktorisasi matriks memiliki kemampuan yang baik dalam menghasilkan topik yang koheren pada representasi TF-IDF. Hasil penelitian ini juga menunjukkan bahwa keunggulan NMF tidak hanya terlihat pada nilai evaluasi kuantitatif, tetapi juga pada kualitas interpretasi topik yang dihasilkan. Selain itu, pengujian pengaruh

stemming menunjukkan bahwa efek preprocessing dapat berbeda pada setiap metode, di mana *stemming* sedikit meningkatkan kualitas topik pada LDA, tetapi justru menurunkan kualitas topik pada NMF. Temuan tersebut menunjukkan bahwa pemilihan tahapan preprocessing perlu disesuaikan dengan karakteristik metode pemodelan yang digunakan agar diperoleh hasil yang optimal.

4.8.4 Implikasi Penelitian

Berdasarkan hasil penelitian yang diperoleh, metode NMF dengan representasi TF-IDF dapat direkomendasikan sebagai pendekatan yang lebih efektif untuk pemodelan topik pada berita online berbahasa Indonesia. Hal ini didukung oleh nilai rata-rata *Topic Coherence (Cv)* yang lebih tinggi, yaitu 0,7645, dibandingkan LDA yang memperoleh 0,4830, serta waktu komputasi yang jauh lebih cepat, yaitu 0,22 detik dibandingkan 63,96 detik pada LDA. Selain itu, topik yang dihasilkan NMF memiliki kata-kata dominan yang lebih spesifik dan mudah diinterpretasikan sehingga memudahkan proses pemberian label topik. Hasil penelitian juga menunjukkan bahwa pengaruh *stemming* berbeda pada setiap metode. Pada LDA, penggunaan *stemming* memberikan peningkatan *coherence* meskipun relatif kecil, sedangkan pada NMF justru menghasilkan nilai *coherence* yang lebih rendah dibandingkan tanpa *stemming*. Oleh karena itu, pemilihan tahapan preprocessing perlu disesuaikan dengan karakteristik metode yang digunakan. Selain itu, meskipun nilai *coherence* tertinggi diperoleh pada jumlah topik tertentu, penelitian ini menetapkan $K = 4$ karena sesuai dengan empat kategori utama dalam dataset, yaitu politik, ekonomi, teknologi, dan olahraga. Hasil tersebut menunjukkan bahwa penentuan jumlah topik tidak hanya perlu mempertimbangkan metrik evaluasi, tetapi juga harus memperhatikan struktur data dan konteks domain agar topik yang dihasilkan tetap relevan dan mudah diinterpretasikan.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan untuk menjawab pertanyaan penelitian mengenai seberapa optimal perbandingan kualitas topik yang dihasilkan oleh metode LDA dan NMF dalam pemodelan topik berita online berbahasa Indonesia berdasarkan nilai *topic coherence*, interpretabilitas, dan kemampuan representasi tema dokumen, dapat disimpulkan bahwa NMF terbukti lebih optimal dibandingkan LDA secara keseluruhan.

Dari segi *topic coherence*, NMF menghasilkan rata-rata nilai C_v sebesar 0,7645 dibandingkan LDA yang hanya 0,4830, dengan selisih 0,2815 atau 58,3% lebih tinggi. NMF unggul pada tiga dari empat topik yang dihasilkan, yaitu topik Teknologi/Sains ($C_v = 0,9860$), Olahraga ($C_v = 0,9130$), dan Politik ($C_v = 0,6087$). Sementara itu, LDA hanya unggul pada topik Ekonomi dengan selisih yang sangat tipis (0,5284 vs 0,5503).

Dari segi interpretabilitas, kata-kata dominan yang dihasilkan NMF lebih eksklusif dan konsisten merepresentasikan satu tema tertentu tanpa tumpang tindih lintas kategori. Sebagai contoh, topik Teknologi pada NMF didominasi oleh kata-kata seperti *nasa*, *misi*, *artemis*, dan *teliti* yang secara jelas mengarah pada tema eksplorasi antariksa. Sebaliknya, topik LDA masih terkontaminasi oleh kata-kata umum seperti *indonesia* dan *perintah* yang muncul di beberapa topik sekaligus, sehingga menurunkan kekhasan dan koherensi topik tersebut.

Dari segi efisiensi komputasi, NMF juga jauh lebih unggul dengan waktu pemrosesan hanya 0,22 detik dibandingkan LDA yang memerlukan 63,96 detik, atau sekitar 291 kali lebih cepat. Perbedaan ini disebabkan oleh perbedaan mekanisme kerja kedua metode, di mana LDA menggunakan pendekatan probabilistik dengan proses inferensi berulang, sedangkan NMF melakukan faktorisasi matriks menggunakan operasi aljabar yang lebih sederhana dan efisien.

Dari segi kemampuan representasi tema dokumen, LDA tetap memiliki keunggulan tersendiri karena sifat probabilistiknya memungkinkan satu dokumen

direpresentasikan sebagai distribusi campuran dari beberapa topik secara bersamaan. Hal ini membuat LDA masih relevan digunakan apabila penelitian membutuhkan analisis distribusi topik yang bersifat campuran pada setiap dokumen. Namun, untuk kebutuhan pemodelan topik yang memprioritaskan kualitas koherensi, ketajaman interpretasi, dan efisiensi komputasi, NMF merupakan pilihan yang lebih unggul.

Dengan demikian, berdasarkan nilai *Topic Coherence* (C_v) yang lebih tinggi, interpretabilitas topik yang lebih baik, serta efisiensi komputasi yang jauh lebih unggul, metode NMF terbukti lebih optimal dibandingkan LDA dalam pemodelan topik berita online berbahasa Indonesia pada dataset yang digunakan.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan beserta keterbatasan yang ditemukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya, antara lain sebagai berikut.

1. Penelitian selanjutnya disarankan untuk mempertimbangkan penggunaan metode pemodelan topik berbasis deep learning, seperti BERTopic atau Top2Vec, sebagai pembanding tambahan terhadap LDA dan NMF. Metode-metode tersebut memanfaatkan representasi semantik kontekstual berbasis transformer yang lebih kaya dan mampu menangkap hubungan makna antar kata secara lebih mendalam, sehingga berpotensi menghasilkan topik yang lebih kohesif dan relevan pada data berita berbahasa Indonesia.
2. Mengingat LDA masih menunjukkan adanya kata-kata umum lintas kategori yang menurunkan nilai coherence pada beberapa topik, penelitian selanjutnya disarankan untuk melakukan penyesuaian daftar stopwords khusus domain berita online berbahasa Indonesia. Selain itu, dapat dilakukan tuning parameter alpha dan eta secara lebih mendalam menggunakan teknik seperti grid search atau Bayesian optimization, guna meningkatkan ketajaman dan kualitas topik yang dihasilkan oleh metode LDA.
3. Penelitian selanjutnya disarankan untuk menguji pengaruh variasi jumlah topik (K) yang lebih luas serta menggunakan dataset dengan jumlah dokumen yang

lebih besar dan periode data yang lebih panjang, agar hasil perbandingan antara LDA dan NMF dapat lebih digeneralisasi pada konteks berita online berbahasa Indonesia secara umum. Penambahan kategori berita di luar empat kategori yang digunakan (politik, ekonomi, teknologi, olahraga) juga dapat memperkaya cakupan analisis tematik.

4. Mengingat temuan penelitian ini menunjukkan bahwa stemming PySastrawi dapat menyebabkan distorsi semantik seperti kata "pemerintah" yang di-stem menjadi "perintah" sehingga kehilangan maknanya, penelitian selanjutnya disarankan untuk mengeksplorasi pendekatan lemmatization sebagai alternatif. Berbeda dengan stemming yang memotong imbuhan secara mekanis, lemmatization mengubah kata ke bentuk dasar yang secara semantik lebih tepat dan mempertahankan makna aslinya, sehingga berpotensi meningkatkan kualitas pemodelan topik khususnya pada metode NMF.

5. Hasil pemodelan topik pada penelitian ini dapat dikembangkan lebih lanjut menjadi sistem visualisasi atau dashboard interaktif yang memudahkan pemantauan tren tematik berita online berbahasa Indonesia secara berkala dan real-time. Pengembangan sistem ini dapat mengintegrasikan pipeline preprocessing, pemodelan NMF, dan visualisasi topik dalam satu platform yang mudah digunakan oleh pengguna non-teknis seperti jurnalis, analis media, maupun lembaga pemantau berita.

6. Penelitian selanjutnya juga dapat mengkombinasikan pendekatan pemodelan topik dengan analisis sentimen untuk memperoleh pemahaman yang lebih komprehensif mengenai isi berita online berbahasa Indonesia, tidak hanya dari sisi identifikasi tema, tetapi juga dari sisi tendensi opini dan polaritas pemberitaan pada masing-masing topik yang dihasilkan

DAFTAR PUSTAKA

- .Egger, R., & Yu, J. (2022). A topic modeling comparison between lda, nmf, top2vec, and bertopic to demystify twitter posts. *Frontiers in sociology*, 7, 886498.
- .Latif, S., Shafait, F., & Latif, R. (2021). Analyzing LDA and NMF topic models for Urdu tweets via automatic labeling. *IEEE Access*, 9, 127531-127547.
- .Janssens, W., Bogaert, M., & Van den Poel, D. (2025). A Comparative Analysis of Topic Reduction Techniques for BERTopic. *IEEE Access*, 13, 204087-204103.
- .Gottumukkala, D. P., PVGD, P. R., & Rao, S. K. (2025). Topic modeling-based prediction of software defects and root cause using BERTopic, and multioutput classifier. *Scientific Reports*, 15(1), 25428.
- .Ibrohim, M. O., Bosco, C., & Basile, V. (2023). Sentiment analysis for the natural environment: A systematic review. *ACM Computing Surveys*, 56(4), 1-37.
- .Massenon, R., Gambo, I., Ogundokun, R. O., Ogundepo, E. A., Srivastava, S., Agarwal, S., & Pak, W. (2024). Mobile app review analysis for crowdsourcing of software requirements: a mapping study of automated and semi-automated tools. *PeerJ Computer Science*, 10, e2401.
- .Muthusami, R., Mani Kandan, N., Saritha, K., Narenthiran, B., Nagaprasad, N., & Ramaswamy, K. (2024). Investigating topic modeling techniques through evaluation of topics discovered in short texts data across diverse domains. *Scientific Reports*, 14(1), 12003.
- .Gurcan, F., & Cagiltay, N. E. (2022). Exploratory analysis of topic interests and their evolution in bioinformatics research using semantic text mining and probabilistic topic modeling. *IEEE Access*, 10, 31480-31493
- .Kumi, S., Snow, C., Lomotey, R. K., & Deters, R. (2024). Uncovering concerns of citizens through machine learning and social network sentiment analysis.

- Ieee Access, 12, 94885-94913.
- .Sik, D., Németh, R., & Katona, E. (2023). Topic modelling online depression forums: beyond narratives of self-objectification and self-blaming. *Journal of Mental Health*, 32(2), 386-395.
- .Li, J., & Chang, X. (2023). Combating misinformation by sharing the truth: a study on the spread of fact-checks on social media. *Information systems frontiers*, 25(4), 1479-1493.
- .Murshed, B. A. H., Mallappa, S., Abawajy, J., Saif, M. A. N., Al-Ariki, H. D. E., & Abdulwahab, H. M. (2023). Short text topic modelling approaches in the context of big data: taxonomy, survey, and analysis. *Artificial Intelligence Review*, 56(6), 5133-5260.
- .Ebrahimi, S. F., & Peltonen, J. (2025, November). Constrained non-negative matrix factorization for guided topic modeling of minority topics. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (pp. 35561-35586).
- .Hou, Y., & Huang, J. (2025). Natural language processing for social science research: A comprehensive review. *Chinese Journal of Sociology*, 11(1), 121-157.
- .Umamaheswaran, S., Dar, V., Sharma, E., & Kurian, J. S. (2023). Mapping climate themes from 2008-2021—an analysis of business news using topic models. *IEEE Access*, 11, 26554-26565.
- .Qiang, J., Qian, Z., Li, Y., Yuan, Y., & Wu, X. (2020). Short text topic modeling techniques, applications, and performance: a survey. *IEEE transactions on knowledge and data engineering*, 34(3), 1427-1445.
- .Hua, T., Lu, C. T., Choo, J., & Reddy, C. K. (2020). Probabilistic topic modeling for comparative analysis of document collections. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 14(2), 1-27.
- .Vayansky, I., & Kumar, S. A. (2020). A review of topic modeling methods. *Information Systems*, 94, 101582.

- .Atzberger, D., Cech, T., Trapp, M., Richter, R., Scheibel, W., Döllner, J., & Schreck, T. (2023). Large-scale evaluation of topic models and dimensionality reduction methods for 2d text spatialization. *IEEE Transactions on Visualization and Computer Graphics*, 30(1), 902-912.
- .Curiskis, S. A., Drake, B., Osborn, T. R., & Kennedy, P. J. (2020). An evaluation of document clustering and topic modelling in two online social networks: Twitter and Reddit. *Information Processing & Management*, 57(2), 102034.
- .He, W., Hou, B., Zheng, A., Feng, Y., Klein, A., O'Connor, K., ... & Shen, L. (2025). Advanced topic modeling with large language models: Analyzing social media content from dementia caregivers. *Innovation in Aging*, 9(Supplement_1), S38-S47.
- .Vangara, R., Bhattarai, M., Skau, E., Chennupati, G., Djidjev, H., Tierney, T., ... & Alexandrov, B. S. (2021). Finding the number of latent topics with semantic non-negative matrix factorization. *IEEE access*, 9, 117217-117231.
- .Zuo, Y., Li, C., Lin, H., & Wu, J. (2021). Topic modeling of short texts: A pseudo-document view with word embedding enhancement. *IEEE Transactions on Knowledge and Data Engineering*, 35(1), 972-985.
- .Voskergian, D., Jayousi, R., & Yousef, M. (2024). Topic selection for text classification using ensemble topic modeling with grouping, scoring, and modeling approach. *Scientific Reports*, 14(1), 23516.
- .Li, Q., Peng, H., Li, J., Xia, C., Yang, R., Sun, L., ... & He, L. (2022). A survey on text classification: From traditional to deep learning. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 13(2), 1-41.
- .Abdelrazek, A., Eid, Y., Gawish, E., Medhat, W., & Hassan, A. (2023). Topic modeling algorithms and applications: A survey. *Information Systems*, 112, 102131.
- .Churchill, R., & Singh, L. (2022). The evolution of topic modeling. *ACM Computing Surveys*, 54(10s), 1-35.

- .Chauhan, U., & Shah, A. (2021). Topic modeling using latent Dirichlet allocation: A survey. *ACM Computing Surveys (CSUR)*, 54(7), 1-35.
- .Meaney, C., Stukel, T. A., Austin, P. C., Moineddin, R., Greiver, M., & Escobar, M. (2023). Quality indices for topic model selection and evaluation: a literature review and case study. *BMC Medical Informatics and Decision Making*, 23(1), 132.
- .Amaro, A., & Bacao, F. (2024). Topic modeling: A consistent framework for comparative studies. *Emerging Science Journal*, 8(1), 125-139.
- .M'sik, B., & Casablanca, B. M. (2020). Topic modeling coherence: A comparative study between LDA and NMF models using COVID'19 corpus. *International Journal*, 9(4), 5756-5761.
- .Hosseiny Marani, A., & Baumer, E. P. (2023). A review of stability in topic modeling: Metrics for assessing and techniques for improving stability. *ACM Computing Surveys*, 56(5), 1-32.
- .Korenčić, D., Ristov, S., Repar, J., & Šnajder, J. (2021). A topic coverage approach to evaluation of topic models. *IEEE access*, 9, 123280-123312.
- .Rüdiger, M., Antons, D., Joshi, A. M., & Salge, T. O. (2022). Topic modeling revisited: New evidence on algorithm performance and quality metrics. *Plos one*, 17(4), e0266325.
- .Ghasiya, P., & Okamura, K. (2021). Understanding the Middle East through the eyes of Japan's Newspapers: A topic modelling and sentiment analysis approach. *Digital Scholarship in the Humanities*, 36(4), 871-885.
- .Umamaheswaran, S., Dar, V., Sharma, E., & Kurian, J. S. (2023). Mapping climate themes from 2008-2021—an analysis of business news using topic models. *IEEE Access*, 11, 26554-26565.
- .Khodeir, N., & Elghannam, F. (2025). Efficient topic identification for urgent MOOC Forum posts using BERTopic and traditional topic modeling techniques. *Education and Information Technologies*, 30(5), 5501-5527.

- .Batool, A., & Byun, Y. C. (2024). Enhanced sentiment analysis and topic modeling during the pandemic using automated latent Dirichlet allocation. *IEEE Access*, 12, 81206-81220.
- .Balasubramaniam, T., Nayak, R., Luong, K., & Bashar, M. A. (2021). Identifying Covid-19 misinformation tweets and learning their spatio-temporal topic dynamics using Nonnegative Coupled Matrix Tensor Factorization. *Social Network Analysis and Mining*, 11(1), 57.
- .Jung, H. S., Lee, H., Woo, Y. S., Baek, S. Y., & Kim, J. H. (2024). Expansive data, extensive model: Investigating discussion topics around LLM through unsupervised machine learning in academic papers and news. *Plos one*, 19(5), e0304680.
- .Silva, C. C., Galster, M., & Gilson, F. (2021). Topic modeling in software engineering research. *Empirical Software Engineering*, 26(6), 120.

DAFTAR RIWAYAT HIDUP



Nama : Aurellia Zhullvita Amanullah
TTL : Ponorogo, 24 juli 2003
Alamat : Graha Mentari, Kabupaten Bangkalan Jawa Timur
Program Studi : Teknik Informatika
Telpon/WA : 085233406129
Email : Aurelliazhulvita@gmail.com

RIWAYAT PENDIDIKAN

- | | |
|--|-------------|
| 1. TK ISLAM TERPADU ROBBANIYYIN
BANGKALAN | 2008 – 2010 |
| 2. SDN NEGERI DEMANGAN 1 BANGKALAN | 2013 – 2016 |
| 3. SMP NEGERI 2 BANGKALAN | 2016 – 2018 |
| 4. SMA NEGERI 1 BANGKALAN | 2019 – 2022 |
| 5. UNIVERSITAS TRUNODJOYO MADURA | 2022 – 2026 |